

第二章：概率论与机器学习核心概念

从贝叶斯定理到信息论

《深度学习基础》课程小组

2026 年 2 月 25 日

目录

- 1 Bayes' theorem
- 2 prior probability
- 3 posterior probability
- 4 Independent variables
- 5 probability density function
- 6 cumulative distribution function
- 7 expectation
- 8 covariance
- 9 conditional expectation
- 10 Gaussian distribution
- 11 likelihood function
- 12 problem of over-fitting
- 13 sum-of-squares error function
- 14 entropy of the random variable
- 15 differential entropy
- 16 relative entropy or Kullback–Leibler divergence
- 17 conditional entropy
- 18 mutual information
- 19 maximum a posteriori estimate
- 20 Bayesian machine learning

贝叶斯定理 (Bayes' Theorem)

定义

贝叶斯定理描述了在已知相关证据 B 的情况下，事件 A 发生的概率如何更新。它是贝叶斯统计推断的核心。它提供了一种根据新数据更新信念（概率）的数学框架。

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

- $P(A|B)$: 后验概率 (Posterior)
- $P(B|A)$: 似然函数 (Likelihood)
- $P(A)$: 先验概率 (Prior)
- $P(B)$: 证据或边际概率 (Evidence)

先验概率 (Prior Probability)

定义

在观察到任何新数据或证据之前，基于现有知识、历史数据或主观信念对事件发生概率的估计。

- 记作 $P(\theta)$ 或 $P(A)$ 。
- 代表“事前”的信念。
- 在贝叶斯推断中，先验可以是无信息的 (Uniform)，也可以是有信息的 (Informative)。

示例

在抛硬币实验中，如果我们认为硬币是公平的，那么正面朝上的先验概率 $P(H) = 0.5$ 。

后验概率 (Posterior Probability)

定义

在考虑了新的证据或数据之后，对事件发生概率的修正估计。

- 记作 $P(\theta|D)$ 或 $P(A|B)$ 。
- 是贝叶斯推断的最终目标。
- 计算公式：后验 $\propto$ 似然 $\times$ 先验。

直观理解

后验概率结合了我们的初始信念（先验）和新观察到的数据（似然），反映了更新后的认知状态。

独立变量 (Independent Variables)

定义

如果两个随机变量 X 和 Y 的联合概率分布等于它们边缘概率分布的乘积，则称它们是统计独立的。

$$P(X, Y) = P(X)P(Y)$$

或者条件概率形式：

$$P(X|Y) = P(X) \quad (\text{当 } P(Y) > 0)$$

- 独立性意味着知道 Y 的值不会提供关于 X 的任何信息。
- 注意：独立一定不相关，但不相关不一定独立（除非是高斯分布）。

概率密度函数 (PDF)

定义

对于连续型随机变量 X ，概率密度函数 $f(x)$ 描述了变量在某个特定值附近的相对可能性。

- $f(x) \geq 0$
- $\int_{-\infty}^{\infty} f(x) dx = 1$
- 变量落在区间 $[a, b]$ 的概率为: $P(a \leq X \leq b) = \int_a^b f(x) dx$

注意

$f(x)$ 本身不是概率 (可以大于 1)，只有积分面积才是概率。

累积分布函数 (CDF)

定义

累积分布函数 $F(x)$ 表示随机变量 X 取值小于或等于 x 的概率。

$$F(x) = P(X \leq x)$$

- 对于连续变量: $F(x) = \int_{-\infty}^x f(t) dt$ 。
- 性质: 单调不减, $F(-\infty) = 0$, $F(\infty) = 1$ 。
- PDF 是 CDF 的导数: $f(x) = \frac{d}{dx} F(x)$ 。

期望 (Expectation)

定义

期望（或均值）是随机变量取值的加权平均，权重为对应的概率。它描述了分布的中心位置。

- 离散型: $\mathbb{E}[X] = \sum_x xP(X = x)$
- 连续型: $\mathbb{E}[X] = \int_{-\infty}^{\infty} xf(x)dx$
- 线性性质: $\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$

意义

如果在大量重复实验中观测随机变量，其算术平均值将收敛于期望值（大数定律）。

协方差 (Covariance)

定义

协方差衡量两个随机变量 X 和 Y 之间的线性相关程度及其方向。

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$$

- $\text{Cov}(X, Y) > 0$: 正相关 (同向变化)。
- $\text{Cov}(X, Y) < 0$: 负相关 (反向变化)。
- $\text{Cov}(X, Y) = 0$: 不相关 (但不一定独立)。
- $\text{Var}(X) = \text{Cov}(X, X)$ 。

条件期望 (Conditional Expectation)

定义

在已知另一个随机变量 Y 取特定值 y 的条件下, 随机变量 X 的期望值。

$$\mathbb{E}[X|Y=y] = \begin{cases} \sum_x xP(X=x|Y=y) & (\text{离散}) \\ \int_{-\infty}^{\infty} xf_{X|Y}(x|y)dx & (\text{连续}) \end{cases}$$

全期望公式

$\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X|Y]]$ 。即：无条件期望等于条件期望的期望。

高斯分布 (Gaussian Distribution)

定义

又称正态分布，是最常见的连续概率分布，由均值 μ 和方差 σ^2 完全确定。

$$\mathcal{N}(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

- 钟形曲线，关于 μ 对称。
- 中心极限定理：大量独立随机变量之和趋向于高斯分布。
- 在机器学习中广泛用于噪声建模和先验假设。

似然函数 (Likelihood Function)

定义

给定观测数据 D 时，关于模型参数 θ 的函数。它衡量参数 θ 产生该数据的可能性。

$$L(\theta|D) = P(D|\theta)$$

- 注意：虽然形式上等于条件概率，但视为 θ 的函数时，它不是概率分布（对 θ 积分不一定为 1）。
- **最大似然估计 (MLE)**: 寻找使 $L(\theta|D)$ 最大的 θ 。

区别

概率是固定参数预测数据；似然是固定数据评估参数。

过拟合问题 (Problem of Over-fitting)

定义

模型在训练数据上表现极好（误差很低），但在未见过的测试数据上表现很差的现象。

- **原因:** 模型过于复杂，记住了训练数据中的噪声而非潜在规律。
- **特征:** 高方差 (High Variance)，低偏差 (Low Bias)。
- **解决方法:**
 - 正则化 (Regularization, e.g., L1, L2)
 - 增加训练数据
 - 降低模型复杂度
 - Dropout (神经网络)
 - 交叉验证

平方和误差函数 (Sum-of-Squares Error)

定义

常用于回归问题的损失函数，衡量模型预测值 $y(x, w)$ 与真实目标值 t 之间的差异。

$$E(w) = \frac{1}{2} \sum_{n=1}^N \{y(x_n, w) - t_n\}^2$$

- 假设噪声服从高斯分布时，最小化 SSE 等价于最大似然估计。
- 系数 $\frac{1}{2}$ 是为了求导方便。
- 对异常值 (Outliers) 敏感。

随机变量的熵 (Entropy)

定义

熵 $H(X)$ 衡量离散随机变量 X 的不确定性或信息含量。

$$H(X) = - \sum_x P(x) \log_2 P(x)$$

- 单位通常为比特 (bits)。
- $H(X) \geq 0$ 。
- 当分布均匀时熵最大 (最不确定); 当某事件概率为 1 时熵为 0 (确定)。
- 表示编码该变量所需的最小平均比特数。

微分熵 (Differential Entropy)

定义

连续随机变量 X 的熵的推广，称为微分熵 $h(X)$ 。

$$h(X) = - \int_{-\infty}^{\infty} f(x) \log f(x) dx$$

注意

- 微分熵可以是负数（不同于离散熵）。
- 它不是绝对信息量的度量，而是相对于均匀分布的相对度量。
- 坐标变换下不具有不变性。

相对熵 / KL 散度 (KL Divergence)

定义

衡量两个概率分布 P (真实分布) 和 Q (近似分布) 之间差异的非对称度量。

$$D_{\text{KL}}(P||Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)} = \mathbb{E}_P \left[\log \frac{P(x)}{Q(x)} \right]$$

- $D_{\text{KL}}(P||Q) \geq 0$, 当且仅当 $P = Q$ 时取等号。
- 非对称: $D_{\text{KL}}(P||Q) \neq D_{\text{KL}}(Q||P)$ 。
- 广泛应用于变分推断、生成模型 (如 VAE) 和强化学习。

条件熵 (Conditional Entropy)

定义

在已知随机变量 Y 的条件下，随机变量 X 剩余的不确定性。

$$H(X|Y) = \sum_y P(y)H(X|Y=y) = - \sum_{x,y} P(x,y) \log P(x|y)$$

- 链式法则: $H(X, Y) = H(Y) + H(X|Y)$ 。
- $H(X|Y) \leq H(X)$: 知道 Y 的信息永远不会增加 X 的不确定性。
- 若 X, Y 独立, 则 $H(X|Y) = H(X)$ 。

互信息 (Mutual Information)

定义

衡量两个随机变量 X 和 Y 之间相互依赖程度的量。表示知道其中一个变量能减少另一个变量多少不确定性。

$$I(X; Y) = H(X) - H(X|Y) = H(Y) - H(Y|X)$$

或者用 KL 散度表示：

$$I(X; Y) = D_{\text{KL}}(P(X, Y) || P(X)P(Y))$$

- $I(X; Y) \geq 0$ 。
- 若 X, Y 独立, 则 $I(X; Y) = 0$ 。
- 对称性: $I(X; Y) = I(Y; X)$ 。

最大后验估计 (MAP Estimate)

定义

一种参数估计方法，通过最大化后验概率来寻找最优参数 θ 。

$$\hat{\theta}_{\text{MAP}} = \arg \max_{\theta} P(\theta|D) = \arg \max_{\theta} P(D|\theta)P(\theta)$$

- 结合了似然 $P(D|\theta)$ 和先验 $P(\theta)$ 。
- 是贝叶斯学派的一种点估计方法。
- 当先验为均匀分布时，MAP 退化为最大似然估计 (MLE)。
- 正则化项通常对应于先验分布（例如 L2 正则化对应高斯先验）。

贝叶斯机器学习 (Bayesian Machine Learning)

定义

一种机器学习方法论，将模型参数视为随机变量，利用贝叶斯定理结合先验知识和观测数据来推断参数的后验分布，而非单一的点估计。

- **核心优势:**

- 自然地处理不确定性 (Uncertainty Quantification)。
- 有效防止过拟合 (通过积分边缘化参数)。
- 可以融入领域知识 (通过先验)。

- **挑战:** 后验分布的计算通常难以解析求解，需借助近似推断 (如 MCMC, 变分推断 VI)。