

第二章：深度学习中的概率论 - 核心概念解释与练习

从贝叶斯定理到信息论


《深度学习基础》课程小组

2026 年 3 月 1 日

目录

- 1 深度学习中的概率论的知识图谱
- 2 基础概率与贝叶斯定理
- 3 统计量与高斯分布
- 4 信息论基础
- 5 推断与机器学习应用

深度学习中的概率论的知识图谱



贝叶斯定理 (Bayes' Theorem)

- **定义**：描述两个事件 A 和 B 之间条件概率关系的定理，是贝叶斯统计学的基石。
- **公式**：
$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$
- **在机器学习中的形式**：
$$p(\theta|D) = \frac{p(D|\theta)p(\theta)}{p(D)}$$
 - $p(\theta|D)$ ：后验概率 (Posterior)。
 - $p(D|\theta)$ ：似然 (Likelihood)。
 - $p(\theta)$ ：先验 (Prior)。
 - $p(D)$ ：证据 (Evidence) 或边缘似然。
- **意义**：提供了从“数据更新信念”的数学框架。我们将先验知识结合观测数据，得到更新后的参数分布。

先验概率 (Prior Probability)

- **定义**：在观测到任何数据之前，对参数 θ 或事件 A 的概率分布的初始信念。
- **表示**： $p(\theta)$ 或 $P(A)$ 。
- **作用**：
 - 引入领域知识（例如：权重通常较小，可用高斯先验）。
 - 起到正则化的作用，防止模型过度依赖少量数据。
- **类型**：
 - **信息性先验 (Informative Prior)**：基于具体知识设定（如 $\theta \sim \mathcal{N}(0, 1)$ ）。
 - **非信息性先验 (Non-informative Prior)**：表示无知（如均匀分布）。
- **深度学习**中：L2 正则化等价于高斯先验，L1 正则化等价于拉普拉斯先验。

后验概率 (Posterior Probability)

- **定义：** 在观测到数据 D 之后，对参数 θ 或类别 C_k 的更新后的概率分布。
- **表示：** $p(\theta|D)$ 或 $P(C_k|\mathbf{x})$ 。
- **核心地位：**
 - 是贝叶斯推断的最终目标。
 - 包含了数据和先验的所有信息。
- **在分类中的应用：**
 - 判别式模型直接建模 $p(C_k|\mathbf{x})$ 。
 - 生成式模型通过贝叶斯定理计算 $p(C_k|\mathbf{x}) \propto p(\mathbf{x}|C_k)p(C_k)$ 。
- **挑战：** 计算分母 $p(D)$ 通常涉及高维积分，难以解析求解，需借助近似推断 (MCMC, 变分推断)。

独立变量 (Independent Variables)

- **定义**: 两个随机变量 X 和 Y 如果满足 $P(X, Y) = P(X)P(Y)$, 则称它们相互独立。
- **条件独立**: 给定 Z 时, X 和 Y 独立, 记为 $X \perp Y|Z$, 即 $P(X, Y|Z) = P(X|Z)P(Y|Z)$ 。
- **在深度学习中的假设**:
 - **i.i.d. 假设**: 训练数据样本之间通常是独立同分布 (Independent and Identically Distributed) 的。这使得似然函数可以写成连乘形式: $L = \prod p(x_i)$ 。
 - **朴素贝叶斯**: 假设特征之间条件独立, 极大地简化了计算。
- **注意**: 在序列数据 (如时间序列、文本) 中, 独立性假设通常不成立, 需使用 RNN 或 Transformer 建模依赖关系。

概率密度函数 (Probability Density Function, PDF)

- **定义**: 描述连续型随机变量 x 在某个特定取值点附近的相对可能性。记为 $p(x)$ 。
- **性质**:
 - 非负性: $p(x) \geq 0$ 。
 - 归一化: $\int_{-\infty}^{\infty} p(x) dx = 1$ 。
 - 概率计算: x 落在区间 $[a, b]$ 的概率为 $\int_a^b p(x) dx$ 。
- **区别**: $p(x)$ 的值本身不是概率 (可以大于 1), 只有积分才是概率。
- **应用**: 定义损失函数 (如负对数似然)、生成模型的目标分布。

累积分布函数 (Cumulative Distribution Function, CDF)

- **定义：** 随机变量 X 小于或等于某个值 x 的概率。

$$F(x) = P(X \leq x) = \int_{-\infty}^x p(t) dt$$

- **性质：**

- 单调不减。
- $F(-\infty) = 0, F(\infty) = 1$ 。
- 与 PDF 的关系： $p(x) = \frac{d}{dx} F(x)$ 。

- **应用：**

- **逆变换采样：** 若 $u \sim U[0, 1]$, 则 $x = F^{-1}(u)$ 服从分布 F 。常用于生成模型采样。
- 计算分位数 (如中位数)。

期望 (Expectation)

- **定义**: 随机变量取值的加权平均, 权重为概率。
- **公式**:
 - 离散: $\mathbb{E}[f(x)] = \sum_x p(x) f(x)$
 - 连续: $\mathbb{E}[f(x)] = \int p(x) f(x) dx$
- **线性性质**: $\mathbb{E}[ax + by] = a\mathbb{E}[x] + b\mathbb{E}[y]$, 无论 x, y 是否独立。
- **经验期望**: 在机器学习中, 通常用样本均值近似总体期望:

$$\mathbb{E}[f(x)] \approx \frac{1}{N} \sum_{n=1}^N f(x_n)$$

- **应用**: 损失函数的定义 (期望风险)、梯度下降中的期望梯度。

协方差 (Covariance)

- **定义：** 衡量两个随机变量 x 和 y 之间的线性相关程度。

$$\text{Cov}[x, y] = \mathbb{E}[(x - \mathbb{E}[x])(y - \mathbb{E}[y])] = \mathbb{E}[xy] - \mathbb{E}[x]\mathbb{E}[y]$$

- **协方差矩阵：** 对于随机向量 $\mathbf{x}$, $\Sigma = \mathbb{E}[(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T]$ 。

- **解释：**

- $\text{Cov} > 0$ ：正相关（同向变化）。
- $\text{Cov} < 0$ ：负相关（反向变化）。
- $\text{Cov} = 0$ ：不相关（但不一定独立，除非是高斯分布）。

- **深度学习应用：**

- PCA（主成分分析）基于协方差矩阵的特征分解。
- Batch Normalization 利用批内协方差统计量进行归一化。
- 自注意力机制 (Self-Attention) 本质上在建模 token 间的协方差关系。

条件期望 (Conditional Expectation)

- **定义：**在已知随机变量 $Y = y$ 的条件下， X 的期望值。记为 $\mathbb{E}[X|Y = y]$ 。

$$\mathbb{E}[X|Y] = \int x p(x|Y) dx$$

- **作为函数：** $\mathbb{E}[X|Y]$ 本身是一个关于 Y 的随机变量。
- **回归的最优解：**
 - 在最小化平方损失 $L = (y - t)^2$ 的意义下，最优预测函数 $y(x)$ 就是目标变量的条件期望：

$$y^*(\mathbf{x}) = \mathbb{E}[t|\mathbf{x}]$$

- **全期望公式：** $\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X|Y]]$ 。

高斯分布 (Gaussian Distribution)

- **别名：**正态分布 (Normal Distribution)。
- **重要性：**由中心极限定理支撑，是深度学习和统计学中最核心的分布。
- **一元形式：**

$$\mathcal{N}(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

- **多元形式：**

$$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{D/2}|\boldsymbol{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^T\boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu})\right)$$

- **关键性质：**
 - 完全由一阶矩（均值）和二阶矩（协方差）决定。
 - 线性变换后仍为高斯。
 - 边缘分布和条件分布仍为高斯。

似然函数 (Likelihood Function)

- **定义**：给定数据 D 下，关于参数 θ 的函数，形式上等于联合概率密度，但视角不同。

$$L(\theta) = p(D|\theta) = \prod_{n=1}^N p(\mathbf{x}_n|\theta)$$

- **与概率的区别**：
 - 概率：固定参数，预测数据。
 - 似然：固定数据，评估参数。
- **最大似然估计 (MLE)**：寻找 θ_{ML} 使得 $L(\theta)$ 最大。
- **对数似然**：为了方便计算，通常最大化 $\ln L(\theta)$ ，将连乘转为求和。
- **联系**：最小化平方和误差等价于在高斯噪声假设下的最大似然估计。

随机变量的熵 (Entropy)

- **定义：** 衡量随机变量不确定性的度量，或编码该变量所需的最小平均比特数。

$$\mathcal{H}[x] = - \sum_x p(x) \log_2 p(x) \quad (\text{离散})$$

$$\mathcal{H}[x] = - \int p(x) \ln p(x) dx \quad (\text{连续, 即微分熵})$$

- **性质：**

- 熵越大，不确定性越高，分布越均匀。
- 熵越小，确定性越高，分布越集中。
- 对于离散变量，均匀分布时熵最大。

- **应用：**

- 决策树分裂标准（信息增益）。
- 强化学习中的最大熵探索。
- 生成模型的目标（最大化生成数据的似然等价于最小化交叉熵）。

微分熵 (Differential Entropy)

- **定义：**连续随机变量的熵。

$$\mathcal{H}[x] = - \int p(x) \ln p(x) dx$$

- **与离散熵的区别：**

- 可以为负值（因为概率密度 $p(x)$ 可以大于 1）。
- 不具有坐标变换不变性（随变量缩放而变化）。
- 不代表绝对的最小编码长度，而是相对于均匀分布的相对度量。

- **高斯分布的微分熵：**

$$\mathcal{H}[\mathcal{N}(\mu, \sigma^2)] = \frac{1}{2} \ln(2\pi e\sigma^2)$$

在所有具有相同方差的分布中，高斯分布的微分熵最大。

相对熵 / KL 散度 (Relative Entropy / KL Divergence)

- **定义：** 衡量两个概率分布 $p(x)$ 和 $q(x)$ 之间的差异（非对称距离）。

$$\text{KL}(p||q) = - \int p(x) \ln \frac{q(x)}{p(x)} dx = \mathbb{E}_{p(x)}[\ln p(x)] - \mathbb{E}_{p(x)}[\ln q(x)]$$

- **性质：**

- 非负性： $\text{KL}(p||q) \geq 0$ ，当且仅当 $p = q$ 时取等号。
- 非对称性： $\text{KL}(p||q) \neq \text{KL}(q||p)$ 。

- **深度学习应用：**

- **变分自编码器 (VAE)：** 损失函数包含 KL 散度项，用于约束潜变量分布接近先验（通常是标准高斯）。
- **强化学习：** 约束策略更新幅度 (PPO, TRPO)。
- **蒸馏：** 让学生网络的输出分布逼近教师网络。

条件熵 (Conditional Entropy)

- **定义：** 在已知随机变量 Y 的条件下， X 的不确定性。

$$\mathcal{H}[X|Y] = \sum_y p(y) \mathcal{H}[X|Y=y] = - \sum_{x,y} p(x,y) \ln p(x|y)$$

- **链式法则：**

$$\mathcal{H}[X, Y] = \mathcal{H}[Y] + \mathcal{H}[X|Y]$$

联合熵等于 Y 的熵加上已知 Y 后 X 的剩余熵。

- **性质：** $\mathcal{H}[X|Y] \leq \mathcal{H}[X]$ 。知道更多信息 (Y) 只会减少或保持不确定性，不会增加。
- **应用：** 定义互信息的基础。

互信息 (Mutual Information)

- **定义**：衡量两个随机变量 X 和 Y 之间相互依赖程度的量。

$$I[X; Y] = \mathcal{H}[X] - \mathcal{H}[X|Y] = \mathcal{H}[Y] - \mathcal{H}[Y|X]$$

也可以表示为联合分布与边缘分布乘积的 KL 散度：

$$I[X; Y] = \text{KL}(p(x, y) || p(x)p(y))$$

- **解释**：知道 Y 后， X 的不确定性减少了多少。

- **性质**：

- 对称性： $I[X; Y] = I[Y; X]$ 。
- 非负性： $I[X; Y] \geq 0$ 。
- 若独立，则 $I[X; Y] = 0$ 。

- **应用**：

- 特征选择。
- InfoGAN：最大化潜变量与生成图像部分的互信息以解耦特征。
- Deep InfoMax：最大化局部与全局特征的互信息进行无监督学习。

过拟合问题 (Problem of Over-fitting)

- **定义：**模型在训练数据上表现极好（误差低），但在未见过的测试数据上表现差（泛化能力弱）。
- **原因：**
 - 模型过于复杂（参数过多），记住了训练数据的噪声而非规律。
 - 训练数据量不足。
- **概率视角：**
 - 最大似然估计 (MLE) 倾向于选择极其复杂的模型以完美拟合数据，导致过拟合。
 - MLE 没有考虑参数的先验信念。
- **解决方案：**
 - 正则化 (Regularization)。
 - 贝叶斯方法 (引入先验)。
 - Dropout, 数据增强, 早停法 (Early Stopping)。

平方和误差函数 (Sum-of-Squares Error Function)

- **定义：**最常用的回归损失函数。

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N (y(\mathbf{x}_n, \mathbf{w}) - t_n)^2$$

- **概率推导：**
 - 假设目标值 t 由模型输出加高斯噪声生成： $t = y(\mathbf{x}, \mathbf{w}) + \epsilon$, $\epsilon \sim \mathcal{N}(0, \beta^{-1})$ 。
 - 此时，最大化似然函数 $\ln p(D|\mathbf{w})$ 等价于最小化平方和误差。
- **缺点：**对异常值 (Outliers) 敏感，因为误差被平方放大。
- **扩展：**加入正则化项 $\frac{\lambda}{2} \|\mathbf{w}\|^2$ 即为正则化最小二乘法。

最大后验估计 (Maximum A Posteriori Estimate, MAP)

- **定义：** 寻找使后验概率 $p(\theta|D)$ 最大的参数值 θ_{MAP} 。

$$\theta_{MAP} = \arg \max_{\theta} p(\theta|D) = \arg \max_{\theta} [\ln p(D|\theta) + \ln p(\theta)]$$

- **对比 MLE：**

- MLE: $\arg \max \ln p(D|\theta)$ (仅看数据)。
- MAP: $\arg \max (\ln p(D|\theta) + \ln p(\theta))$ (数据 + 先验)。

- **正则化解释：**

- 高斯先验 $\rightarrow$ L2 正则化。
- 拉普拉斯先验 $\rightarrow$ L1 正则化。

- **局限：** MAP 只是一个点估计，忽略了后验分布的形状（不确定性），不如全贝叶斯推断完整。

贝叶斯机器学习 (Bayesian Machine Learning)

- **核心理念**: 不寻求单一的“最佳”参数点, 而是计算参数的完整后验分布 $p(\theta|D)$ 。

- **预测**: 通过积分 (边缘化) 所有可能的参数进行预测:

$$p(t|\mathbf{x}, D) = \int p(t|\mathbf{x}, \theta) p(\theta|D) d\theta$$

- **优势**: (1) **自然防止过拟合**: 通过先验和边缘化自动实现奥卡姆剃刀原理。
(2) **不确定性量化**: 预测结果不仅包含值, 还包含置信度 (方差)。这对安全关键应用 (如自动驾驶、医疗) 至关重要。
- **挑战与方法**: 积分通常难以计算。常用近似方法: 变分推断 (Variational Inference, VI)、马尔可夫链蒙特卡洛 (MCMC)、拉普拉斯近似。
- **现代应用**: 贝叶斯神经网络 (BNN)、高斯过程 (GP)、扩散模型 (Diffusion Models)。

总结

- **基础**：贝叶斯定理连接了先验、似然和后验，是理解模型更新的钥匙。
- **统计量**：期望、协方差和高斯分布构成了建模数据分布的语言。
- **信息论**：熵、KL 散度和互信息提供了衡量不确定性、分布差异和信息量的工具，是许多损失函数的理论基础。
- **推断**：从 MLE 到 MAP 再到全贝叶斯推断，我们逐渐从点估计走向分布估计，从而更好地解决过拟合问题并量化不确定性。
- **掌握这些概率理论概念**，是深入理解现代深度学习算法（如 VAE, GAN, Transformer, Diffusion）的前提。