

第三章：深度学习中的标准分布 - 概念解析与习题

从离散分布到非参数方法


《深度学习基础》课程小组

2026 年 3 月 2 日

目录

- 1 深度学习中的标准分布的知识图谱
- 2 离散概率分布
- 3 多元高斯分布 (Multivariate Gaussian)
- 4 混合模型与特殊分布
- 5 通用理论与非参数方法
- 6 标准分布的十个习题

深度学习中的标准分布的知识图谱



伯努利分布 (Bernoulli Distribution)

- **定义**: 描述单次二元试验 (如抛硬币) 结果的分布。
- **变量**: $x \in \{0, 1\}$, 其中 1 代表 “成功”, 0 代表 “失败”。
- **参数**: $\mu = p(x = 1)$, 即成功的概率, $0 \leq \mu \leq 1$ 。
- **概率质量函数 (PMF)**:

$$\text{Bern}(x|\mu) = \mu^x(1 - \mu)^{1-x}$$

- **数字特征**:
 - 均值: $\mathbb{E}[x] = \mu$
 - 方差: $\text{Var}[x] = \mu(1 - \mu)$
- **应用**: 二分类问题的输出层 (如逻辑回归), 生成式建模中的二值像素。

二项分布 (Binomial Distribution)

- **定义**: 描述 N 次独立的伯努利试验中, “成功” 次数 m 的分布。
- **变量**: $m \in \{0, 1, \dots, N\}$ 。
- **参数**: N (试验次数), μ (单次成功概率)。
- **概率质量函数**:

$$\text{Bin}(m|N, \mu) = \binom{N}{m} \mu^m (1 - \mu)^{N-m}$$

其中 $\binom{N}{m} = \frac{N!}{m!(N-m)!}$ 是组合数。

- **数字特征**:
 - 均值: $\mathbb{E}[m] = N\mu$
 - 方差: $\text{Var}[m] = N\mu(1 - \mu)$
- **联系**: 当 $N = 1$ 时, 退化为伯努利分布。

多项分布 (Multinomial Distribution)

- **定义**: 二项分布向多类别的推广。描述 N 次独立试验中, K 个互斥类别各自出现次数 $m_1, \dots, m_K$ 的联合分布。
- **变量**: $\mathbf{m} = (m_1, \dots, m_K)^T$, 满足 $\sum m_k = N$ 。
- **参数**: $\boldsymbol{\mu} = (\mu_1, \dots, \mu_K)^T$, 其中 $\sum \mu_k = 1$ 。
- **概率质量函数**:

$$\text{Mult}(\mathbf{m}|N, \boldsymbol{\mu}) = \frac{N!}{m_1! m_2! \dots m_K!} \prod_{k=1}^K \mu_k^{m_k}$$

- **1-of-K 编码**: 若只观察一次试验 ($N = 1$), 则变量为向量 $\mathbf{x}$, 其中仅有一个分量 $x_k = 1$, 其余为 0。此时 $p(\mathbf{x}|\boldsymbol{\mu}) = \prod_{k=1}^K \mu_k^{x_k}$ 。
- **应用**: 多分类问题的标签分布, 词袋模型 (Bag of Words)。

多元高斯分布 (Multivariate Gaussian Distribution)

- **定义**: 连续变量中最重要、最常用的分布, 由均值向量和协方差矩阵完全确定。
- **变量**: $\mathbf{x} \in \mathbb{R}^D$ 。
- **参数**:
 - 均值向量 $\boldsymbol{\mu} \in \mathbb{R}^D$ 。
 - 协方差矩阵 $\boldsymbol{\Sigma} \in \mathbb{R}^{D \times D}$ (对称正定)。
- **概率密度函数 (PDF)**:

$$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{D/2}|\boldsymbol{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)$$

- **性质**:
 - 等高线是椭圆 (由 $\boldsymbol{\Sigma}$ 的特征向量决定方向)。
 - 中心极限定理的基础。

马氏距离 (Mahalanobis Distance)

- **定义**: 考虑了数据相关性 (协方差) 的距离度量, 表示点 $\mathbf{x}$ 到分布中心 μ 的“标准差” 倍数。

- **公式**:

$$\Delta^2 = (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu)$$

- **几何意义**:

- 如果 $\Sigma = \mathbf{I}$ (单位矩阵), 退化为欧几里得距离。
- 如果特征间存在相关性或量纲不同, 马氏距离会自动进行“白化” (Whitening) 变换, 消除相关性和尺度影响。
- **在高斯分布中的作用**: 高斯 PDF 中的指数部分正是 $-\frac{1}{2}\Delta^2$ 。常数马氏距离的轨迹构成了高斯分布的椭球等高面。

高斯分布的矩 (Moments of the Gaussian Distribution)

- 一阶矩 (均值):

$$\mathbb{E}[\mathbf{x}] = \boldsymbol{\mu}$$

- 二阶中心矩 (协方差):

$$\mathbb{E}[(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T] = \boldsymbol{\Sigma}$$

- 高阶矩:

- 所有奇数阶中心矩为 0 (由于对称性)。
- 偶数阶矩可以通过 $\boldsymbol{\Sigma}$ 的组合表示 (Isserlis' theorem / Wick's probability theorem)。
- 例如: $\mathbb{E}[x_i x_j x_k x_l]$ 可以分解为协方差项的乘积之和。
- **重要性:** 高斯分布完全由其一阶和二阶矩决定, 高阶矩不提供额外信息。这在许多近似推断方法 (如卡尔曼滤波、变分推断) 中非常关键。

多元高斯的条件分布 (Conditional Distribution)

- **设定**: 将 $\mathbf{x}$ 划分为 $\mathbf{x}_a$ 和 $\mathbf{x}_b$ 。

$$\mathbf{x} = \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b \end{pmatrix}, \quad \boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_a \\ \boldsymbol{\mu}_b \end{pmatrix}, \quad \boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_{aa} & \boldsymbol{\Sigma}_{ab} \\ \boldsymbol{\Sigma}_{ba} & \boldsymbol{\Sigma}_{bb} \end{pmatrix}$$

- **性质**: 给定 $\mathbf{x}_b$, $\mathbf{x}_a$ 的条件分布仍然是高斯分布 $p(\mathbf{x}_a|\mathbf{x}_b) = \mathcal{N}(\mathbf{x}_a|\boldsymbol{\mu}_{a|b}, \boldsymbol{\Sigma}_{a|b})$ 。

- **条件均值**:

$$\boldsymbol{\mu}_{a|b} = \boldsymbol{\mu}_a + \boldsymbol{\Sigma}_{ab}\boldsymbol{\Sigma}_{bb}^{-1}(\mathbf{x}_b - \boldsymbol{\mu}_b)$$

(这是 $\mathbf{x}_b$ 的线性函数)

- **条件协方差**:

$$\boldsymbol{\Sigma}_{a|b} = \boldsymbol{\Sigma}_{aa} - \boldsymbol{\Sigma}_{ab}\boldsymbol{\Sigma}_{bb}^{-1}\boldsymbol{\Sigma}_{ba}$$

(与 $\mathbf{x}_b$ 的具体值无关, 仅取决于协方差结构)

- **应用**: 高斯过程回归、卡尔曼滤波、贝叶斯网络推断。

多元高斯的边缘分布 (Marginal Distribution)

- **设定:** 同上, 将 $\mathbf{x}$ 划分为 $\mathbf{x}_a$ 和 $\mathbf{x}_b$ 。
- **性质:** 对 $\mathbf{x}_b$ 积分 (边缘化) 后, $\mathbf{x}_a$ 的边缘分布仍然是高斯分布 $p(\mathbf{x}_a) = \mathcal{N}(\mathbf{x}_a | \boldsymbol{\mu}_a, \boldsymbol{\Sigma}_{aa})$ 。
- **结果:**
 - 边缘均值: 直接取对应部分的均值 $\boldsymbol{\mu}_a$ 。
 - 边缘协方差: 直接取对应部分的子矩阵 $\boldsymbol{\Sigma}_{aa}$ 。
- **对比条件分布:**
 - 边缘化非常简单 (直接切分矩阵)。
 - 条件分布需要矩阵求逆和舒尔补 (Schur Complement) 运算。
- **意义:** 高斯分布在边缘化操作下是封闭的, 这使得在处理潜变量模型时非常方便。

线性高斯模型 (Linear-Gaussian Model)

- **定义：** 涉及两个高斯分布的线性变换模型。
 - 先验： $p(\mathbf{x}) = \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_x, \boldsymbol{\Lambda}^{-1})$
 - 条件似然： $p(\mathbf{y}|\mathbf{x}) = \mathcal{N}(\mathbf{y}|\mathbf{Ax} + \mathbf{b}, \mathbf{L}^{-1})$
- **结论 1 (边缘分布)：** $p(\mathbf{y})$ 是高斯分布。
- **结论 2 (后验分布)：** $p(\mathbf{x}|\mathbf{y})$ 也是高斯分布。
- **解析解：**
 - 这种模型的边缘分布和后验分布的均值和协方差都有解析解（涉及矩阵求逆引理）。
- **应用：**
 - 因子分析 (Factor Analysis)。
 - 线性动态系统 (Linear Dynamical Systems)。
 - 卡尔曼滤波 (Kalman Filter) 的核心推导基础。

多元高斯的极大似然估计 (MLE for Mean & Covariance)

- **设定**: 给定独立同分布数据集 $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ 。
- **均值的 MLE**: 样本均值。

$$\boldsymbol{\mu}_{\text{ML}} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n$$

- **协方差的 MLE**: 样本协方差 (有偏估计)。

$$\boldsymbol{\Sigma}_{\text{ML}} = \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu}_{\text{ML}})(\mathbf{x}_n - \boldsymbol{\mu}_{\text{ML}})^T$$

- **偏差问题**: $\boldsymbol{\Sigma}_{\text{ML}}$ 低估了真实的协方差。无偏估计量为: $\tilde{\boldsymbol{\Sigma}} = \frac{1}{N-1} \sum(\dots)$ 。
- **深度学习视角**: 在批量归一化 (Batch Norm) 中, 我们计算 mini-batch 的均值和方差, 需注意训练时使用移动平均, 而测试时使用全局统计量或修正后的无偏估计。

高斯混合模型 (Mixture of Gaussians, GMM)

- **动机**: 单个高斯分布是单峰的, 无法拟合多峰复杂分布。
- **定义**: K 个高斯分布的线性叠加。

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

- **参数**:
 - π_k : 混合系数 (Mixing coefficients), 满足 $\sum \pi_k = 1, \pi_k \geq 0$ 。
 - $\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k$: 第 k 个分量的均值和协方差。
- **隐变量视角**: 引入离散隐变量 z 表示样本属于哪个分量, $p(z_k = 1) = \pi_k$ 。
- **求解**: 由于对数似然函数中包含求和的对数 $\ln \sum$, 没有解析解。通常使用 **EM 算法** (Expectation-Maximization) 进行迭代优化。
- **应用**: 聚类、密度估计、VAE 的先验近似。

冯·米塞斯分布 (Von Mises Distribution)

- **背景**: 定义在圆环 (周期性变量) 上的分布, 相当于线性空间中正态分布的循环版本。
- **变量**: 角度 $\theta \in [0, 2\pi)$ 。
- **参数**:
 - μ_0 : 平均方向。
 - κ : 集中参数, 类似精度的倒数。 $\kappa = 0$ 时为均匀分布, κ 越大越集中。
- **概率密度**:
$$p(\theta|\mu_0, \kappa) = \frac{1}{2\pi I_0(\kappa)} \exp(\kappa \cos(\theta - \mu_0))$$
其中 $I_0(\kappa)$ 是修正的零阶贝塞尔函数 (归一化常数)。
- **应用**:
 - 处理周期性数据 (如时间、风向、机器人关节角度)。
 - 在某些循环神经网络 (RNN) 或生成模型中用于建模角度输出。

指数族分布 (The Exponential Family)

- **定义**：一大类概率分布的统称，其 PDF/PMF 可写成如下形式：

$$p(\mathbf{x}|\boldsymbol{\eta}) = h(\mathbf{x})g(\boldsymbol{\eta}) \exp(\boldsymbol{\eta}^T \mathbf{u}(\mathbf{x}))$$

- **组件**：

- $\boldsymbol{\eta}$ ：自然参数 (Natural parameters)。
- $\mathbf{u}(\mathbf{x})$ ：充分统计量 (Sufficient statistics)。
- $h(\mathbf{x})$ ：基底测度。
- $g(\boldsymbol{\eta})$ ：归一化系数。

- **成员**：高斯、伯努利、二项、多项、泊松、Gamma、Beta 等。

- **重要性质**：

- 凸性：对数似然函数是关于 $\boldsymbol{\eta}$ 的凹函数，保证有唯一最大值。
- 充分统计量：数据的所有信息都压缩在 $\sum \mathbf{u}(\mathbf{x}_n)$ 中。
- 共轭先验：存在解析形式的共轭先验分布，便于贝叶斯推断。

非参数方法 (Nonparametric Methods)

- **概念辨析:**

- **并非** “没有参数”，而是参数的数量不固定，通常随数据量 N 的增长而增长。
- 不假设数据服从特定的参数化分布形式（如高斯）。

- **特点:**

- **灵活性:** 模型复杂度由数据决定，理论上可以逼近任意复杂的分布。
- **数据依赖:** 预测新数据时通常需要保留全部或部分训练数据。
- **计算成本:** 预测阶段计算量大 ($O(N)$ 或更高)，训练阶段快（通常只是存储数据）。

- **典型代表:**

- 直方图 (Histograms)。
- 核密度估计 (KDE)。
- K 近邻 (KNN)。
- 高斯过程 (Gaussian Processes)。

核密度估计 (Kernel Density Estimation, KDE)

- **思想**: 将每个数据点视为一个小的概率质量块 (核函数), 将所有核叠加得到整体密度。

- **公式**:

$$p(\mathbf{x}) = \frac{1}{N} \sum_{n=1}^N \frac{1}{h^D} k\left(\frac{\mathbf{x} - \mathbf{x}_n}{h}\right)$$

- **组件**:

- $k(\cdot)$: 核函数 (通常选高斯核), 满足非负且积分为 1。
- h : 带宽 (Bandwidth) 或平滑参数。

- **带宽 h 的作用**:

- h 太小: 过拟合, 密度函数呈现尖锐的峰值 (噪声大)。
- h 太大: 欠拟合, 密度函数过于平滑, 掩盖数据结构。

- **联系**: 可以看作是无限多个高斯分量的混合模型, 每个分量中心在数据点上, 权重相等。

K 近邻分类器 (Nearest-Neighbour Classifier)

- **原理**：一种基于实例的非参数分类/回归方法。
- **算法**：
 - ① 对于新输入 $\mathbf{x}$ ，在训练集中找到距离最近的 K 个点。
 - ② **分类**：通过多数投票决定类别 ($K = 1$ 时即为最近邻)。
 - ③ **回归**：取 K 个邻居目标值的平均值。
- **概率解释**：

$$p(C_k|\mathbf{x}) \approx \frac{N_k}{K}$$

其中 N_k 是 K 个邻居中属于类 C_k 的数量。

- **优缺点**：
 - **优**：简单，无需训练，决策边界灵活。
 - **缺**：预测慢（需计算所有距离），对高维数据失效（维数灾难），对噪声敏感（当 K 较小时）。

总结

- **基础分布**：伯努利、二项、多项分布构成了离散变量建模的基石；多元高斯分布则是连续变量建模的核心。
- **高斯性质**：马氏距离、条件/边缘分布的封闭性、线性高斯模型的可解性，使得高斯分布在推断中占据统治地位。
- **复杂建模**：高斯混合模型 (GMM) 通过叠加突破单峰限制；冯·米塞斯分布处理周期性数据。
- **理论框架**：指数族统一了大多数常用分布的性质。
- **非参数视角**：当先验假设不足时，KDE 和 KNN 等方法利用数据本身驱动模型，虽计算昂贵但极具灵活性。
- 这些概率工具是理解变分自编码器 (VAE)、扩散模型 (Diffusion Models) 和高斯过程等现代深度学习算法的前提。

习题 3.1 (★): 伯努利分布

伯努利分布的基本性质与熵

问题描述: 验证伯努利分布 $\text{Bern}(x|\mu) = \mu^x(1-\mu)^{1-x}$ 满足以下基本性质:

① **归一化:** $\sum_{x=0}^1 p(x|\mu) = 1$

② **期望:** $\mathbb{E}[x] = \mu$

③ **方差:** $\text{var}[x] = \mu(1-\mu)$

进阶任务: 证明服从该分布的随机二元变量 x 的熵 $H[x]$ 为:

$$H[x] = -\mu \ln \mu - (1-\mu) \ln(1-\mu)$$

提示: 熵的定义为 $H[x] = -\sum p(x) \ln p(x)$ 。注意当 $x=0$ 和 $x=1$ 时的具体取值。

习题 3.7 (☆☆☆): 高斯分布的 KL 散度

两个多元高斯分布间的 KL 散度

任务: 证明两个 D 维高斯分布 $q(\mathbf{x}) = \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_q, \boldsymbol{\Sigma}_q)$ 和 $p(\mathbf{x}) = \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_p, \boldsymbol{\Sigma}_p)$ 之间的 Kullback-Leibler 散度为:

$$\text{KL}(q||p) = \frac{1}{2} \left\{ \ln \frac{|\boldsymbol{\Sigma}_p|}{|\boldsymbol{\Sigma}_q|} - D + \text{Tr}(\boldsymbol{\Sigma}_p^{-1} \boldsymbol{\Sigma}_q) + (\boldsymbol{\mu}_p - \boldsymbol{\mu}_q)^T \boldsymbol{\Sigma}_p^{-1} (\boldsymbol{\mu}_p - \boldsymbol{\mu}_q) \right\}$$

关键点

利用高斯分布的对数形式 $\ln \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 展开计算期望。

习题 3.8 (★★): 最大熵原理

给定均值和协方差下的最大熵分布

问题：我们要证明：在所有具有指定均值 μ 和协方差 Σ 的分布中，**高斯分布**具有最大的熵。即最大化熵泛函：

$$H[\mathbf{x}] = - \int p(\mathbf{x}) \ln p(\mathbf{x}) d\mathbf{x}$$

约束条件： 1. 归一化； 2. 均值固定； 3. 协方差固定：

$$\int p(\mathbf{x}) d\mathbf{x} = 1; \quad \int p(\mathbf{x}) \mathbf{x} d\mathbf{x} = \mu; \quad \int p(\mathbf{x}) (\mathbf{x} - \mu)(\mathbf{x} - \mu)^T d\mathbf{x} = \Sigma.$$

任务：使用**拉格朗日乘子法**对上述带约束问题进行变分最大化，证明最优解 $p(\mathbf{x})$ 即为高斯分布 $\mathcal{N}(\mathbf{x}|\mu, \Sigma)$ 。

习题 3.9 (☆☆☆): 高斯分布的熵

多元高斯分布熵的计算

任务:

证明 D 维多元高斯分布 $\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 的熵由下式给出:

$$H[\mathbf{x}] = \frac{1}{2} \ln |\boldsymbol{\Sigma}| + \frac{D}{2} (1 + \ln(2\pi))$$

推导思路

- ① 写出高斯分布的概率密度函数 $p(\mathbf{x})$ 。
- ② 代入熵的定义 $H = -\mathbb{E}[\ln p(\mathbf{x})]$ 。
- ③ 利用二次型 $\mathbb{E}[(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})] = \text{Tr}(\boldsymbol{\Sigma}^{-1} \boldsymbol{\Sigma}) = D$ 的性质简化计算。

习题 3.20 (★★): 伍德伯里矩阵求逆公式

验证伍德伯里恒等式 (Woodbury Identity)

问题描述: 线性代数中著名的**伍德伯里矩阵求逆公式**形式如下:

$$(\mathbf{A} + \mathbf{BCD})^{-1} = \mathbf{A}^{-1} - \mathbf{A}^{-1}\mathbf{B}(\mathbf{C}^{-1} + \mathbf{DA}^{-1}\mathbf{B})^{-1}\mathbf{DA}^{-1}$$

任务: 通过将等式**右边**乘以 $(\mathbf{A} + \mathbf{BCD})$, 证明结果为单位矩阵 $\mathbf{I}$, 从而验证该公式的正确性。

应用背景

该公式在机器学习中常用于高效更新协方差矩阵的逆 (例如在卡尔曼滤波或高斯过程回归中), 特别是当 $\mathbf{C}$ 的维度远小于 $\mathbf{A}$ 时。

习题 3.25 (★★): 独立高斯变量的和 I

利用线性 - 高斯模型推导和的分布

问题设定:

- 随机向量 $\mathbf{x}$ 和 $\mathbf{z}$ **相互独立**。
- 分布分别为: $\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}_{\mathbf{x}}, \boldsymbol{\Sigma}_{\mathbf{x}})$, $\mathbf{z} \sim \mathcal{N}(\boldsymbol{\mu}_{\mathbf{z}}, \boldsymbol{\Sigma}_{\mathbf{z}})$ 。
- 定义新变量: $\mathbf{y} = \mathbf{x} + \mathbf{z}$ 。

任务: 不直接使用卷积公式, 而是通过构建**线性 - 高斯模型**来推导 $p(\mathbf{y})$ 。

- ① **构建条件分布:** 将 $\mathbf{y}$ 视为给定 $\mathbf{x}$ 的线性变换加噪声。写出 $p(\mathbf{y}|\mathbf{x})$ 的形式, 并识别出线性高斯模型的标准参数:

$$\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b} + \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma}_{\boldsymbol{\epsilon}})$$

习题 3.25 (★★): 独立高斯变量的和 II

利用线性 - 高斯模型推导和的分布

② **应用通用性质**: 利用线性高斯系统的边缘分布性质:

$$\begin{aligned}\mathbb{E}[\mathbf{y}] &= \mathbf{A}\boldsymbol{\mu}_x + \mathbf{b} \\ \text{cov}[\mathbf{y}] &= \Sigma_\epsilon + \mathbf{A}\Sigma_x\mathbf{A}^T\end{aligned}$$

③ **得出结论**: 证明 $\mathbf{y}$ 的边缘分布为:

$$p(\mathbf{y}) = \mathcal{N}(\mathbf{y} \mid \boldsymbol{\mu}_x + \boldsymbol{\mu}_z, \Sigma_x + \Sigma_z)$$

关键提示

在此模型中, $\mathbf{z}$ 充当了加法噪声的角色。请确定 $\mathbf{A}$, $\mathbf{b}$ 和噪声协方差 Σ_ϵ 分别对应题目中的哪些量。

习题 3.31 (★★): 冯·米塞斯分布的高斯极限

冯·米塞斯分布在大浓度参数下的近似

背景: 冯·米塞斯分布 (Von Mises distribution) 定义为:

$$p(\theta|\theta_0, m) = \frac{1}{2\pi I_0(m)} \exp\{m \cos(\theta - \theta_0)\}$$

当浓度参数 m 很大时, 分布集中在众数 θ_0 附近。

- 任务:**
1. 定义变换变量 $\xi = m^{1/2}(\theta - \theta_0)$ 。
 2. 对余弦项进行泰勒展开: $\cos \alpha \approx 1 - \frac{\alpha^2}{2}$ 。
 3. 证明当 $m \rightarrow \infty$ 时, 该分布趋向于一个**高斯分布**。

提示: 注意雅可比行列式的变化以及归一化常数 $I_0(m)$ 在大 m 时的渐近行为。

习题 3.36 (★): 指数族的二阶性质

指数族分布中 $\ln g(\eta)$ 的二阶导数

已知结果: 对于指数族分布, $\ln g(\eta)$ 的一阶梯度与充分统计量的期望有关:

$$-\nabla \ln g(\eta) = \mathbb{E}[\mathbf{u}(\mathbf{x})]$$

任务: 从归一化条件出发: $g(\eta) \int h(\mathbf{x}) \exp\{\eta^T \mathbf{u}(\mathbf{x})\} d\mathbf{x} = 1$

对其取关于 η 的**二阶导数**, 证明: $-\nabla \nabla \ln g(\eta) = \underbrace{\mathbb{E}[\mathbf{u}\mathbf{u}^T] - \mathbb{E}[\mathbf{u}]\mathbb{E}[\mathbf{u}]^T}_{\text{cov}[\mathbf{u}(\mathbf{x})]}$

意义

这表明 $\ln g(\eta)$ 的负海森矩阵 (Hessian) 等于充分统计量的协方差矩阵, 且协方差矩阵必须是半正定的, 这意味着 $\ln g(\eta)$ 是凸函数。

习题 3.37 (★★): 直方图密度模型的 MLE

直方图模型的最大似然估计

模型设定:

- 空间被划分为固定区域 i 。区域 i 的体积为 Δ_i 。密度在区域 i 内为常数 h_i 。
- 观测数据: 共 N 个点, 其中 n_i 个落在区域 i 。

任务:

1. 写出该模型的对数似然函数。
2. 使用**拉格朗日乘子法**强制执行归一化约束 $\sum_i h_i \Delta_i = 1$ 。
3. 推导出 $\{h_i\}$ 的最大似然估计量表达式。

预期结果

估计值应与落入该区域的频率成正比, 与区域体积成反比。

习题 3.38 (★): K 近邻模型的非正常性

K 近邻密度模型的积分发散性

问题描述: K 近邻 (K-Nearest Neighbors, KNN) 密度估计模型定义为:

$$p(\mathbf{x}) = \frac{K}{NV(\mathbf{x})}$$

其中 $V(\mathbf{x})$ 是以 $\mathbf{x}$ 为中心、恰好包含 K 个训练数据点的超球体体积。

任务: 证明该模型定义了一个**非正常分布** (Improper Distribution), 即其在整个空间上的积分是发散的:

$$\int p(\mathbf{x}) d\mathbf{x} = \infty$$

直观理解

考虑远离所有数据点的区域, $V(\mathbf{x})$ 会变得非常大但增长缓慢, 导致尾部衰减不足以使积分收敛。