

线性回归与相关核心概念

从基函数到偏差 - 方差权衡

《深度学习基础》课程小组

2026 年 2 月 25 日

目录

线性回归 (Linear Regression)

定义

一种监督学习算法，假设目标变量 t 与输入变量 $\mathbf{x}$ 之间存在线性关系。

$$y(\mathbf{x}, \mathbf{w}) = w_0 + \sum_{i=1}^D w_i x_i = \mathbf{w}^T \tilde{\mathbf{x}}$$

其中 $\tilde{\mathbf{x}}$ 是增广向量 $(1, x_1, \dots, x_D)^T$ 。

- **目标:** 找到参数 $\mathbf{w}$ ，使得预测值 y 尽可能接近真实值 t 。
- **线性含义:** 对参数 $\mathbf{w}$ 是线性的（而非必须对输入 $\mathbf{x}$ 线性，可通过基函数扩展）。
- 是最基础且广泛使用的回归模型。

基函数 (Basis Functions)

定义

一组固定的非线性函数 $\phi_j(\mathbf{x})$ ，用于将原始输入空间映射到新的高维特征空间，从而允许线性模型拟合非线性关系。

$$y(\mathbf{x}, \mathbf{w}) = w_0 + \sum_{j=1}^M w_j \phi_j(\mathbf{x})$$

- **常见类型:**

- 多项式基: $\phi_j(x) = x^j$
- 高斯基: $\phi_j(x) = \exp(-\frac{(x-\mu_j)^2}{2s^2})$
- Sigmoid 基: $\phi_j(x) = \sigma(\frac{x-\mu_j}{s})$
- 模型对 $\mathbf{w}$ 仍然是线性的，因此求解方法不变。

特征提取 (Feature Extraction)

定义

通过变换原始数据，构建出一组新的、更具代表性或更紧凑的特征（即基函数的输出）的过程。

- **目的:**

- 降低维度 (Dimensionality Reduction)。
- 去除噪声和冗余信息。
- 使数据在新空间中线性可分或更适合回归。

- **方法:**

- 手动设计基函数 (Domain Knowledge)。
- 主成分分析 (PCA)。
- 自动学习特征 (如深度学习)。

- 在线性回归语境下，特征提取通常指计算 $\phi(\mathbf{x})$ 。

似然函数 (Likelihood Function)

定义

在给定参数 $\mathbf{w}$ 和输入 $\mathbf{X}$ 的情况下，观测到目标数据 $\mathbf{t}$ 的概率。

假设噪声服从高斯分布 $t = y(\mathbf{x}, \mathbf{w}) + \epsilon$, $\epsilon \sim \mathcal{N}(0, \beta^{-1})$:

$$p(\mathbf{t}|\mathbf{X}, \mathbf{w}, \beta) = \prod_{n=1}^N \mathcal{N}(t_n | \mathbf{w}^T \phi(\mathbf{x}_n), \beta^{-1})$$

- **最大似然估计 (MLE)**: 寻找 $\mathbf{w}$ 最大化该函数。
- 取对数后，最大化似然等价于**最小化平方和误差**。
- 提供了概率视角的回归推导基础。

摩尔 - 彭若斯伪逆 (Moore-Penrose Pseudo-inverse)

定义

对于非方阵或奇异矩阵 Φ ，其伪逆 $\Phi^\dagger$ 是逆矩阵概念的推广，用于求解线性方程组的最小二乘解。

$$\mathbf{w}_{ML} = \Phi^\dagger \mathbf{t}$$

其中 $\Phi^\dagger = (\Phi^T \Phi)^{-1} \Phi^T$ (当 $\Phi^T \Phi$ 可逆时)。

- **作用**: 即使样本数 N 不等于特征数 M ，或者特征间存在线性相关，也能给出一个解。
- 如果解不唯一，伪逆给出的是**范数最小**的解 ($\|\mathbf{w}\|_2$ 最小)。
- 数值计算中通常通过 SVD (奇异值分解) 实现，比直接求逆更稳定。

最小二乘的几何意义 (1/2)

向量空间视角


将问题看作在由基函数张成的列空间 $\mathcal{R}(\Phi)$ 中寻找一个向量，使其最接近目标向量 $\mathbf{t}$ 。

- 设计矩阵 Φ 的列向量张成一个子空间。
- 预测向量 $\mathbf{y} = \Phi\mathbf{w}$ 必须位于这个子空间内。
- 目标向量 $\mathbf{t}$ 通常位于该子空间之外。

核心结论

最小二乘解 $\mathbf{w}_{ML}$ 对应的预测值 $\hat{\mathbf{t}} = \Phi\mathbf{w}_{ML}$ 是 $\mathbf{t}$ 在 $\mathcal{R}(\Phi)$ 上的**正交投影**。

最小二乘的几何意义 (2/2)



- **残差向量** $\mathbf{e} = \mathbf{t} - \hat{\mathbf{t}}$ 垂直于子空间 $\mathcal{R}(\Phi)$ 。
- 数学表达: $\Phi^T(\mathbf{t} - \Phi\mathbf{w}) = 0$ (正规方程)。
- 最小化误差平方和 $\|\mathbf{e}\|^2$ 等价于寻找最短的垂直距离。

顺序学习 (Sequential Learning)

定义

数据逐个（或小批量）到达，模型参数随着新数据的到来实时更新，而无需重新遍历所有历史数据。

- **场景:** 在线广告、股票预测、传感器数据流。
- **优势:**
 - 内存效率高（不需要存储所有数据）。
 - 能快速适应数据分布的变化 (Concept Drift)。
- **典型算法:**
 - 随机梯度下降 (SGD)。
 - 递归最小二乘法 (RLS)。
 - 卡尔曼滤波。

随机梯度下降 (SGD)

定义

一种优化算法，每次迭代仅使用**一个**（或一小批）样本计算梯度来更新参数，而不是整个数据集。

$$\mathbf{w}^{(\tau+1)} = \mathbf{w}^{(\tau)} - \eta \nabla E_n(\mathbf{w}^{(\tau)})$$

其中 E_n 是第 n 个样本的误差。

- **优点:** 计算速度快，支持在线学习，能跳出局部极小值（由于噪声）。
- **缺点:** 收敛路径震荡，需要仔细调整学习率 η （通常需要衰减）。
- 是大规模机器学习和深度学习的基石。

正则化最小二乘 (Regularized Least Squares)

定义

在平方和误差函数基础上增加一个惩罚项，以限制参数的大小，防止过拟合。

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N (y(\mathbf{x}_n, \mathbf{w}) - t_n)^2 + \frac{\lambda}{2} \|\mathbf{w}\|^2$$

- λ : 正则化系数，控制惩罚力度。
- **解析解**: $\mathbf{w}_{reg} = (\Phi^T \Phi + \lambda \mathbf{I})^{-1} \Phi^T \mathbf{t}$ 。
- 加入 $\lambda \mathbf{I}$ 保证了矩阵 $(\Phi^T \Phi + \lambda \mathbf{I})$ 总是可逆的，解决了病态矩阵问题。
- 贝叶斯视角：等价于引入高斯先验的最大后验估计 (MAP)。

参数收缩方法 (Parameter Shrinkage)

定义

一类通过迫使模型参数向零（或某个先验值）“收缩”来降低模型复杂度的技术。

- **L2 正则化 (Ridge Regression):**

- 惩罚项 $\lambda \sum w_i^2$ 。
- 使参数变小但通常不为零，平滑模型。

- **L1 正则化 (Lasso):**

- 惩罚项 $\lambda \sum |w_i|$ 。
- 具有**稀疏性**，能将部分参数精确压缩为 0，实现特征选择。

- **作用:** 权衡偏差与方差，提高泛化能力。

决策理论 (Decision Theory)

定义

在不确定性下做出最优决策的数学框架。在机器学习中，用于将概率预测转化为具体的类别或数值决策。

- **核心要素:**

- ① 损失函数 (Loss Function) $L(t, y)$: 衡量预测 y 与真实 t 的差异代价。
- ② 期望损失 (Expected Loss): $R = \mathbb{E}[L(t, y)]$ 。

- **最优决策:** 选择使期望损失最小的 y 。

- **回归例子:** 若 $L = (t - y)^2$, 最优解是条件期望 $y = \mathbb{E}[t|x]$; 若 $L = |t - y|$, 最优解是中位数。

预测分布 (Predictive Distribution)

定义

不仅给出一个点预测值，而是给出新输入 $\mathbf{x}$ 对应目标 t 的完整概率分布 $p(t|\mathbf{x}, D)$ ，包含了预测的不确定性。

$$p(t|\mathbf{x}, D) = \int p(t|\mathbf{x}, \mathbf{w})p(\mathbf{w}|D)d\mathbf{w}$$

● 组成:

- **数据噪声:** $p(t|\mathbf{x}, \mathbf{w})$ 固有的方差。
- **参数不确定性:** 由 $p(\mathbf{w}|D)$ 引起，数据越少，这部分越大。
- 贝叶斯线性回归可以直接计算出解析的高斯预测分布。
- 对于风险敏感的应用（如医疗、自动驾驶）至关重要。

偏差 - 方差权衡 (1/2): 定义

核心概念

模型泛化误差可以分解为三个部分：偏差、方差和不可约误差。

$$\text{Error} = \underbrace{(\mathbb{E}[\hat{f}(x)] - f(x))^2}_{\text{Bias}^2} + \underbrace{\mathbb{E}[(\hat{f}(x) - \mathbb{E}[\hat{f}(x)])^2]}_{\text{Variance}} + \underbrace{\sigma^2}_{\text{Noise}}$$

- **偏差 (Bias):** 模型本身的假设与真实函数的差距。高偏差导致**欠拟合**。
- **方差 (Variance):** 模型对训练数据微小变化的敏感程度。高方差导致**过拟合**。
- **权衡:** 降低偏差通常会增加方差，反之亦然。目标是找到总误差最小的平衡点。

偏差 - 方差权衡 (2/2): 直观理解

- **简单模型** (如线性):
 - 高偏差, 低方差。
 - 无论数据怎么变, 模型都太简单, 无法捕捉规律。
- **复杂模型** (如高阶多项式):
 - 低偏差, 高方差。
 - 完美拟合当前数据, 但数据一变, 模型剧烈波动。

解决方法

- 增加数据量 (降低方差)。
- 正则化 (增加一点偏差以大幅降低方差)。
- 集成学习 (Bagging 降低方差, Boosting 降低偏差)。
- 选择合适的模型复杂度。