

第四章：单层神经网络 - 回归模型术语解析与习题

从最小二乘法到贝叶斯推断


《深度学习基础》课程小组

2026 年 3 月 2 日

目录

- 1 单层网络-回归模型的知识图谱
- 2 模型构建与基础
- 3 参数求解与几何解释
- 4 正则化与模型选择
- 5 决策理论与贝叶斯视角
- 6 五个习题

单层网络-回归模型的知识图谱



线性回归 (Linear Regression)

- **定义：**一种基本的统计学习方法，用于建模输入变量 $\mathbf{x}$ 与连续目标变量 t 之间的线性关系。
- **模型形式：**

$$y(\mathbf{x}, \mathbf{w}) = w_0 + \sum_{i=1}^D w_i x_i = \mathbf{w}^T \tilde{\mathbf{x}}$$

其中 $\tilde{\mathbf{x}}$ 是增广输入向量（包含 $x_0 = 1$ ）。

- **在神经网络中的位置：**
 - 单层网络的最基本形式。
 - 如果没有激活函数（或激活函数为恒等函数），输出层即为线性回归。
- **目标：**找到权重 $\mathbf{w}$ ，使得预测值 $y(\mathbf{x}, \mathbf{w})$ 尽可能接近真实值 t 。

基函数 (Basis Functions)

- **动机**：标准线性回归只能拟合线性关系。为了拟合非线性数据，我们将输入 $\mathbf{x}$ 通过一组非线性函数变换。
- **广义线性回归模型**：

$$y(\mathbf{x}, \mathbf{w}) = w_0 + \sum_{j=1}^M w_j \phi_j(\mathbf{x}) = \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x})$$

其中 $\boldsymbol{\phi}(\mathbf{x}) = [\phi_1(\mathbf{x}), \dots, \phi_M(\mathbf{x})]^T$ 是基函数向量。

- **关键点**：
 - 模型关于参数 $\mathbf{w}$ 仍然是**线性的**（这是“线性回归”名称的由来）。
 - 关于输入 $\mathbf{x}$ 可以是非线性的。
- **常见基函数**：多项式基、高斯基、Sigmoid 基。

特征提取 (Feature Extraction)

- **定义**：将原始输入数据 x 转换为新的表示形式 $\phi(x)$ 的过程。
- **与基函数的关系**：
 - 基函数 $\phi_j(x)$ 的输出即为提取出的新**特征**。
 - 这一层通常被称为神经网络的“隐藏层”或“特征层”。
- **目的**：
 - 将数据映射到一个更高维或更具判别力的空间，使得在该空间中数据呈现线性可分或线性可回归的特性。
 - 例如：将一维 x 映射为 (x, x^2, x^3) ，从而可以用平面拟合曲线。
- **现代视角**：在深度学习中，特征提取通常是自动学习的（通过反向传播），而在传统单层网络中，基函数往往是预先固定的。

似然函数 (Likelihood Function)

- **概率视角**: 假设目标值 t 由确定性函数 $y(\mathbf{x}, \mathbf{w})$ 加上高斯噪声 ϵ 生成:

$$t = y(\mathbf{x}, \mathbf{w}) + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \beta^{-1})$$

- **条件分布**:

$$p(t|\mathbf{x}, \mathbf{w}, \beta) = \mathcal{N}(t|y(\mathbf{x}, \mathbf{w}), \beta^{-1})$$

- **似然函数**: 给定数据集 $D = \{(\mathbf{x}_n, t_n)\}_{n=1}^N$, 参数的似然函数为所有数据点概率的乘积:

$$L(\mathbf{w}, \beta) = \prod_{n=1}^N \mathcal{N}(t_n|\mathbf{w}^T \phi(\mathbf{x}_n), \beta^{-1})$$

- **作用**: 最大化似然函数 (MLE) 等价于最小化平方和误差函数。

Moore–Penrose 伪逆 (Moore–Penrose Pseudo-inverse)

- **背景：**线性回归的最小二乘解需要求解正规方程 (Normal Equation)：

$$(\Phi^T \Phi) \mathbf{w} = \Phi^T \mathbf{t}$$

其中 Φ 是设计矩阵 (Design Matrix)。

- **问题：**当 $\Phi^T \Phi$ 不可逆时 (例如特征数多于样本数, 或特征间存在多重共线性), 无法直接求逆。
- **解决方案：**使用 Moore–Penrose 伪逆 $\Phi^\dagger = (\Phi^T \Phi)^{-1} \Phi^T$ 。
- **解析解：**

$$\mathbf{w}_{\text{ML}} = \Phi^\dagger \mathbf{t}$$

- **性质：**即使矩阵不是方阵或奇异, 伪逆也能给出一个最小范数的最小二乘解。

最小二乘法的几何解释 (Geometry of Least Squares)

- **向量空间:**

- 目标向量 $\mathbf{t}$ 位于 N 维空间中。
- 设计矩阵 Φ 的列向量张成一个子空间 S 。

- **投影:**

- 最小二乘法的目标是找到 S 中的一个向量 $\mathbf{y} = \Phi\mathbf{w}$, 使其与 $\mathbf{t}$ 的距离 (欧几里得距离) 最小。
- 这个最优的 $\mathbf{y}$ 正是 $\mathbf{t}$ 在子空间 S 上的**正交投影**。

- **残差:** 误差向量 $\mathbf{e} = \mathbf{t} - \Phi\mathbf{w}$ 垂直于子空间 S (即垂直于 Φ 的所有列)。



- 数学表达: $\Phi^T(\mathbf{t} - \Phi\mathbf{w}) = \mathbf{0}$, 这正是正规方程。

顺序学习 (Sequential Learning)

- **定义：**也称为在线学习 (Online Learning)。模型数据点逐个（或小批量）到达，每收到一个新数据就更新一次参数，而不是等待所有数据收集完毕（批处理）。
- **优势：**
 - 适用于数据流场景或内存受限的情况。
 - 能够适应数据分布随时间变化的情况（概念漂移）。
- **算法示例：**
 - 递归最小二乘法 (RLS)。
 - 随机梯度下降 (SGD)。
- **更新规则：** $\mathbf{w}_{\text{new}} = \mathbf{w}_{\text{old}} - \eta \nabla E_n(\mathbf{w}_{\text{old}})$ ，其中 E_n 是当前单个样本的误差。

随机梯度下降 (Stochastic Gradient Descent, SGD)

- **对比:**

- **批梯度下降:** 每次更新遍历所有 N 个样本计算总梯度。计算量大, 收敛稳但慢。
- **SGD:** 每次更新仅基于一个随机选取的样本 $(\mathbf{x}_n, t_n)$ 。

- **更新公式:**

$$\mathbf{w}^{(\tau+1)} = \mathbf{w}^{(\tau)} - \eta \nabla E_n(\mathbf{w}^{(\tau)})$$

其中 $E_n(\mathbf{w}) = \frac{1}{2}(y(\mathbf{x}_n, \mathbf{w}) - t_n)^2$.

- **特点:**

- 计算速度快, 可立即响应新数据。
- 路径具有随机性 (在极小值附近震荡), 需要逐渐减小学习率 η 以保证收敛。

正则化最小二乘法 (Regularized Least Squares)

- **问题：**普通最小二乘法容易过拟合 (Overfitting)，特别是当基函数过多或数据噪声大时，权重 $\mathbf{w}$ 会变得非常大。
- **方法：**在误差函数中加入惩罚项 (正则化项)。

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N (y(\mathbf{x}_n, \mathbf{w}) - t_n)^2 + \frac{\lambda}{2} \|\mathbf{w}\|^2$$

- L_2 **正则化：**上述公式称为岭回归 (Ridge Regression)。
- **效果：**
 - 限制权重的大小，使模型更平滑。
 - λ 控制惩罚力度： λ 越大，权重越趋近于 0。
- **解析解：** $\mathbf{w} = (\Phi^T \Phi + \lambda \mathbf{I})^{-1} \Phi^T \mathbf{t}$ 。加入 $\lambda \mathbf{I}$ 保证了矩阵可逆。

参数收缩法 (Parameter Shrinkage Method)

- **定义**：正则化技术的一种统称，因为其效果是将参数估计值向零（或某个先验均值）“收缩” (Shrink)。
- **常见类型**：
 - **Ridge Regression (L_2)**： $\lambda \sum w_i^2$ 。使权重变小但不为零，适合处理多重共线性。
 - **Lasso (L_1)**： $\lambda \sum |w_i|$ 。倾向于产生稀疏解（部分权重精确为 0），具有特征选择功能。
- **贝叶斯解释**：
 - L_2 正则化等价于假设权重服从高斯先验 $p(\mathbf{w}) = \mathcal{N}(\mathbf{0}, \alpha^{-1}\mathbf{I})$ 时的最大后验估计 (MAP)。
 - L_1 正则化等价于假设权重服从拉普拉斯先验。

偏差 - 方差权衡 (The Bias-Variance Trade-off)

- **期望预测误差分解**: 对于新的输入 $\mathbf{x}$, 期望平方误差可以分解为三部分:

$$\mathbb{E}[(t - y(\mathbf{x}))^2] = (\text{Bias})^2 + \text{Variance} + \text{Noise}$$

- **偏差 (Bias)**:

- 模型预测的平均值与真实值之间的差异。
- 高偏差意味着模型太简单 (欠拟合), 无法捕捉数据的内在规律。

- **方差 (Variance)**:

- 模型预测值在不同训练集上的波动程度。
- 高方差意味着模型太复杂 (过拟合), 过度记住了训练数据的噪声。

- **权衡**:

- 增加模型复杂度 $\rightarrow$ 偏差降低, 方差升高。
- 减少模型复杂度 (或增加正则化) $\rightarrow$ 偏差升高, 方差降低。
- 目标是找到总误差最小的平衡点。

决策理论 (Decision Theory)

- **核心思想**: 在回归问题中, 我们需要根据输入 $\mathbf{x}$ 做出一个预测 $y(\mathbf{x})$, 以最小化预期的损失。
- **损失函数**: 常用平方损失 $L(t, y) = (y - t)^2$ 。
- **期望损失最小化**: $\min_{y(\mathbf{x})} \mathbb{E}[L] = \min_{y(\mathbf{x})} \iint (y(\mathbf{x}) - t)^2 p(\mathbf{x}, t) dt d\mathbf{x}$
- **结论**: 对于平方损失, 最优预测 $y^*(\mathbf{x})$ 是目标变量的**条件期望**:

$$y^*(\mathbf{x}) = \mathbb{E}_t[t|\mathbf{x}] = \int t p(t|\mathbf{x}) dt$$

这就是为什么我们在回归中通常试图逼近条件均值。

- **其他损失**: 若使用绝对值损失 $|y - t|$, 最优解为条件中位数; 若使用 0-1 损失 (离散化), 最优解为条件众数。

预测分布 (Predictive Distribution)

- **超越点估计**: 传统的回归只给出一个预测值 $y(\mathbf{x})$ 。贝叶斯方法则给出一个完整的概率分布 $p(t|\mathbf{x}, D)$, 反映了预测的不确定性。
- **构成**:

$$p(t|\mathbf{x}, D) = \int p(t|\mathbf{x}, \mathbf{w})p(\mathbf{w}|D) d\mathbf{w}$$

- $p(t|\mathbf{x}, \mathbf{w})$: 给定参数的噪声模型 (通常是高斯)。
- $p(\mathbf{w}|D)$: 参数的后验分布 (反映了我们对权重的不确定度)。
- **结果**:
 - 预测分布通常也是一个高斯分布。
 - 其方差包含两部分: 数据本身的噪声方差 + 参数不确定性带来的方差。
 - 在训练数据稀缺的区域, 预测分布的方差会变大 (模型表示 “我不确定”)。

平方和误差函数 (Sum-of-Squares Error Function)

- **定义**：衡量模型预测值与真实值之间差异的最常用指标。

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N (y(\mathbf{x}_n, \mathbf{w}) - t_n)^2$$

- **系数 1/2**：为了方便求导后消去平方项的系数 2，不影响优化结果。
- **与似然的关系**：
 - 在高斯噪声假设下，最大化对数似然函数 $\ln L$ 等价于最小化 $E(\mathbf{w})$ 。
 - 这建立了概率模型与经典最小二乘法之间的桥梁。
- **局限性**：对异常值 (Outliers) 敏感，因为误差被平方放大了。

设计矩阵 (Design Matrix)

- **定义：** 将数据集中的所有输入经过基函数变换后排列成的矩阵。

$$\Phi = \begin{pmatrix} \phi_0(\mathbf{x}_1) & \phi_1(\mathbf{x}_1) & \cdots & \phi_M(\mathbf{x}_1) \\ \phi_0(\mathbf{x}_2) & \phi_1(\mathbf{x}_2) & \cdots & \phi_M(\mathbf{x}_2) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_0(\mathbf{x}_N) & \phi_1(\mathbf{x}_N) & \cdots & \phi_M(\mathbf{x}_N) \end{pmatrix}$$

- **维度：** $N \times M$ (N 个样本, M 个基函数/特征)。
- **作用：**
 - 将非线性的基函数变换转化为线性的矩阵运算。
 - 模型预测向量可简洁地写为 $\mathbf{y} = \Phi \mathbf{w}$ 。
 - 是推导正规方程和几何解释的核心对象。

- **建模**：通过**基函数**和**特征提取**，单层网络可以处理非线性回归问题。
- **求解**：**最小二乘法**及其几何解释提供了闭式解，而 **SGD** 和**顺序学习**适应了大规模数据。
- **泛化**：**正则化**和**参数收缩**是防止过拟合、平衡**偏差与方差**的关键手段。
- **理论基石**：**决策理论**证明了最小二乘对应于条件期望，而**预测分布**则提供了更丰富的不确定性信息。
- 这些概念共同构成了现代机器学习和深度学习回归任务的理论基础。

习题 4.1 (★): 多项式回归的正规方程

平方和误差函数的最小化

考虑由下式给出的平方和误差函数: $E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N [y(x_n, \mathbf{w}) - t_n]^2$

其中模型 $y(x, \mathbf{w})$ 为 M 阶多项式: $y(x, \mathbf{w}) = w_0 + w_1x + w_2x^2 + \cdots + w_Mx^M$

证明最小化该误差函数的系数 $\mathbf{w} = \{w_i\}$ 由以下线性方程组的解给出:

$$\sum_{j=0}^M A_{ij}w_j = T_i, \quad (i = 0, 1, \dots, M) \quad (1)$$

其中系数定义为: $A_{ij} = \sum_{n=1}^N (x_n)^{i+j}$, $T_i = \sum_{n=1}^N (x_n)^i t_n$.

提示: 对 $E(\mathbf{w})$ 关于 w_i 求偏导并令其为零。

习题 4.2 (★): 正则化回归

引入正则化项后的线性方程

现在考虑加入 L_2 正则化项的误差函数:

$$\tilde{E}(\mathbf{w}) = \underbrace{\frac{1}{2} \sum_{n=1}^N [y(x_n, \mathbf{w}) - t_n]^2}_{\text{数据项}} + \underbrace{\frac{\lambda}{2} \|\mathbf{w}\|^2}_{\text{正则化项}} \quad (2)$$

其中 $\|\mathbf{w}\|^2 = \mathbf{w}^T \mathbf{w} = \sum_{i=0}^M w_i^2$ 。

写出类似于习题 4.1 中的一组耦合线性方程, 这些方程由最小化 $\tilde{E}(\mathbf{w})$ 的系数 w_i 所满足。正则化参数 λ 如何改变矩阵 A_{ij} 的对角线元素?

习题 4.4 (☆☆☆): 几何解释与投影

最小二乘法的几何意义

第一部分：投影矩阵。证明矩阵

$$\mathbf{P} = \Phi(\Phi^T\Phi)^{-1}\Phi^T \quad (3)$$

是将任意向量 $\mathbf{v}$ 投影到由设计矩阵 Φ 的列张成的空间 $\mathcal{S}$ 上的投影算子。
(需验证 $\mathbf{P}^2 = \mathbf{P}$ 且 $\mathbf{P}^T = \mathbf{P}$)

第二部分：正交投影。利用上述结果证明，最小二乘解

$$\mathbf{w}_{ML} = (\Phi^T\Phi)^{-1}\Phi^T\mathbf{t} \quad (4)$$

对应的预测向量 $\mathbf{y} = \Phi\mathbf{w}_{ML}$ 恰好是目标向量 $\mathbf{t}$ 到流形 $\mathcal{S}$ 上的**正交投影**。

习题 4.8 (★): 多变量回归的期望损失

从单变量到多变量的条件期望

背景: 单变量平方损失的最小化解是条件期望 $\mathbb{E}[t|\mathbf{x}]$ 。

推广: 考虑由向量 $\mathbf{t}$ 描述的多个目标变量, 其期望损失为:

$$\mathbb{E}[L] = \iint \|\mathbf{f}(\mathbf{x}) - \mathbf{t}\|^2 p(\mathbf{x}, \mathbf{t}) \, d\mathbf{x} \, d\mathbf{t} \quad (5)$$

任务: 使用变分法 (或对 $\mathbf{f}(\mathbf{x})$ 直接求导), 证明使该期望损失最小化的函数 $\mathbf{f}(\mathbf{x})$ 由下式给出:

$$\mathbf{f}(\mathbf{x}) = \mathbb{E}_{\mathbf{t}}[\mathbf{t}|\mathbf{x}] \quad (6)$$

结论

即使在多输出情况下, 最小化均方误差的最优预测仍然是目标向量的**条件均值**。

习题 4.12 (★★): L_q 损失与鲁棒回归

不同 q 值下的最优解

考虑 L_q 损失函数下的期望损失:

$$\mathbb{E}[L_q] = \iint |f(\mathbf{x}) - t|^q p(\mathbf{x}, t) d\mathbf{x} dt \quad (7)$$

- ① 为了最小化 $\mathbb{E}[L_q]$, 写出 $y(\mathbf{x})$ 必须满足的一般条件。
- ② 当 $q = 1$ 时: 证明该解代表**条件中位数**。即 $y(\mathbf{x})$ 使得:

$$P(t < y(\mathbf{x})|\mathbf{x}) = P(t \geq y(\mathbf{x})|\mathbf{x}) = 0.5$$

- ③ 当 $q \rightarrow 0$ 时: 证明最小期望损失由**条件众数**给出。即 $y(\mathbf{x})$ 等于使条件概率密度 $p(t|\mathbf{x})$ 最大化的 t 值。

讨论: 这说明不同的损失函数对应着对目标分布不同统计特性的估计。