

第五章：单层神经网络 - 分类模型关键术语解析

《深度学习基础》课程小组

2026 年 5 月 4 日

目录

- 1 基础概念与决策理论
- 2 生成式与判别式模型
- 3 线性模型与激活函数
- 4 模型评估

判别函数 (Discriminant Function)

- **定义：**一个函数 $y(\mathbf{x})$ ，它将输入向量 $\mathbf{x}$ 映射到一个输出值，该值用于决定 $\mathbf{x}$ 所属的类别。
- **作用：**在分类问题中，我们不需要知道具体的概率分布，只需要知道哪个类别的得分最高。
- **形式：**
 - 对于二类分类：若 $y(\mathbf{x}) > 0$ 则属于 C_1 ，否则 C_2 。
 - 对于多类分类：选择 $y_k(\mathbf{x})$ 最大的类别 k 。

决策区域与决策边界 (Decision Regions & Boundaries)

决策区域 (Decision Regions):

- 输入空间中被分配给特定类别 C_k 的区域 $\mathcal{R}_k$ 。
- 所有 $\mathbf{x} \in \mathcal{R}_k$ 都被分类为 C_k 。

决策边界 (Decision Boundaries):

- 分隔不同决策区域的表面 (在二维中是线, 三维中是面)。
- 由方程 $y_i(\mathbf{x}) = y_j(\mathbf{x})$ 定义。
- 也称为 **决策面 (Decision Surfaces)**。

在线性模型中, 如果判别函数是线性的, 决策边界就是超平面。

损失函数与损失矩阵 (Loss Function & Matrix)

- **损失函数** $L(t, y)$: 衡量预测值 y 与真实目标 t 之间差异的函数。目标是期望损失最小化。
- **损失矩阵** L_{kj} :
 - 用于离散类别分类。
 - L_{kj} 表示将真实类别为 C_k 的样本错误分类为 C_j 所付出的代价。
 - 通常对角线元素 $L_{kk} = 0$ (正确分类无损失)。
- **期望风险**: $E[L] = \sum_k \sum_j L_{kj} \int_{\mathcal{R}_j} p(\mathbf{x}, C_k) d\mathbf{x}$ 。

拒绝选项 (Reject Option)

- **背景**: 在某些应用中, 错误分类的代价非常高 (如医疗诊断)。
- **机制**:
 - 引入一个 “拒绝” 类别。
 - 如果所有类别的最大后验概率 $p(C_k|\mathbf{x})$ 低于某个阈值 θ , 则 classifier 拒绝做出判断, 转由人类专家处理。
- **权衡**: 通过调整阈值 θ , 可以在 “覆盖率” (处理多少样本) 和 “准确率” 之间进行权衡。

推断阶段 (Inference Stage)

- **定义：** 模型训练完成后，使用新数据 $\mathbf{x}_{new}$ 进行预测的过程。
- **流程：**
 - ① 输入新的特征向量。
 - ② 计算判别函数值或后验概率。
 - ③ 根据决策规则（如最大概率或最小损失）输出类别标签。
- **注意：** 在生成式模型中，推断可能涉及计算复杂的积分；而在判别式模型中，通常直接计算函数值，速度较快。

生成式概率模型 (Generative Probabilistic Model)

- **核心思想**: 对联合概率分布 $p(\mathbf{x}, C_k)$ 进行建模。
- **分解**: $p(\mathbf{x}, C_k) = p(\mathbf{x}|C_k)p(C_k)$ 。
 - $p(C_k)$: 类先验概率。
 - $p(\mathbf{x}|C_k)$: 类条件概率密度 (似然)。
- **推断**: 利用贝叶斯定理计算后验概率:

$$p(C_k|\mathbf{x}) = \frac{p(\mathbf{x}|C_k)p(C_k)}{\sum_j p(\mathbf{x}|C_j)p(C_j)}$$

- **优点**: 可以检测异常值, 能处理缺失数据, 可生成新样本。

判别式概率模型 (Discriminative Probabilistic Model)

- **核心思想**: 直接对后验概率 $p(C_k|\mathbf{x})$ 进行建模, 或者学习一个直接将 $\mathbf{x}$ 映射到类别标签的函数。
- **特点**:
 - 不关心数据 $\mathbf{x}$ 是如何生成的 (不建模 $p(\mathbf{x})$)。
 - 专注于寻找类别之间的决策边界。
- **例子**: 逻辑回归 (Logistic Regression), 神经网络。
- **优点**: 通常在分类任务上表现更好, 计算更直接, 不需要对输入数据的分布做强烈假设。

生成式分类器 vs 判别式分类器

生成式分类器 (Generative Classifiers)

- 建模 $p(\mathbf{x}, \mathcal{C}_k)$ 。
- 需要更多数据来准确估计密度。
- 对异常值敏感 (如果密度估计不准)。
- 例: 朴素贝叶斯, 高斯判别分析。

判别式分类器 (Discriminative Classifiers)

- 建模 $p(\mathcal{C}_k|\mathbf{x})$ 或直接决策边界。
- 直接优化分类性能。
- 通常在大数据集上精度更高。
- 例: 逻辑回归, SVM, 感知机。

朴素贝叶斯 (Naive Bayes)

- **定义**：一种特殊的生成式模型。
- **核心假设**：给定类别 C_k ，输入特征的各个分量 x_i 之间是**条件独立**的。

$$p(\mathbf{x}|C_k) = \prod_{i=1}^D p(x_i|C_k)$$

- **优势**：
 - 极大地减少了参数数量（从指数级降为线性级）。
 - 训练速度快，对小数据集表现良好。
- **劣势**：独立性假设在现实中往往不成立，可能影响概率估计的准确性，但分类效果通常依然不错。

异常值与鲁棒性 (Outliers & Robustness)

- **异常值 (Outliers):** 与数据集中其他观测值显著不同的数据点。
- **影响:**
 - 在生成式模型中, 异常值会严重扭曲均值和协方差的估计, 从而移动决策边界。
 - 在基于平方误差损失的模型中, 异常值会被赋予极大的权重。
- **鲁棒性 (Robustness):** 模型对异常值不敏感的特性。
- **提高鲁棒性的方法:**
 - 使用重尾分布 (如 Student-t 分布) 代替高斯分布。
 - 使用对异常值不敏感的损失函数 (如绝对值损失)。
 - 数据预处理 (剔除或截断)。

异常检测 (Outlier Detection)

- **原理**: 利用生成式模型计算新数据点的概率密度 $p(\mathbf{x})$ 。

$$p(\mathbf{x}) = \sum_k p(\mathbf{x}|\mathcal{C}_k)p(\mathcal{C}_k)$$

- **判定**: 如果 $p(\mathbf{x})$ 低于某个阈值, 则认为该点是异常值 (即该点不太可能由已知的数据分布生成)。
- **应用**: 欺诈检测、故障诊断、数据清洗。
- **注意**: 判别式模型通常难以直接进行异常检测, 因为它们不建模 $p(\mathbf{x})$ 。

线性判别函数 (Linear Discriminant Function)

- **定义：** 输入变量 $\mathbf{x}$ 的线性函数。

$$y(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$$

- **几何意义：**
 - $\mathbf{w}$ 决定了决策边界的法线方向。
 - w_0 (偏置) 决定了决策边界距离原点的距离。
- **决策规则：** $y(\mathbf{x}) > 0 \implies C_1$, 否则 C_2 。
- **局限性：** 只能解决线性可分问题。

Logistic Sigmoid 函数

- **公式:**

$$\sigma(a) = \frac{1}{1 + e^{-a}}$$

- **性质:**

- 将实数域 $(-\infty, \infty)$ 映射到 $(0, 1)$ 区间。
- 单调递增, 关于点 $(0, 0.5)$ 中心对称。
- 导数简单: $\sigma'(a) = \sigma(a)(1 - \sigma(a))$ 。

- **用途:** 在二分类问题中, 将线性判别函数的输出转化为概率 $p(C_1|\mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x})$ 。

逻辑回归 (Logistic Regression)

- **本质**：一种广义线性模型，用于二分类问题的**判别式**模型。
- **模型形式**：

$$p(C_1|\mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x})$$

$$p(C_2|\mathbf{x}) = 1 - p(C_1|\mathbf{x})$$

- **参数估计**：
 - 不使用最小二乘法（因为假设不是高斯噪声）。
 - 使用**最大似然估计 (MLE)**。
 - 损失函数通常是交叉熵误差 (Cross-Entropy Error)。

迭代重加权最小二乘法 (IRLS)

- **背景**：逻辑回归的最大似然解没有解析解（闭式解），因为方程是非线性的。
- **方法**：一种数值优化算法。
 - 将最大化似然函数的问题转化为一系列加权最小二乘问题。
 - 每次迭代更新权重 w 和数据点的权重系数。
- **收敛性**：对于逻辑回归这种凸优化问题，IRLS 能保证收敛到全局最优解。
- **地位**：是求解广义线性模型（GLM）的标准算法之一。

Softmax 函数

- **定义**：Sigmoid 函数在多分类问题中的推广。
- **公式**：对于 K 个类别，

$$y_k = \frac{e^{a_k}}{\sum_{j=1}^K e^{a_j}}$$

其中 a_k 通常是线性判别函数的输出。

- **性质**：
 - 输出值在 $(0, 1)$ 之间。
 - 所有输出之和为 1 ($\sum y_k = 1$)。
- **用途**：将一组任意实数转化为概率分布，常用于多类逻辑回归和神经网络的输出层。

多类逻辑回归 (Multi-class Logistic Regression)

- **模型**: 结合线性判别函数和 Softmax 函数。

$$p(C_k|\mathbf{x}) = \frac{\exp(\mathbf{w}_k^T \mathbf{x})}{\sum_{j=1}^K \exp(\mathbf{w}_j^T \mathbf{x})}$$

- **参数**: 需要学习 K 组权重向量 $\{\mathbf{w}_1, \dots, \mathbf{w}_K\}$ 。
- **训练**: 同样使用最大似然估计, 通过梯度下降或 IRLS 求解。
- **决策**: 选择 $p(C_k|\mathbf{x})$ 最大的类别。

一对多分类器 (One-versus-the-Rest Classifier)

- **策略**：将多分类问题分解为多个二分类问题。
- **方法**：
 - 对于 K 个类别，训练 K 个独立的二分类器。
 - 第 k 个分类器区分“类别 k ”与“非类别 k ”（其余所有类）。
- **预测**：输入 x ，看哪个分类器的输出置信度最高。
- **缺点**：
 - 可能出现多个分类器都判定为正例或都为负例的情况（模糊区域）。
 - 类别不平衡问题（“Rest”部分通常远大于正例部分）。

Probit 回归与 Erf 函数

- **Probit 函数**: 标准正态分布的累积分布函数 (CDF)。

$$\Phi(a) = \int_{-\infty}^a \mathcal{N}(z|0, 1) dz$$

- **Erf 函数 (误差函数)**:

$$\text{erf}(a) = \frac{2}{\sqrt{\pi}} \int_0^a e^{-t^2} dt$$

两者关系密切: $\Phi(a) = \frac{1}{2}[1 + \text{erf}(a/\sqrt{2})]$ 。

- **Probit 回归**:
 - 类似于逻辑回归, 但使用 Probit 链接函数代替 Sigmoid。
 - 假设潜在变量服从高斯分布。
 - 在贝叶斯推断中有时比 Logit 模型更方便处理。

激活函数 (Activation Function)

- **定义：**神经元中引入非线性因素的函数。在单层网络分类中，它通常位于线性组合之后。
- **作用：**
 - 将线性输出映射到特定范围（如概率 $(0, 1)$ ）。
 - 引入非线性（虽然在单层线性分类器中，激活函数本身不增加模型的表达复杂度，但它改变了输出的解释方式，即从距离变为概率）。
- **常见类型：**
 - Sigmoid (逻辑回归)
 - Softmax (多分类)
 - ReLU (主要用于隐藏层，但在输出层不常用)
 - Probit

广义线性模型 (Generalized Linear Models, GLM)

- **概念**：线性回归的推广，允许响应变量具有非正态分布。
- **三个组成部分**：
 - ① **随机成分**：响应变量 Y 服从指数族分布（如伯努利、泊松、高斯）。
 - ② **系统成分**：线性预测子 $\eta = \mathbf{w}^T \mathbf{x}$ 。
 - ③ **链接函数 (Link Function)**：连接期望值 $E[Y]$ 和线性预测子的单调可微函数 $g(\cdot)$ ，使得 $g(E[Y]) = \eta$ 。
- **例子**：
 - 线性回归 (恒等链接 + 高斯分布)
 - 逻辑回归 (Logit 链接 + 伯努利分布)
 - Probit 回归 (Probit 链接 + 伯努利分布)

典则链接函数 (Canonical Link Functions)

- **定义**：当链接函数 $g(\mu)$ 等于自然参数 θ 时，称为典则链接。
- **指数族分布形式**： $p(y|\theta) = h(y) \exp(\theta T(y) - A(\theta))$ 。
- **常见典则链接**：
 - 高斯分布 $\rightarrow$ 恒等函数 (Identity)。
 - 伯努利分布 $\rightarrow$ Logit 函数 ($\ln(\frac{\mu}{1-\mu})$)，对应逻辑回归。
 - 泊松分布 $\rightarrow$ 对数函数 (Log)。
- **重要性**：使用典则链接时，似然函数是凹的 (Concave)，保证了优化算法（如牛顿法/IRLS）能收敛到全局最优解，且计算形式最简洁。

指数族分布 (Exponential Family)

- **定义**：一类概率分布的集合，其概率密度/质量函数可以写成以下形式：

$$p(x|\eta) = h(x) \exp(\eta^T T(x) - A(\eta))$$

- **组件**：

- η ：自然参数 (Natural parameters)。
- $T(x)$ ：充分统计量 (Sufficient statistics)。
- $A(\eta)$ ：对数配分函数 (Log partition function)，保证归一化。
- **成员**：高斯分布、伯努利分布、多项式分布、泊松分布、Gamma 分布等。
- **意义**：广义线性模型的基础，许多优良的统计性质（如充分统计量的存在）都源于此。

二次判别函数 (Quadratic Discriminant)

- **来源**: 在生成式模型中, 如果假设各类别的类条件概率 $p(\mathbf{x}|C_k)$ 服从高斯分布, 且**协方差矩阵** Σ_k **各不相同**。
- **结果**: 对数后验概率 $\ln p(C_k|\mathbf{x})$ 中包含 $\mathbf{x}^T \Sigma_k^{-1} \mathbf{x}$ 项。
- **决策边界**: 由于不同类别的二次项系数不同, 相减后无法抵消, 导致决策边界是**二次曲面** (椭圆、抛物线、双曲线等)。
- **对比**: 如果假设所有类别共享同一个协方差矩阵 $\Sigma_k = \Sigma$, 二次项抵消, 退化为**线性判别分析 (LDA)**。

分类器准确率 (Classifier Accuracy)

- **定义：** 分类正确的样本数占总样本数的比例。

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

- **局限性：**
 - 在类别不平衡 (Class Imbalance) 的数据集中具有误导性。
 - 例如：99% 负样本，1% 正样本。全预测为负，准确率 99%，但模型毫无用处。
- **替代指标：** 精确率 (Precision)、召回率 (Recall)、F1-score、AUC。

混淆矩阵 (Confusion Matrix)

- **定义**: 一个 $K \times K$ 的表格, 用于总结分类模型的性能。
- **结构** (以二分类为例):

	预测正	预测负
实际正	TP (真阳性)	FN (假阴性)
实际负	FP (假阳性)	TN (真阴性)

- **用途**:
 - 直观展示错误类型 (是把正类错判为负类, 还是反之?)。
 - 计算 Precision, Recall, Specificity 等指标的基础。

ROC 曲线 (ROC Curve)

- **全称**: Receiver Operating Characteristic Curve.
- **坐标轴**:
 - X 轴: 假正率 ($FPR = FP / (FP + TN)$).
 - Y 轴: 真正率 ($TPR / Recall = TP / (TP + FN)$).
- **绘制**: 通过改变分类阈值, 得到一系列的 (FPR, TPR) 点连成的曲线。
- **AUC (Area Under Curve)**:
 - 曲线下面积, 衡量分类器整体性能。
 - $AUC = 0.5$ 表示随机猜测; $AUC = 1.0$ 表示完美分类。
 - 对类别不平衡不敏感, 是评价二分类器的重要指标。

总结

- 单层网络分类模型构成了现代深度学习的基础构件。
- 理解**生成式**与**判别式**的区别是选择模型的关键。
- **逻辑回归**和 **Softmax** 是处理概率输出的核心工具。
- 正确的**评估指标**（如混淆矩阵、ROC）比单纯的准确率更能反映模型真实性能。
- 深入理解这些概念有助于更好地设计、训练和调试复杂的神经网络。