

第 6 章：深度神经网络

第 1 节：固定基函数的局限性

《深度学习基础》课程小组

2026 年 5 月 3 日

- 1 线性基函数模型
- 2 主要局限性
- 3 维度诅咒
- 4 高维空间特性
- 5 数据流形
- 6 数据相关基函数

线性基函数模型

- 分类模型:

$$y(\mathbf{x}, \mathbf{w}) = f\left(\sum_{j=1}^M w_j \phi_j(\mathbf{x}) + w_0\right)$$

其中 $f(\cdot)$ 是非线性输出激活函数

- 回归模型: 形式相同, 但 $f(\cdot)$ 被替换为恒等函数
- 理论上, 这些模型可以解决任何回归或分类问题

主要局限性

- 基函数 $\phi_j(\mathbf{x})$ 是固定的，与训练数据无关
- 当输入变量数量增加时，模型性能显著下降
- 面临“维度诅咒”问题
- 需要寻找适应特定应用的基函数

维度诅咒：多项式模型

- 单变量多项式模型：

$$y(x, \mathbf{w}) = w_0 + w_1x + w_2x^2 + \dots + w_Mx^M$$


- 多变量情况 (D 个输入变量)：

$$y(\mathbf{x}, \mathbf{w}) = w_0 + \sum_{i=1}^D w_i x_i + \sum_{i=1}^D \sum_{j=1}^D w_{ij} x_i x_j + \sum_{i=1}^D \sum_{j=1}^D \sum_{k=1}^D w_{ijk} x_i x_j x_k$$

- 系数增长： $\mathcal{O}(D^3)$ 或 $\mathcal{O}(D^M)$

维度诅咒：网格分类器

- 将输入空间划分为规则单元格
- 每个测试点根据其所在单元格的多数类进行分类
- 问题：单元格数量随维度指数增长
- 需要指数级的训练数据来填充所有单元格



图：分类的一种方法，对高维数据，方框的数量将急剧增加

高维空间的几何直觉

- D 维超球体体积: $V_D(r) = K_D r^D$

$$V_1(r) = r, \quad V_2(r) = \pi r^2, \quad V_3(r) = \frac{4}{3}\pi r^3.$$

- 计算四维超球体的体积和表面积。
- 半径 $1 - \epsilon$ 到 1 之间的体积比例:

$$\frac{V_D(1) - V_D(1 - \epsilon)}{V_D(1)} = 1 - (1 - \epsilon)^D$$

- 在高维空间中, 超球体的大部分体积集中在表面附近的薄壳中!

高维空间中的高斯分布

- 高维空间中高斯分布的概率质量也集中在特定半径的薄壳中
- 低维空间的几何直觉在高维空间中可能失效
- 高维空间也可能有优势：使原本线性不可分的问题变得线性可分




图: 二维数据可分, 一维数据不可分的例子

径向基函数与支持向量机

- 径向基函数 (RBF):

$$\phi_n(\mathbf{x}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}_n\|^2}{s^2}\right)$$

- 支持向量机 (SVM): 自动选择基函数子集
- 缺点: 计算复杂度高, 不产生概率输出, 难以扩展到多类问题

数据相关基函数

- 传统方法：专家知识手工设计特征
- 现代方法：从训练数据中学习基函数（领域知识更多体现在网络架构定性设计层面）
- 深度神经网络能够学习适应数据流形的基函数
- 能够学习深层层次表示

自然图像 vs 随机图像

- 自然图像与随机图像示例展示了真实数据的强相关性
- 相邻像素在自然图像中具有相似的颜色
- 自然图像仅覆盖高维空间的一小部分

总结

- 固定基函数在高维空间中面临严重挑战
- 维度诅咒导致模型效率低下
- 数据流形概念解释了高维数据的有效低维结构
- 需要数据相关的、自适应的基函数
- 深度神经网络提供了有效的解决方案