

第 6 章：深度神经网络

第 2 节：多层网络 (Multilayer Networks)

《深度学习基础》课程小组

2026 年 5 月 3 日

目录

1 两层神经网络模型

2 参数矩阵

3 隐藏单元激活函数


4 权重空间对称性

多层网络概述

- 对于大规模数据集和高维空间问题，需要找到针对特定问题调整的一组基函数
- 神经网络的关键思想是选择具有可学习参数的基函数 $\phi_j(\mathbf{x})$
- 这些参数与系数 $\{w_j\}$ 一起在训练过程中调整
- 使用梯度下降法最小化误差函数来优化整个模型

两层神经网络模型（输入层、隐藏层和输出层）

- 构造 M 个输入变量 $x_1, \dots, x_D$ 的线性组合: $a_j^{(1)} = \sum_{i=1}^D w_{ji}^{(1)} x_i + w_{j0}^{(1)}, j = 1, \dots, M.$
- 每个量 a_j 通过可微非线性激活函数 $h(\cdot)$ 变换: $z_j^{(1)} = h(a_j^{(1)}).$



激活函数

- 这些代表基函数的输出，在神经网络中称为隐藏单元
- 最终通过第二层变换得到输出：

$$a_k^{(2)} = \sum_{j=1}^M w_{kj}^{(2)} z_j^{(1)} + w_{k0}^{(2)}$$

- 上标 (1) 表示第一层参数，参数 $w_{ji}^{(1)}$ 称为权重参数， $w_{j0}^{(1)}$ 称为偏置参数
- 输出量 y_k 通过可微非线性激活函数 $f(\cdot)$ 变换：

$$y_k = f(a_k^{(2)}).$$

参数矩阵表示

- 偏置参数可以吸收到权重参数中，定义额外输入变量 $x_0 = 1$ ：

$$a_j = \sum_{i=0}^D w_{ji}^{(1)} x_i$$

- 整体网络函数变为：

$$y_k(\mathbf{x}, \mathbf{w}) = f \left(\sum_{j=0}^M w_{kj}^{(2)} h \left(\sum_{i=0}^D w_{ji}^{(1)} x_i \right) \right)$$

- 矩阵形式表示：

$$\mathbf{y}(\mathbf{x}, \mathbf{w}) = f \left(\mathbf{W}^{(2)} h \left(\mathbf{W}^{(1)} \mathbf{x} \right) \right)$$

通用逼近性质

- 1980 年代广泛研究了两层前馈网络的逼近性质
- 对于广泛的激活函数，此类网络可以以任意精度逼近 $\mathbb{R}^D$ 连续子集上的任何函数
- 类似结果也适用于从任何有限维离散空间到另一个空间的函数
- 因此神经网络被称为通用逼近器

隐藏单元激活函数

- 隐藏单元激活函数的唯一要求是可微
- 最简单的选择是恒等函数，但这等价于无隐藏单元的网络
- 常用的非线性可微函数包括：
 - Logistic Sigmoid: $\sigma(a) = \frac{1}{1+\exp(-a)}$
 - Tanh: $\tanh(a) = \frac{e^a - e^{-a}}{e^a + e^{-a}}$
 - Softplus: $h(a) = \ln(1 + \exp(a))$
 - ReLU: $h(a) = \max(0, a)$

ReLU 及其变体

- ReLU (修正线性单元) 定义为: $h(a) = \max(0, a)$
- 经验上表现最好的激活函数之一
- 倾斜 ReLU (Leaky ReLU) 定义为:

$$h(a) = \max(0, a) + \alpha \min(0, a)$$

- 其中 $0 < \alpha < 1$

权重空间对称性

- 前馈网络的一个特性是多个不同的权重向量 $\mathbf{w}$ 可以产生相同的输入到输出映射
- 对于具有 M 个隐藏单元的两层网络：
 - 有 M 个“符号翻转”对称性
 - 有 $M!$ 个交换对称性（对应隐藏单元的不同排序）
 - 总体对称因子为 $M!2^M$

总结

- 多层网络通过可学习参数的基函数实现复杂模式识别
- 两层网络具有通用逼近能力
- 不同的激活函数各有优缺点
- 权重空间存在对称性，但通常对实际应用影响不大
- 深度学习通过更多层实现分层内部表示学习