

第 6 章：深度神经网络

第 3 节：深度网络 (Deep Networks)

《深度学习基础》课程小组

2026 年 5 月 2 日

目录

- ① 深度网络概述
- ② 分层表示
- ③ 分布式表示
- ④ 表示学习
- ⑤ 迁移学习
- ⑥ 对比学习
- ⑦ 通用网络架构
- ⑧ 张量

深度网络：超越两层

- 传统两层网络（图 6.9）难以训练深层结构，但**深度神经网络**（ > 2 层）带来显著优势；
- 深层网络可指数级提升表示能力：输入空间被划分为 $O(2^L)$ 个区域（ L 为深度），而两层网络需指数级隐藏单元；
- 核心动机：**分层表示**（Hierarchical representation）——低层特征（边、角）→ 中层组合（眼、耳）→ 高层语义（猫）。

分层表示：归纳偏置的核心

关键思想

深度网络通过层级抽象建模“像素 → 特征 → 概念”的映射，形成**组合性归纳偏置** (compositional inductive bias)。

- **例子：识别“猫”** ——
 - 底层：边缘、纹理（卷积核学习）；
 - 中层：眼睛、胡须（组合低层特征）；
 - 高层：整体对象（分类决策）。
- **生成视角：从边 → 圆 → 头部 → 猫**，每层组合方式呈指数增长。

分布式表示：高效编码

定义

隐藏层中**多个单元的组合**表示一个特征，而非单个单元独占。

- M 个单元可表示最多 2^M 种组合（指数增长）；
- **例子**：人脸图像（眼镜/帽子/胡须）——3 个单元即可编码 8 种组合；
- 优势：紧凑、鲁棒、泛化性强（统计相关性隐含在激活模式中）。

表示学习：自动发现有用特征

目标

将原始数据 x 映射到新空间 $z = f(x)$ ，使下游任务（如分类）更易求解。

- **监督式**：用标签驱动（如分类损失）；
- **无监督式**：仅用数据自身结构——
 - **自编码器 (Autoencoders)**：输入 $\rightarrow$ 压缩编码 $\rightarrow$ 重建输入；
 - 目标：强制网络学习有意义的压缩表示。
- 表示空间常称**嵌入空间 (embedding space)**。

核心思想

在任务 A 上预训练模型 → 迁移至任务 B (数据少)，复用底层通用特征。

- 典型流程：

- ① 在大规模数据集（如 ImageNet）上预训练 CNN；
- ② 冻结前 k 层，仅微调最后几层（或全网络微调）；
- ③ 适配新任务（如皮肤病变分类）。

- 两种策略：

- **冻结 + 微调 (Fine-tuning)**：小学习率更新全部参数；
- **特征提取**：固定预训练网络，仅训练新分类头。

对比学习：基于相似性的表示

基本设定

定义**正样本对**（语义相似）与**负样本对**（语义不同），优化嵌入距离。

正样本构造

- 实例判别：同一图像的增强版本（旋转、裁剪等）；
- 监督对比：同类图像为正对，异类为负对；
- CLIP：图像-文本对为正，错配为负。

InfoNCE 损失函数

$$E(w) = -\log \frac{\exp(\mathbf{f}_w(\mathbf{x})^T \mathbf{f}_w(\mathbf{x}^+))}{\exp(\mathbf{f}_w(\mathbf{x})^T \mathbf{f}_w(\mathbf{x}^+)) + \sum_{n=1}^N \exp(\mathbf{f}_w(\mathbf{x})^T \mathbf{f}_w(\mathbf{x}_n^-))} \quad (6.20)$$

CLIP 损失函数

$$\begin{aligned} E(w) = & -\frac{1}{2} \log \frac{\exp(\mathbf{f}_w(\mathbf{x}^+)^T \mathbf{g}_\theta(\mathbf{y}^+))}{\exp(\mathbf{f}_w(\mathbf{x}^+)^T \mathbf{g}_\theta(\mathbf{y}^+)) + \sum_{n=1}^N \exp(\mathbf{f}_w(\mathbf{x}_n^-)^T \mathbf{g}_\theta(\mathbf{y}^+))} \\ & -\frac{1}{2} \log \frac{\exp(\mathbf{f}_w(\mathbf{x}^+)^T \mathbf{g}_\theta(\mathbf{y}^+))}{\exp(\mathbf{f}_w(\mathbf{x}^+)^T \mathbf{g}_\theta(\mathbf{y}^+)) + \sum_{n=1}^N \exp(\mathbf{f}_w(\mathbf{x}_n^+)^T \mathbf{g}_\theta(\mathbf{y}^-))} \end{aligned} \quad (6.21)$$

解释 CLIP 损失函数

- f : 图像编码器; g : 文本编码器;
- 正对 $(\mathbf{x}^+, \mathbf{y}^+)$: 匹配的图文对;
- 负对 $(\mathbf{x}^+, \mathbf{y}^-)$: 错配文本; 负对 $(\mathbf{x}^-, \mathbf{y}^+)$: 错配图像。

通用网络架构：超越全连接

核心约束

前馈性 (Feed-forward)：无环有向图 $\Rightarrow$ 输出是输入的确定性函数。

- 任意节点 k 的计算：

$$z_k = h \left(\sum_{j \in \mathcal{A}(k)} w_{kj} z_j + b_k \right) \quad (6.22)$$

其中 $\mathcal{A}(k)$ 是 k 的祖先节点集合（所有输入该节点的单元）。

- 支持复杂拓扑：残差连接、Inception 分支、图神经网络等均可建模。

张量：高维数据的自然表示

定义

张量是标量、向量、矩阵的高维推广；神经网络中广泛存在。

- **例子：** N 张 RGB 图像 ($I \times J$ 像素) $\rightarrow$ 四阶张量 $\mathbf{X} \in \mathbb{R}^{I \times J \times 3 \times N}$;
 - i, j : 像素坐标;
 - $k = 1, 2, 3$: R/G/B 通道;
 - n : 样本索引。
- **重要性：**
 - 卷积操作天然作用于张量;
 - GPU 高度优化张量运算 (如 cuDNN);
 - Transformer 中的注意力权重也是张量。

本节小结

核心概念

- 分层表示 → 组合性归纳偏置
- 分布式表示 → 指数级特征容量
- 表示学习 → 自动发现嵌入空间
- 迁移学习 → 知识复用

前沿方法

- 对比学习 (InfoNCE, CLIP)
- 通用架构 (前馈图、张量运算)
- 多模态对齐 (图像-文本)

深度网络的本质：通过可微分的层级变换，将原始数据映射到任务友好的表示空间。