

第 6 章：深度神经网络

第 5 节：混合密度网络 (MDN)

《深度学习基础》课程小组

2026 年 5 月 2 日

目录

- 1 引言
- 2 MDN 的概念
- 3 示例：机器人运动学
- 4 MDN 的架构
- 5 训练：损失函数
- 6 MDN 的预测
- 7 应用
- 8 优点与缺点
- 9 总结

1. 引言：复杂条件分布的需求

- 标准神经网络 (NN) 通常将 $p(t|x)$ 建模为简单的分布 (例如, 回归任务中的高斯分布)。
- 这对于单峰、对称的分布效果很好。
- 然而, 许多现实世界的问题涉及**非高斯、多峰**的条件分布。
- 例如: 逆问题 (如机器人运动学) 中, 一个输入 x 可能对应多个有效的输出 t 。
- 解决方案: 使用更灵活的分布族来建模 $p(t|x)$ 。

2. 核心思想：混合密度网络 (MDN)

- MDN 将标准神经网络与输出层的**高斯混合模型 (GMM)** 相结合。
- 神经网络输出 GMM 的参数。
- 这使得网络能够表示复杂的、多峰的条件密度 $p(\mathbf{t}|\mathbf{x})$ 。
- 一般形式：


$$p(\mathbf{t}|\mathbf{x}) = \sum_{k=1}^K \pi_k(\mathbf{x}) \mathcal{N}(\mathbf{t}|\boldsymbol{\mu}_k(\mathbf{x}), \sigma_k^2(\mathbf{x})\mathbf{I})$$

- 其中：
 - K : 混合分量的数量。
 - $\pi_k(\mathbf{x})$: 分量 k 的混合系数 (神经网络的输出)。
 - $\boldsymbol{\mu}_k(\mathbf{x})$: 分量 k 的均值向量 (神经网络的输出)。
 - $\sigma_k^2(\mathbf{x})$: 分量 k 的方差 (通常为各向同性, 神经网络的输出)。

3. 示例：机器人臂逆运动学

- 正向问题：给定关节角度 θ_1, θ_2 ，求末端执行器位置 (x, y) 。通常有唯一解。
- 逆向问题：给定末端执行器位置 (x, y) ，求关节角度 θ_1, θ_2 。可能有多解（例如，“肘部向上” vs “肘部向下”）。
- 预测 $\mathbb{E}[\theta|x, y]$ （均值）的标准神经网络会失败，因为两个有效解的均值可能是无效的。
- MDN 可以将 $p(\theta|x, y)$ 建模为一个多峰分布，从而捕捉到这两个有效解。


Figure 6.16 (a) A two-link robot arm, in which the Cartesian coordinates (x_1, x_2) of the end effector are determined uniquely by the two joint angles θ_1 and θ_2 and the (fixed) lengths L_1 and L_2 of the arms. This is known as the *forward kinematics* of the arm. (b) In practice, we have to find the joint angles that will give rise to a desired end effector position. This *inverse kinematics* has two solutions corresponding to 'elbow up' and 'elbow down'.



图： 机器人臂在相同末端位置下的两种可能构型。

4. 实验示例：逆函数

- 考虑一个正向过程： $x \rightarrow t = f(x) + \epsilon$ （带有噪声 ϵ ）。
- 逆向问题是：给定 t ，推断 x 。这可能是高度多峰的。
- 生成数据： $x_n \sim U(0, 1)$, $t_n = x_n + 0.3 \sin(2\pi x_n) + \text{噪声}$ 。
- 交换角色：使用 t_n 作为输入， x_n 作为目标。
- 标准神经网络（最小二乘法）：对于多峰 $p(x|t)$ 拟合效果差。
- MDN：能够捕捉 $p(x|t)$ 的复杂形状。




图：左（正向问题）标准神经网络拟合效果好；右（逆向问题）拟合效果差。

5. 混合密度网络的架构

- 标准的前馈神经网络（例如，具有隐藏层的 MLP）。
- 输出层有多个头（heads）：
 - K 个单元用于混合系数 $\pi_k(\mathbf{x})$ （Softmax 激活函数）。
 - $K \times L$ 个单元用于均值 $\mu_{k,j}(\mathbf{x})$ （线性激活函数，其中 L 是 t 的维度）。
 - K 个单元用于方差 $\sigma_k^2(\mathbf{x})$ （Exp 激活函数以确保正值）。
- 总输出数： $K + K \times L + K = K(L + 2)$ 。
- 神经网络学习将 $\mathbf{x}$ 映射到参数 $\{\pi_k, \mu_k, \sigma_k^2\}$ 。

Figure 6.18 The mixture density network can represent general conditional probability densities $p(t|\mathbf{x})$ by considering a parametric mixture model for the distribution of t whose parameters are determined by the outputs of a neural network that takes $\mathbf{x}$ as its input vector.



图：混合密度网络的示意图。

6. 输出激活函数

- 混合系数 $\pi_k(\mathbf{x})$:

- 必须满足 $\sum_k \pi_k = 1$ 和 $0 \leq \pi_k \leq 1$ 。
- 在预激活值 a_k^π 上使用 Softmax:

$$\pi_k = \frac{\exp(a_k^\pi)}{\sum_{l=1}^K \exp(a_l^\pi)}$$

- 方差 $\sigma_k^2(\mathbf{x})$:

- 必须为正: $\sigma_k^2 > 0$ 。
- 在预激活值 a_k^σ 上使用指数函数:

$$\sigma_k^2 = \exp(a_k^\sigma)$$

- 均值 $\mu_k(\mathbf{x})$:

- 可以为任意实数值。
- 使用线性激活函数: $\mu_{k,j} = a_{k,j}^\mu$ 。

7. 训练：损失函数（负对数似然）

- 为了训练 MDN，最大化观测数据 $\{\mathbf{x}_n, \mathbf{t}_n\}$ 的似然。
- 最小化负对数似然：

$$E(\mathbf{w}) = - \sum_{n=1}^N \log \left(\sum_{k=1}^K \pi_k(\mathbf{x}_n; \mathbf{w}) \mathcal{N}(\mathbf{t}_n | \boldsymbol{\mu}_k(\mathbf{x}_n; \mathbf{w}), \sigma_k^2(\mathbf{x}_n; \mathbf{w}) \mathbf{I}) \right)$$

- 这个损失函数鼓励预测的混合分布 $p(\mathbf{t}_n | \mathbf{x}_n)$ 对真实目标 $\mathbf{t}_n$ 分配较高的概率。
- 可以使用标准反向传播算法计算梯度 $\frac{\partial E}{\partial \mathbf{w}}$ 。

8. 关于输出预激活值的梯度

- 定义中间量 (后验责任):

$$\gamma_{nk} = \frac{\pi_k(\mathbf{x}_n) \mathcal{N}(\mathbf{t}_n | \boldsymbol{\mu}_k(\mathbf{x}_n), \sigma_k^2(\mathbf{x}_n) \mathbf{I})}{\sum_{l=1}^K \pi_l(\mathbf{x}_n) \mathcal{N}(\mathbf{t}_n | \boldsymbol{\mu}_l(\mathbf{x}_n), \sigma_l^2(\mathbf{x}_n) \mathbf{I})}$$

- 关于输出预激活值 ($a_k^\pi, a_{kl}^\mu, a_k^\sigma$) 的梯度:

$$\frac{\partial E_n}{\partial a_k^\pi} = \pi_k - \gamma_{nk}$$

$$\frac{\partial E_n}{\partial a_{kl}^\mu} = \gamma_{nk} \left(\frac{\mu_{kl} - t_{nl}}{\sigma_k^2} \right)$$

$$\frac{\partial E_n}{\partial a_k^\sigma} = \gamma_{nk} \left(L - \frac{\|\mathbf{t}_n - \boldsymbol{\mu}_k\|^2}{\sigma_k^2} \right)$$

9. 进行预测：条件分布

- 训练完成后，MDN 提供完整的条件密度 $p(\mathbf{t}|\mathbf{x})$ 。
- 这比仅仅预测一个单一值 $\hat{\mathbf{t}}$ 更丰富。
- 我们可以从 $p(\mathbf{t}|\mathbf{x})$ 中采样，以生成多样化、合理的输出。
- 我们可以计算统计量：
 - 条件均值： $\mathbb{E}[\mathbf{t}|\mathbf{x}] = \sum_k \pi_k(\mathbf{x}) \boldsymbol{\mu}_k(\mathbf{x})$
 - 条件方差：涉及 $\pi_k, \boldsymbol{\mu}_k, \sigma_k^2$ 的更复杂公式。
- 对于多峰分布，均值可能会产生误导；采样或模式更有意义。

9. 进行预测：条件分布 - 实验结果




图: (a) 分量配置、(b) 分量的均值、(c) 条件概率密度、(d) 近似条件众数

10. 混合密度网络的应用

- **逆问题**：机器人控制、计算机视觉（姿态估计）。
- **序列建模**：手写合成（Graves, 2013）、语音生成。
- **不确定性量化**：不仅预测一个值，还预测反映置信度的分布。
- **物理/科学**：建模复杂的物理关系（例如，系外行星表征）。
- **生成任务**：提供一种可学习的、参数化的复杂输出分布建模方法。

11. 混合密度网络的优点

- 能够建模复杂、多峰的条件分布。
- 提供预测中的不确定性度量。
- 灵活的框架：可以调整分量数量 K 和网络架构。
- 统一了函数逼近和密度建模。
- 输出混合模型的可解释参数。

12. 混合密度网络的缺点

- 比标准回归/分类网络更复杂。
- 需要更多参数（特别是当 K 或 L 较大时）。
- 训练可能更具挑战性（例如，模式坍塌、梯度消失）。
- 选择分量数量 K 需要调优。
- 假设组件为高斯分布（尽管可以使用其他类型的组件）。

13. 总结

- 混合密度网络 (MDN) 是一种用于建模复杂条件概率分布 $p(\mathbf{t}|\mathbf{x})$ 的强大工具。
- 它将神经网络与高斯混合模型 (GMM) 相结合。
- 网络输出 GMM 的参数 (混合系数、均值、方差)。
- 这对于具有多峰输出的问题特别有用 (逆问题)。
- 通过最大似然 (负对数似然损失) 进行训练。
- 提供超越单一预测点的丰富预测, 包括不确定性信息。

14. 参考文献

- 教材: Bishop, C. M. & Bishop, H. (2023). Deep Learning Foundations and Concepts. Springer Nature Switzerland AG.
- Bishop, C. M. (1994). Mixture Density Networks. Technical Report NCRG/94/004, Aston University.
- Graves, A. (2013). Generating Sequences With Recurrent Neural Networks. arXiv preprint arXiv:1308.0850.
- 博客文章: blog.otoro.net (使用 TensorFlow 的混合密度网络)。

15. 课程网站资源

`https://gitee.com/liqing-wang-cscs/deep-learning-foundations`

- 课文解读
- 例子代码
- 本幻灯片
- 课文相关练习题