

第 7 章：梯度下降

第 1 节：误差曲面 (Error Surfaces)

《深度学习基础》课程小组

2026 年 10 月 7 日

目录

- 1 神经网络的参数设定
- 2 基于梯度的误差函数优化
- 3 反向传播
- 4 泛化与正则化
- 5 误差曲面的几何直观
- 6 驻点与梯度
- 7 非线性与等效极小值
- 8 全局与局部极小值
- 9 局部二次近似
- 10 海森矩阵与二阶信息
- 11 正定矩阵与等高线
- 12 总结
- 13 参考文献

1. 从函数逼近到参数设定

- 神经网络是一类非常广泛且灵活的函数。
- 原则上，只要隐藏单元足够多，就能以任意精度逼近任何函数。
- 深度神经网络还能编码与层级化表示对应的归纳偏置。
- 现在的问题：如何根据训练数据，找到合适的网络参数（权重和偏置）？

1.1 关键概念：归纳偏置与层级化表示

归纳偏置 (Inductive Bias)

模型为了从有限数据中泛化而做出的一系列假设或偏好。

例如：CNN 的归纳偏置是“平移不变性”——猫在图像左上角还是右下角，都是猫。

层级化表示 (Hierarchical Representations)

数据特征被组织成从低级到高级、从简单到复杂的层次结构。

例如：人脸识别中，底层提取边缘线条 → 中层组合成眼睛、鼻子 → 高层组合成完整人脸。

- **实验建议**：结合 MNIST 手写数字识别，把这两个概念串起来。

2. 为什么要用梯度？

- 与回归和分类模型一样，我们通过**优化误差函数**来选择模型参数。
- 误差函数可以用**最大似然法**来定义。
- 直接评估误差函数值来最小化（如网格搜索）——**效率非常低**。
- 更高效的方法：**利用梯度信息**，即计算误差函数对网络参数的导数。
- 这就是为什么我们要求神经网络和误差函数都**可微**。

2.1 如何用最大似然构造误差函数？

- ① **写出似然函数**：假设样本独立同分布，

$$L(\mathbf{w}) = \prod_{n=1}^N p(t_n|x_n, \mathbf{w})$$

- ② **取对数**：将乘积转化为求和，

$$\ln L(\mathbf{w}) = \sum_{n=1}^N \ln p(t_n|x_n, \mathbf{w})$$

- ③ **转化为误差函数**：最大化对数似然等价于最小化负对数似然，

$$E(\mathbf{w}) = -\ln L(\mathbf{w}) = -\sum_{n=1}^N \ln p(t_n|x_n, \mathbf{w})$$

- 回归（高斯噪声）→ 均方误差 (MSE)
- 二分类（伯努利分布）→ 交叉熵损失 (Cross-Entropy)

2.2 什么是直接误差函数评估？

- **定义：**不使用梯度信息，仅通过反复“代入参数值 $\rightarrow$ 计算误差”来寻找最小值。
- **典型方法：**网格搜索 (Grid Search)、随机搜索 (Random Search)、Nelder-Mead 单纯形法。
- **为什么效率低？**
 - 神经网络参数量巨大（数万到数百万）。
 - 在高维空间中逐点评估，就像蒙着眼睛在山谷里找最低点。
 - 利用梯度，就像知道了脚下山坡的倾斜方向，可以直接朝下坡方向大步前进。

3. 反向传播：高效计算导数

- 误差函数对网络中各参数的导数，可以用**反向传播 (Backpropagation)** 高效计算。
- 核心思想：计算过程从后向前传递，类似于前向传播的“镜像”。
- **前向传播**：输入 $\rightarrow$ 逐层计算 $\rightarrow$ 得到预测 $\rightarrow$ 计算误差（保存中间变量）。
- **反向传播**：从误差开始 $\rightarrow$ 利用保存的中间变量 $\rightarrow$ 逐层回传局部梯度 $\rightarrow$ 得到所有参数的梯度。

3.1 反向传播为什么高效?

- 链式法则逐层分解:

$$\frac{\partial E}{\partial \text{某层参数}} = \frac{\partial E}{\partial \text{该层输出}} \times \frac{\partial \text{该层输出}}{\partial \text{该层输入}} \times \frac{\partial \text{该层输入}}{\partial \text{该层参数}}$$

- **避免重复计算**: 从输出层向输入层逐层回传“误差信号”，每层只需与自己的局部导数相乘。
- **计算复杂度**: 约等于一次前向传播的两倍，将指数级计算量降为线性级别。

实验建议

用一个简单的两神经网络，手动走一遍前向传播和反向传播的具体计算过程。

4. 泛化能力与正则化的重要性

- 虽然似然用于定义误差函数，但神经网络优化的目标是在测试数据上取得良好泛化。
- **经典统计学**：数据多、参数少，目标是精确拟合，找到似然最大化的唯一最优解。
- **现代深度学习**：参数极多（甚至多于数据量），目标不是精确优化。
- 学习算法本身的特性（如 SGD 的隐式正则化）以及显式正则化方法（Dropout、权重衰减）对泛化至关重要。

5. 权重空间与误差曲面

- 将所有权重和偏置整合为一个向量 $\mathbf{w}$ ，通过优化误差函数 $E(\mathbf{w})$ 来训练。
- **权重空间 (Weight Space)**: 若网络有 W 个参数，则权重空间是 W 维空间，每个点代表一组参数。
- **误差曲面 (Error Surface)**: 误差函数 $E(\mathbf{w})$ 像地形的高低起伏。
- **优化本质**: 在这个高维地形中寻找海拔最低的山谷 (全局极小值或较好的局部极小值)。




图: 误差函数 $E(\mathbf{w})$ 作为覆盖在权重空间之上的曲面。

6. 驻点与梯度的数学性质

- 在权重空间中迈出一小步 $\delta \mathbf{w}$, 误差变化为:

$$\delta E \simeq \delta \mathbf{w}^T \nabla E(\mathbf{w}) \quad (7.1)$$

其中 $\nabla E(\mathbf{w})$ 指向误差增长最快的方向。

- 最小值出现在梯度为零的点:

$$\nabla E(\mathbf{w}) = \mathbf{0} \quad (7.2)$$

- 梯度为零的点称为**驻点**, 可分为极小值、极大值和鞍点。

6.1 为什么要计算梯度？

- **公式 (7.1)**: 一阶泰勒近似。当 $\delta \mathbf{w}$ 与 $-\nabla E(\mathbf{w})$ 方向一致时，误差下降最快——这就是“梯度下降”名称的由来。
- **公式 (7.2)**: 极值的一阶必要条件。找到“平地”（驻点），但可能是碗底、山顶或马鞍面。
- **深度学习中的挑战**: 高维空间中鞍点远多于局部极小值。需要动量、Adam 等机制帮助跳出鞍点。

7. 误差曲面的非线性与等效极小值

- 误差函数对权重和偏置具有高度非线性依赖，存在许多梯度为零的点。
- 对于任何局部极小值 w ，通常还存在其他等效极小值。
- 例如：具有 M 个隐藏单元的两层网络，每个点属于一个包含 $M! 2^M$ 个等效点的集合。

为什么有这么多等效极小值？

- **排列对称性** ($M!$)：隐藏单元地位平等，交换任意两个单元的所有权重，网络输入输出关系不变。
- **符号对称性** (2^M)：使用奇函数激活（如 $\tanh$ ），将某单元所有输入输出权重同时取反，输出不变。

8. 全局极小值与局部极小值

- **全局极小值**：在整个 w 空间中误差函数最小的点。
- **局部极小值**：其他对应较高误差值的极小值点。
- 过去认为梯度法可能陷入较差的局部极小值。
- **实践中并非如此**：大型网络在不同初始条件下都能达到性能相似的解。

为什么深度学习不怕局部极小值？

- 高维空间中**鞍点远多于局部极小值**。
- 即使掉入局部极小值，其误差值往往接近，且处于**平坦区域**，对应良好泛化能力。

9. 局部二次近似与泰勒展开

- 通过局部二次近似可以深入理解优化问题。
- $E(\mathbf{w})$ 在 $\tilde{\mathbf{w}}$ 附近的泰勒展开：

$$E(\mathbf{w}) \approx E(\tilde{\mathbf{w}}) + (\mathbf{w} - \tilde{\mathbf{w}})^T \mathbf{b} + \frac{1}{2}(\mathbf{w} - \tilde{\mathbf{w}})^T \mathbf{H}(\mathbf{w} - \tilde{\mathbf{w}}) \quad (7.3)$$

- 梯度：** $\mathbf{b} \equiv \nabla E|_{\mathbf{w}=\tilde{\mathbf{w}}}$
- 海森矩阵：** $\mathbf{H}(\tilde{\mathbf{w}}) \equiv \nabla \nabla E(\mathbf{w})|_{\mathbf{w}=\tilde{\mathbf{w}}}$
- 梯度的局部近似：

$$\nabla E(\mathbf{w}) \approx \mathbf{b} + \mathbf{H}(\mathbf{w} - \tilde{\mathbf{w}}) \quad (7.6)$$

9.1 从 (7.3) 到 (7.6): 求梯度

对 (7.3) 式两边关于 $\mathbf{w}$ 求梯度:

- ① 第一项 $E(\tilde{\mathbf{w}})$ 是常数, 导数为 0。
- ② 第二项 $(\mathbf{w} - \tilde{\mathbf{w}})^T \mathbf{b}$ 是线性项, 导数为 $\mathbf{b}$ 。
- ③ 第三项 $\frac{1}{2}(\mathbf{w} - \tilde{\mathbf{w}})^T \mathbf{H}(\mathbf{w} - \tilde{\mathbf{w}})$ 是二次型, 导数为 $\mathbf{H}(\mathbf{w} - \tilde{\mathbf{w}})$ 。

合并得:

$$\nabla E(\mathbf{w}) \approx \mathbf{b} + \mathbf{H}(\mathbf{w} - \tilde{\mathbf{w}})$$

意义

- (7.3) 用二次曲面近似原函数的“高度”。
- (7.6) 用切平面斜率近似原函数的梯度。
- 在牛顿法中, 可通过求解 $\mathbf{H}\Delta\mathbf{w} = -\mathbf{b}$ 直接“跳跃”到近似极小值点。

10. 海森矩阵与驻点分类

在极小值点 $\mathbf{w}^*$ 附近, $\nabla E = \mathbf{0}$, (7.3) 变为:

$$E(\mathbf{w}) = E(\mathbf{w}^*) + \frac{1}{2}(\mathbf{w} - \mathbf{w}^*)^T \mathbf{H}(\mathbf{w} - \mathbf{w}^*) \quad (7.7)$$

考虑海森矩阵的特征值方程:

$$\mathbf{H}\mathbf{u}_i = \lambda_i \mathbf{u}_i \quad (7.8)$$

将 $(\mathbf{w} - \mathbf{w}^*)$ 展开为特征向量的线性组合:

$$\mathbf{w} - \mathbf{w}^* = \sum_i \alpha_i \mathbf{u}_i \quad (7.10)$$

代入得:

$$E(\mathbf{w}) = E(\mathbf{w}^*) + \frac{1}{2} \sum_i \lambda_i \alpha_i^2 \quad (7.11)$$

10.1 特征值与驻点类型

- 若所有 $\lambda_i > 0$: $\mathbf{w}^*$ 是局部极小值。
- 若所有 $\lambda_i < 0$: $\mathbf{w}^*$ 是局部极大值。
- 若特征值有正有负: $\mathbf{w}^*$ 是鞍点。

直观理解

- 特征向量 $\mathbf{u}_i$ 是误差曲面的“主轴”。
- 特征值 λ_i 描述曲面在 $\mathbf{u}_i$ 方向上的弯曲程度。
- $\lambda_i > 0$: 向上弯曲 (碗底); $\lambda_i < 0$: 向下弯曲 (山顶)。

11. 正定矩阵与局部极小值的充要条件

- 矩阵 $\mathbf{H}$ 是**正定**的，当且仅当：

$$\mathbf{v}^T \mathbf{H} \mathbf{v} > 0, \quad \text{对于所有 } \mathbf{v} \quad (7.12)$$

- 任意向量 $\mathbf{v} = \sum_i c_i \mathbf{u}_i$ ，则：

$$\mathbf{v}^T \mathbf{H} \mathbf{v} = \sum_i c_i^2 \lambda_i \quad (7.14)$$

- $\mathbf{H}$ 正定 $\Leftrightarrow$ 所有特征值为正。
- 局部极小值的充要条件**：梯度为零，且海森矩阵正定。

11.1 等高线的几何直觉

- 在以特征向量为基的新坐标系中， $E(\mathbf{w})$ 的等高线是轴对齐的椭圆。
- 椭圆的轴长与对应特征值的平方根成反比。




图: 在极小值 w^* 附近，误差等高线为椭圆，其轴与海森矩阵的特征向量对齐。

- λ_i 越大，该方向上曲面越陡，等高线越扁。
- 若某些 $\lambda_i < 0$ ，等高线变为双曲线（鞍点特征）。

12. 本节总结

- 神经网络通过**优化误差函数**来确定参数。
- **梯度信息**使优化效率远高于直接评估。
- **反向传播**高效计算所有参数的梯度，复杂度约等于两次前向传播。
- **误差曲面**是覆盖在权重空间上的高维曲面，优化即寻找最低点。
- **驻点**（梯度为零）分为极小值、极大值和鞍点。
- **海森矩阵**的特征值决定驻点类型：全正为极小值，全负为极大值，有正有负为鞍点。
- 深度学习中，**鞍点远多于局部极小值**，且局部极小值通常质量很高。
- **局部二次近似**和**正定矩阵**为理解优化提供了严格的数学工具。

13. 参考文献

- 教材: Bishop, C. M. & Bishop, H. (2023). Deep Learning Foundations and Concepts. Springer Nature Switzerland AG.
- Bishop, C. M. (2006). Pattern Recognition and Machine Learning. Springer.