

第 7 章：梯度下降

第 3 节：收敛性 (Convergence)

《深度学习基础》课程小组

2026 年 10 月 7 日

目录

- 1 学习率与收敛问题
- 2 二次近似分析
- 3 动量
- 4 学习率调度
- 5 RMSProp 与 Adam
- 6 总结
- 7 参考文献

1. 学习率的选择与“山谷”问题

- 应用梯度下降时，需要选择学习率 η 。
- 考虑误差曲面的“山谷”形状（图 7.3）：曲率随方向显著变化。
- 在大多数点上，局部梯度并不直接指向极小值。
- 直观上增大 η 应该加快收敛。
- 但实际上：每一步在山谷两侧来回振荡。
- 若 η 太大，振荡会发散。
- 为避免发散， η 必须足够小 $\Rightarrow$ 沿山谷方向进展非常缓慢。

1.1 固定步长梯度下降示意图




图: 误差曲面呈长山谷形状, 梯度下降在两侧振荡, 沿山谷方向进展缓慢。

- u_1 和 u_2 是海森矩阵的特征向量。
- 相邻步骤在谷壁之间振荡。

2. 极小值附近的二次近似分析

在极小值附近，由 (7.7)(7.8)(7.10)：

$$\nabla E = \sum_i \alpha_i \lambda_i \mathbf{u}_i \quad (7.24)$$

权重变化：

$$\Delta \mathbf{w} = \sum_i \Delta \alpha_i \mathbf{u}_i \quad (7.25)$$

结合梯度下降公式 (7.16) 和正交性 (7.9)：

$$\Delta \alpha_i = -\eta \lambda_i \alpha_i \quad (7.26)$$

$$\alpha_i^{\text{new}} = (1 - \eta \lambda_i) \alpha_i^{\text{old}} \quad (7.27)$$

α_i 可解释为沿 $\mathbf{u}_i$ 方向到极小值的距离。

2.1 收敛条件与线性收敛

经过 T 步后:

$$\alpha_i^{(T)} = (1 - \eta\lambda_i)^T \alpha_i^{(0)} \quad (7.29)$$

- 若 $|1 - \eta\lambda_i| < 1$, 则 $T \rightarrow \infty$ 时 $\alpha_i \rightarrow 0$, 即 $\mathbf{w} \rightarrow \mathbf{w}^*$ 。
- 梯度下降在极小值附近呈线性收敛。
- 收敛要求所有 $\lambda_i > 0$ (驻点确实是极小值)。
- 增大 η 可使 $(1 - \eta\lambda_i)$ 更小, 加快收敛。
- 但必须保证 $|1 - \eta\lambda_i| < 1$, 否则 α_i 发散。
- 限制: $\eta < 2/\lambda_{\max}$ 。

2.2 条件数与收敛速度

- 收敛速度由最小特征值主导。
- 取 η 为最大允许值时，沿最小特征值方向的收敛由下式控制：

$$\left(1 - \frac{2\lambda_{\min}}{\lambda_{\max}}\right) \quad (7.30)$$

- $\lambda_{\min}/\lambda_{\max}$ 的倒数称为海森矩阵的条件数 (condition number)。
- 若该比值很小 (椭圆高度拉长)，则收敛极其缓慢。

3. 动量 (Momentum)

- 解决特征值差异大问题的简单技术：在梯度下降中加入动量项。
- 效果：为权重空间中的运动增加惯性，平滑振荡。
- 修改后的公式：

$$\Delta \mathbf{w}^{(\tau-1)} = -\eta \nabla E(\mathbf{w}^{(\tau-1)}) + \mu \Delta \mathbf{w}^{(\tau-2)} \quad (7.31)$$

- μ 称为动量参数。

3.1 低曲率区域：有效学习率增大


在低曲率区域（图 7.4），假设梯度不变，迭代求和：

$$\begin{aligned}\Delta \mathbf{w} &= -\eta \nabla E \{1 + \mu + \mu^2 + \dots\} \\ &= -\frac{\eta}{1 - \mu} \nabla E\end{aligned}\tag{7.32}$$

- 动量项的效果：有效学习率从 η 增大到 $\eta/(1 - \mu)$ 。
- 典型值 $\mu = 0.9 \Rightarrow$ 有效学习率增大约 10 倍。

3.2 高曲率区域：抑制振荡

- 在高曲率区域（图 7.5），梯度下降呈**振荡**状态。
- 动量项的连续贡献**相互抵消**，有效学习率接近 η 。
- 结论：动量项可以**加速收敛而不引起发散振荡**（图 7.6）。



图：添加动量项后沿山谷方向进展更快。

3.3 带动量的 SGD 算法 I

- 引入第二个参数 μ , 范围 $0 \leq \mu \leq 1$, 典型值 $\mu = 0.9$ 。

3.3 带动量的 SGD 算法 II

Algorithm 1 Stochastic gradient descent with momentum

Input: Training set $\{1, \dots, N\}$; batch size B ; error $E_{n:n+B-1}(\mathbf{w})$; η ; μ ; initial $\mathbf{w}$

Output: Final weight vector $\mathbf{w}$

$n \leftarrow 1$; $\Delta \mathbf{w} \leftarrow 0$

repeat

$\Delta \mathbf{w} \leftarrow -\eta \nabla E_{n:n+B-1}(\mathbf{w}) + \mu \Delta \mathbf{w}$

// 带动量更新

$\mathbf{w} \leftarrow \mathbf{w} + \Delta \mathbf{w}$

// 更新权重

$n \leftarrow n + B$

if $n + B > N$ **then**

 shuffle data; $n \leftarrow 1$

end if

until convergence

return $\mathbf{w}$

3.4 Nesterov 动量

- 改变计算顺序：先根据上一步动量走一步，再在新位置计算梯度。

$$\Delta \mathbf{w}^{(\tau-1)} = -\eta \nabla E \left(\mathbf{w}^{(\tau-1)} + \mu \Delta \mathbf{w}^{(\tau-2)} \right) + \mu \Delta \mathbf{w}^{(\tau-2)} \quad (7.34)$$

- 对批量梯度下降可改善收敛速度。
- 对随机梯度下降效果可能较弱。

4. 学习率调度 (Learning Rate Schedule)

- η 太小 $\rightarrow$ 学习慢; η 太大 $\rightarrow$ 不稳定。
- 最佳实践: **训练初期用较大 η , 随时间减小。**

$$\mathbf{w}^{(\tau)} = \mathbf{w}^{(\tau-1)} - \eta^{(\tau-1)} \nabla E_n(\mathbf{w}^{(\tau-1)}) \quad (7.35)$$

- 常见调度方式:

$$\eta^{(\tau)} = (1 - \tau/K) \eta^{(0)} + (\tau/K) \eta^{(K)} \quad (7.36)$$

$$\eta^{(\tau)} = \eta^{(0)} (1 + \tau/s)^c \quad (7.37)$$

$$\eta^{(\tau)} = \eta^{(0)} c^{\tau/s} \quad (7.38)$$

- 超参数 $\eta^{(0)}, \eta^{(K)}, K, S, c$ 需**经验性选择**。
- 建议监控**学习曲线**, 确保误差以合适速率下降。

5. 自适应学习率算法

- 最优学习率取决于误差曲面的局部曲率。
- 曲率随参数空间方向变化。
- 动机：为每个参数使用不同的学习率，自动调整。
- 注意：这种直觉在局部对角海森矩阵时成立，实际中不常见，但这些算法仍然有效且广泛使用。

5.1 AdaGrad

- 核心思想：用**梯度平方的累积和**来减小每个参数的学习率。
- 高曲率参数的学习率减小最快。

$$r_i^{(\tau)} = r_i^{(\tau-1)} + \left(\frac{\partial E(\mathbf{w})}{\partial w_i} \right)^2 \quad (7.39)$$

$$w_i^{(\tau)} = w_i^{(\tau-1)} - \frac{\eta}{\sqrt{r_i^{(\tau)} + \delta}} \left(\frac{\partial E(\mathbf{w})}{\partial w_i} \right) \quad (7.40)$$

- $\delta \approx 10^{-8}$ 保证数值稳定性。
- **问题**：从训练开始就累积平方梯度，后期更新量过小，训练过慢。

5.2 RMSProp

- 将 AdaGrad 的平方梯度和替换为指数加权平均。

$$r_i^{(\tau)} = \beta r_i^{(\tau-1)} + (1 - \beta) \left(\frac{\partial E(\mathbf{w})}{\partial w_i} \right)^2 \quad (7.41)$$

$$w_i^{(\tau)} = w_i^{(\tau-1)} - \frac{\eta}{\sqrt{r_i^{(\tau)} + \delta}} \left(\frac{\partial E(\mathbf{w})}{\partial w_i} \right) \quad (7.42)$$

- 典型值 $\beta = 0.9$ 。

5.3 Adam: RMSProp + 动量 I

- 名称来自 **adaptive moments**。
- 为每个参数 **分别存储动量**，对梯度和平方梯度都使用指数加权移动平均。

$$s_i^{(\tau)} = \beta_1 s_i^{(\tau-1)} + (1 - \beta_1) \left(\frac{\partial E(\mathbf{w})}{\partial w_i} \right) \quad (7.43)$$

$$r_i^{(\tau)} = \beta_2 r_i^{(\tau-1)} + (1 - \beta_2) \left(\frac{\partial E(\mathbf{w})}{\partial w_i} \right)^2 \quad (7.44)$$

$$\hat{s}_i^{(\tau)} = \frac{s_i^{(\tau)}}{1 - \beta_1^\tau} \quad (7.45)$$

$$\hat{r}_i^{(\tau)} = \frac{r_i^{(\tau)}}{1 - \beta_2^\tau} \quad (7.46)$$

$$w_i^{(\tau)} = w_i^{(\tau-1)} - \eta \frac{\hat{s}_i^\tau}{\sqrt{\hat{r}_i^\tau} + \delta} \quad (7.47)$$

5.3 Adam: RMSProp + 动量 II

- 偏差修正: $1/(1 - \beta_1^T)$ 和 $1/(1 - \beta_2^T)$ 修正零初始化带来的偏差。
- 典型值: $\beta_1 = 0.9$, $\beta_2 = 0.99$ 。
- Adam 是深度学习中最广泛采用的优化算法。

5.4 Adam 算法伪代码

Algorithm 2 Adam optimization

Input: $\{1, \dots, N\}$; B ; $E_{n:n+B-1}(\mathbf{w})$; η ; β_1, β_2 ; δ

Output: Final weight vector $\mathbf{w}$

$n \leftarrow 1$; $s \leftarrow 0$; $r \leftarrow 0$

repeat

 随机选择一个小批量

$g = -\nabla E_{n:n+B-1}(\mathbf{w})$

$s \leftarrow \beta_1 s + (1 - \beta_1)g$

$r \leftarrow \beta_2 r + (1 - \beta_2)g \odot g$

$\hat{s} \leftarrow s / (1 - \beta_1^T)$

$\hat{r} \leftarrow r / (1 - \beta_2^T)$

$\Delta \mathbf{w} \leftarrow -\eta \frac{\hat{s}}{\sqrt{\hat{r} + \delta}}$

$\mathbf{w} \leftarrow \mathbf{w} + \Delta \mathbf{w}$

$n \leftarrow n + B$

if $n + B > N$ **then**

 shuffle data; $n \leftarrow 1$

end if

until convergence

return $\mathbf{w}$

6. 本节总结

- **学习率 η** 的选择至关重要：太大导致振荡发散，太小收敛缓慢。
- **二次近似分析**：收敛速度由条件数 $\lambda_{\max}/\lambda_{\min}$ 决定。
- **动量**：增加惯性，低曲率区域增大有效学习率，高曲率区域抑制振荡。
- **Nesterov 动量**：改变计算顺序，对批量梯度下降更有效。
- **学习率调度**：训练初期用大 η ，随时间减小（线性、幂律、指数衰减）。
- **自适应学习率算法**：
 - **AdaGrad**：累积平方梯度，后期更新过小。
 - **RMSProp**：指数加权平均，解决 AdaGrad 后期过慢问题。
 - **Adam**：RMSProp + 动量 + 偏差修正，最广泛使用。

7. 参考文献

- 教材: Bishop, C. M. & Bishop, H. (2023). Deep Learning Foundations and Concepts. Springer Nature Switzerland AG.
- Nesterov, Y. (2004). Introductory Lectures on Convex Optimization.
- Duchi, J., Hazan, E., & Singer, Y. (2011). Adaptive subgradient methods for online learning and stochastic optimization.
- Hinton, G. (2012). Lecture 6.5 - RMSProp, COURSERA: Neural Networks for Machine Learning.
- Kingma, D. P. & Ba, J. (2014). Adam: A method for stochastic optimization.