

第 7 章：梯度下降

第 4 节：归一化 (Normalization)

《深度学习基础》课程小组

2026 年 10 月 7 日

目录

- 1 引言
- 2 输入数据归一化
- 3 批归一化
- 4 层归一化
- 5 总结
- 6 参考文献

1. 为什么需要归一化?

- 对前向传播中计算的变量进行归一化，消除网络处理极大或极小数值的需要。
- 原则上权重和偏置可适应任何值，但实践中归一化对有效训练至关重要。
- 本节按归一化范围分三类：
 - 输入数据归一化：跨输入数据
 - 批归一化：跨小批量
 - 层归一化：跨层

归一化为何至关重要?

- 统一输入量纲，避免特征主导偏差
- 加速收敛，提升训练效率
- 缓解梯度消失与爆炸问题
- 降低对初始化和超参数的敏感性
- 支持更深网络结构的训练

2. 数据归一化 (Data Normalization)

- 实际问题中，不同输入变量可能跨越**差异极大的范围**。
- 例如健康数据：身高 1.8 m vs 血小板 $300,000/\mu\text{L}$ 。
- 这种差异使梯度下降训练**变得困难**。

为什么困难？

单层回归网络中，若两个输入范围差异大：

- 一个权重的变化引起的输出变化远大于另一个。
- 对应误差曲面沿不同轴有**非常不同的曲率** (图 7.3)。

2.1 输入归一化的步骤

- ① 计算每个输入的均值和方差 (训练前一次性完成):

$$\mu_i = \frac{1}{N} \sum_{n=1}^N x_{ni} \quad (7.48)$$

$$\sigma_i^2 = \frac{1}{N} \sum_{n=1}^N (x_{ni} - \mu_i)^2 \quad (7.49)$$

- ② 重新缩放输入:

$$\tilde{x}_{ni} = \frac{x_{ni} - \mu_i}{\sigma_i} \quad (7.50)$$

使 $\{\tilde{x}_{ni}\}$ 具有零均值和单位方差。

- 重要: 必须用相同的 μ_i 和 σ_i 预处理开发集、验证集、测试集。

2.2 开发集、验证集、测试集的区别

数据集	功能
开发集/验证集	训练中调整超参数、选择模型架构、决定是否停止训练
测试集	最终评估泛化性能，训练和调参过程中不可见

- 三者必须保持数据分布一致，且不能相互重叠。
- 若训练集与测试集来源不同（如网络图片 vs 手机拍摄），部署时性能可能骤降。

3. 批归一化 (Batch Normalization)

- 将输入归一化的思路应用到**每个隐藏层**。
- 若某隐藏层激活值范围差异大，归一化为零均值和单位方差使**下一层学习更容易**。
- 与输入归一化不同：隐藏单元归一化需在**每次权重更新后重复**。
- 这被称为**批归一化** (Ioffe and Szegedy, 2015)。

另一个动机：梯度消失与爆炸

由链式法则，第一层参数的梯度是大量雅可比矩阵元素的乘积：

$$\frac{\partial E}{\partial w_i} = \sum_m \cdots \sum_l \sum_j \frac{\partial z_m^{(1)}}{\partial w_i} \cdots \frac{\partial z_j^{(K)}}{\partial z_l^{(K-1)}} \frac{\partial E}{\partial z_j^{(K)}} \quad (7.51)$$

若大多数项幅值 $< 1 \rightarrow$ 梯度趋于 0；若 $> 1 \rightarrow$ 趋于 ∞ 。

3.1 批归一化的定义

考虑多层网络中特定层，对预激活值 a_i 进行归一化。对小批量大小 K ：

$$\mu_i = \frac{1}{K} \sum_{n=1}^K a_{ni} \quad (7.52)$$

$$\sigma_i^2 = \frac{1}{K} \sum_{n=1}^K (a_{ni} - \mu_i)^2 \quad (7.53)$$

$$\hat{a}_{ni} = \frac{a_{ni} - \mu_i}{\sqrt{\sigma_i^2 + \delta}} \quad (7.54)$$

- δ 是小常数，避免 σ_i^2 很小时的数值问题。

3.2 可学习的重缩放参数

- 归一化减少了该层参数的自由度，降低表示能力。
- 通过重缩放补偿：

$$\tilde{a}_{ni} = \gamma_i \hat{a}_{ni} + \beta_i \quad (7.55)$$

- β_i 和 γ_i 是自适应参数，与权重和偏置一起通过梯度下降联合学习。
- 这些可学习参数是批归一化与输入归一化的关键区别。

3.3 批归一化 vs 输入归一化

维度	输入归一化	批归一化
归一化对象	输入层特征	隐藏层预激活值
计算时机	训练前一次性	每个小批量动态计算
可学习参数	无	β_i (均值)、 γ_i (标准差)
推理阶段	使用固定统计量	使用训练期间记录的移动平均值
解决痛点	输入量纲不一致	梯度消失/爆炸, 深层网络训练

3.4 为什么可学习参数更容易训练？

- 变换 (7.55) 看似抵消了归一化效果——均值和方差又可适应任意值。
- **关键区别**：参数在训练中的演变方式。

原始网络：被动演变（间接控制）

均值/方差由该层所有 W 和 b 通过复杂函数决定。
改变分布是更新 W, b 的**副产物**，不受直接控制。

批归一化：主动演变（直接控制）

均值/方差由**独立参数** β_i, γ_i 直接决定。
梯度下降有直接路径更新它们，**解耦**了“控制分布”与“拟合特征”的任务。

3.5 批归一化作为网络层

- 公式 (7.52)–(7.55) 关于 β_i, γ_i 可微。
- 可视为神经网络中的附加层：每个标准隐藏层后可跟一个批归一化层。
- 在代码中只需像普通层一样添加（如 `'BatchNorm1d()'`）。
- 反向传播时框架自动计算并更新 β 和 γ 。

3.6 推理阶段的移动平均

- 推理时没有训练小批量，无法从单个样本确定均值和方差。
- 原则上可对全训练集计算，但代价过高。
- 替代方案：训练期间计算移动平均值：

$$\bar{\mu}_i^{(\tau)} = \alpha \bar{\mu}_i^{(\tau-1)} + (1 - \alpha) \mu_i \quad (7.56)$$

$$\bar{\sigma}_i^{(\tau)} = \alpha \bar{\sigma}_i^{(\tau-1)} + (1 - \alpha) \sigma_i \quad (7.57)$$

- 这些移动平均值训练时不起作用，仅在推理阶段处理新数据点。

3.7 批归一化为何有效?

- 实践中非常有效，但**内在原因仍有不确定性**。
- **最初动机**：内部协变量偏移 (internal covariate shift)
 - 较早层权重更新改变后续层看到的数值分布。
- **后续研究** (Santurkar et al., 2018):
 - 协变量偏移**不是关键因素**。
 - 训练提升实际源于**误差函数曲面平滑度的改善**。

4. 层归一化 (Layer Normalization)

- 批归一化的问题：
 - 批量太小时，均值和方差估计过于嘈杂。
 - 大批量可能分配到不同 GPU，全局归一化效率低。
- 替代方案：对每个数据点，跨该层所有隐藏单元值进行归一化。
- 这被称为层归一化 (Ba, Kiros, and Hinton, 2016)。
- 最初用于循环神经网络（每时间步分布变化，批归一化不可行）。
- 在Transformer 等架构中同样有用。

4.1 层归一化的定义

与批归一化类似，进行如下变换：

$$\mu_n = \frac{1}{M} \sum_{i=1}^M a_{ni} \quad (7.58)$$

$$\sigma_n^2 = \frac{1}{M} \sum_{i=1}^M (a_{ni} - \mu_n)^2 \quad (7.59)$$

$$\hat{a}_{ni} = \frac{a_{ni} - \mu_n}{\sqrt{\sigma_n^2 + \delta}} \quad (7.60)$$

- 求和 $i = 1, \dots, M$ 在**该层所有隐藏单元**上进行。
- 与批归一化一样，为每个隐藏单元引入可学习的 β_i 和 γ_i (公式 7.55)。
- **关键优势**：训练和推理使用**相同**的归一化函数，**无需存储移动平均值**。

4.2 三种归一化的核心对比

维度	输入归一化	批归一化	层归一化
归一化对象	输入层特征	隐藏层预激活值	隐藏层预激活值
归一化方向	跨所有样本，对每个特征	跨小批量样本，对每个隐藏单元	跨隐藏单元，对每个数据点
可学习参数	无	β_i, γ_i	β_i, γ_i
推理阶段	固定统计量	移动平均值	与训练相同
需要移动平均	否	是	否
对小批量依赖	否	是	否
典型应用	数据预处理	CNN 等前馈网络	RNN、Transformer

5. 本节总结

- **归一化**对确保有效训练至关重要，消除网络处理极大/极小值的需求。
- **输入数据归一化**：训练前一次性计算，使各输入具有零均值和单位方差。
- **批归一化**：
 - 对每个隐藏单元跨小批量归一化预激活值。
 - 引入可学习参数 β_i, γ_i 补偿表示能力损失。
 - 缓解梯度消失/爆炸，使训练极深网络成为可能。
 - 推理阶段使用训练期间记录的移动平均值。
- **层归一化**：
 - 对每个数据点跨隐藏单元归一化。
 - 不依赖小批量，训练和推理使用相同函数。
 - 适用于 RNN、Transformer 等序列模型。

6. 参考文献

- 教材: Bishop, C. M. & Bishop, H. (2023). Deep Learning Foundations and Concepts. Springer Nature Switzerland AG.
- Ioffe, S. & Szegedy, C. (2015). Batch normalization: Accelerating deep network training by reducing internal covariate shift.
- Santurkar, S. et al. (2018). How does batch normalization help optimization?
- Ba, J. L., Kiros, J. R., & Hinton, G. E. (2016). Layer normalization.