

第 9 章：正则化

第 1 节：归纳偏置 (Inductive Bias)

《深度学习基础》课程小组

2026 年 10 月 7 日

目录

- 1 模型选择与归纳偏置
- 2 没有免费午餐定理
- 3 对称性与不变性
- 4 等变性
- 5 总结
- 6 参考文献

1. 模型选择：偏差-方差权衡

- 多项式回归实验：中等复杂度的模型泛化误差最小。
- 正则化实验：中等 λ 值给出最佳预测。
- 偏差-方差分解的启示：
 - 高偏差的简单模型：无法捕捉数据生成过程的变化
 - 低偏差的灵活模型：容易过拟合，泛化差
- 数据量增大 $\Rightarrow$ 可使用更灵活（更低偏差）的模型而不产生过大方差。
- 实践中还需考虑内存、执行速度等因素，但本节聚焦泛化性能。

1.1 逆问题 (Inverse Problems)

- 模型选择问题的根源：大多数机器学习任务是**逆问题**。
- **正问题**：给定条件分布 $p(t|x)$ ，从有限输入点采样对应目标值——简单直接。
- **逆问题**：仅给定有限样本，**推断整个分布**。
- 逆问题本质上是**不适定** (ill-posed) 的：
 - 有无限多个分布可能生成了观测到的训练数据。
 - 任何在观测目标值处具有非零概率密度的分布都是候选。

1.2 归纳偏置 (Inductive Bias)

- 为了对新 x 做预测，需要从无限可能中**选择特定分布**。
- 对某种选择的偏好称为**归纳偏置**或**先验知识**。
- 先验知识可来自背景信息，帮助约束解空间。

常见归纳偏置示例

- **平滑性**：输入的小变化应导致输出的小变化。
- 正则化项 (9.1) 鼓励小权重 $\Rightarrow$ 偏向变化更慢的函数。
- **平移不变性**：图像中物体的身份与其位置无关。
- **注意**：不要引入与数据生成过程不一致的偏置或约束。
- 例如：假设线性关系而实际存在显著非线性 $\Rightarrow$ 系统产生不准确答案。

1.3 迁移学习与多任务学习

- 迁移学习和多任务学习可从正则化视角理解。
- 当某任务训练数据有限时，可使用相关任务的额外数据帮助确定参数。
- 任务间相似性的假设是一种更复杂的归纳偏置形式。
- 这解释了使用额外数据带来的性能提升。

2. 没有免费午餐定理 (No Free Lunch)

- 深度神经网络是高度灵活模型，已革新众多领域。
- 看似是能解决所有任务的“通用”学习算法。
- 但即使非常灵活的神经网络也包含重要的归纳偏置。
- 例如：CNN 编码了平移等变性等归纳偏置，对图像应用特别有用。

定理内容 (Wolpert, 1996)

在所有可能问题上平均而言，每个学习算法都一样好。
若某算法在某些问题上优于平均，必在其他问题上劣于平均。

2.1 定理的理论性与实际意义

- 定理中的“所有可能问题”包含**非常不符合实际**的输入-输出关系。
- 大多数实际问题展现某种程度的**平滑性**:
 - 输入的小变化大多对应目标的小变化。
- 神经网络及大多数广泛使用的机器学习技术都展现这种归纳偏置，因此具有**广泛适用性**。

核心启示

尽管定理偏理论，但它强调了**偏置在决定算法性能中的核心重要性**。

- 偏置可以是**隐式**的：如神经网络参数有限，限制了可表示的函数。
- 偏置也可以是**显式**的：如反映特定问题先验知识的编码。

2.2 通用算法与专用偏置

- 寻找通用学习算法，实质是寻找**适合广泛应用的归纳偏置**。
- 对特定应用，若能融入**更强的专用归纳偏置**，可获得更好结果。
- **基于模型的机器学习** (Winn et al., 2023):
 - 倡导将机器学习模型中的所有假设**显式化**。
 - 以便为归纳偏置做出适当选择。
- 归纳偏置的引入方式：
 - 通过**分布形式**（如输出是固定基函数的线性函数）
 - 通过**正则化项**
 - 通过**训练过程本身**
- 深层网络即使参数多于数据点，只要训练过程设置正确，也能给出良好泛化。
- 将深度学习应用于实际问题的部分技巧在于**精心设计归纳偏置**。

3. 对称性与不变性 (Symmetry & Invariance)

- 许多应用中，预测应在输入变量的一个或多个变换下保持不变（不变性）。
- **平移不变性**：物体在图像中的位置不影响其分类。
- **尺度不变性**：物体大小的变化不影响其分类。
- 利用这些对称性创建归纳偏置可大幅提升性能。
- 这是几何深度学习 (Bronstein et al., 2021) 的主题。

3.1 群论基础

- 保持特定属性不变的变换（如平移、缩放）代表**对称性**。
- 对应某对称性的所有变换构成**群** (group)。
- 群由元素集合 $\mathcal{A}, \mathcal{B}, \mathcal{C}, \dots$ 和二元运算 $\circ$ 组成。

群的四大公理

- 封闭性**: $A \circ B$ 仍在集合中。
- 结合律**: $(A \circ B) \circ C = A \circ (B \circ C)$ 。
- 单位元**: 存在 $\mathcal{I}$ 使得 $A \circ \mathcal{I} = \mathcal{I} \circ A = A$ 。
- 逆元**: 存在 A^{-1} 使得 $A \circ A^{-1} = A^{-1} \circ A = \mathcal{I}$ 。

- 简单例子：正方形旋转 90° 的倍数；二维平面中物体的连续平移。

3.2 从数据中学习不变性的困难

- 原则上，神经网络对输入变换的不变性可**从数据中学习**，无需特殊修改。
- 实践中极具挑战：
 - 变换可导致原始数据**显著变化**。
 - 例如：图像中物体即使平移几个像素，像素值也会大幅改变。
 - 多种不变性常需**同时成立**：二维平移、缩放、旋转、强度变化、色彩平衡等。
 - 这些变换的组合**呈指数级**，所需训练集大小**不可承受**。

3.3 实现不变性的四类方法

- ① **预处理**: 计算在所需变换下不变的特征。后续系统使用这些特征作为输入, 自然尊重这些不变性。
- ② **正则化误差函数**: 在误差函数中添加正则化项, 惩罚输入受不变变换时模型输出的变化。
- ③ **数据增强**: 用变换后的训练数据副本扩展训练集, 携带与未变换样本相同的目标值。
- ④ **网络结构**: 通过适当的网络架构选择, 将不变性性质构建到网络结构中。

3.4 方法一：预处理

- **挑战**：设计具有所需不变性的特征，同时**不丢弃**对确定网络输出有用的信息。
- 固定的手工特征能力有限。
- 已被深度神经网络获得的**学习表示**所取代。

3.5 方法二：正则化误差函数

- 示例：切线传播 (tangent propagation, Simard et al., 1992)。
- 训练时向误差函数添加正则化项。
- 直接惩罚由对应不变变换的输入变化引起的输出变化。
- 局限：
 - 增加训练复杂度。
 - 难以处理小变换 (如小于一个像素的平移)。

3.6 方法三：数据增强

- 通常**易于实现**，实践中非常有效。
- 常用于图像分析，因为创建变换后的训练数据很直接。
- 示例变换（图 9.1）：
 - 水平翻转、缩放、平移、旋转
 - 亮度对比度变化、加性噪声、颜色偏移
- 医学软组织图像：还可包括连续“**橡皮布**”变形。

训练算法中的实现

- **顺序算法**（如 SGD）：每次呈现前变换输入，可每次应用不同变换。
- **批量方法**：复制每个数据点若干次，独立变换每个副本。

3.7 数据增强的理论分析

- 考虑代表原始样本小变化的变换，对误差函数做**泰勒展开**。
- 得到正则化误差函数，其中正则化项惩罚网络输出对输入的梯度在**变换方向上的投影**。
- 与切线传播技术相关。
- **特殊情况**：变换为添加随机噪声时，正则化项惩罚网络输出对输入的导数。
- 直观合理：鼓励网络输出在输入加噪时保持不变。

3.8 方法四：网络结构

- 将不变性构建到网络结构中，已被证明**非常强大有效**。
- 带来其他关键好处。
- 将在计算机视觉的**卷积神经网络**背景下详细讨论。

4. 等变性 (Equivariance)

- 不变性的重要推广：等变性。
- 输入变换时，输出不是保持不变，而是按特定方式变换。
- 示例：图像分割网络。
 - 输入：图像 I
 - 输出：每个像素分类为前景物体或背景的分割
 - 若物体位置平移，希望对应分割也同样平移
- 用 S 表示分割网络， $\mathcal{T}$ 表示平移操作：

$$S(\mathcal{T}(I)) = \mathcal{T}(S(I)) \quad (9.2)$$

- 平移图像的分割 = 原图像分割的平移 (图 9.2)。

4.1 广义等变性

更一般地，输出变换可与输入变换不同：

$$\mathcal{S}(\mathcal{T}(\mathbf{I})) = \tilde{\mathcal{T}}(\mathcal{S}(\mathbf{I})) \quad (9.3)$$

- **示例 1：**分割图像分辨率低于原图。
 - $\mathcal{T}$ ：原图空间中的平移
 - $\tilde{\mathcal{T}}$ ：低维分割空间中对应的平移
- **示例 2：** $\mathcal{S}$ 测量物体方向， $\mathcal{T}$ 表示旋转（对像素值的复杂非线性变换）。
 - $\tilde{\mathcal{T}}$ 会增减 $\mathcal{S}$ 生成的标量方向值

4.2 不变性是等变性的特例

- 不变性是等变性中输出变换为单位变换的特殊情况。
- 示例：分类网络 $\mathcal{C}$ 和翻译操作 $\mathcal{T}$ ：

$$\mathcal{C}(\mathcal{T}(\mathbf{I})) = \mathcal{C}(\mathbf{I}) \quad (9.4)$$

- 物体类别不依赖于其在图像中的位置。

总结

- 不变性： $f(\mathcal{T}(x)) = f(x)$
- 等变性： $f(\mathcal{T}(x)) = \tilde{\mathcal{T}}(f(x))$
- 不变性是等变性在 $\tilde{\mathcal{T}} = \mathcal{I}$ 时的特例

5. 本节总结

- **模型选择**是机器学习的核心问题，源于大多数任务是**逆问题**。
- **归纳偏置**：从无限可能中选择特定分布的偏好，即先验知识。
- **没有免费午餐定理**：所有算法在所有问题上平均一样好，但实际问题具有结构（如平滑性）。
- 偏置可以是**隐式**（如参数有限）或**显式**（如先验知识编码）。
- **对称性与不变性**：
 - 平移不变性、尺度不变性
 - 群论：封闭性、结合律、单位元、逆元
 - 从数据直接学习不变性困难（指数级变换组合）
- **实现不变性的四类方法**：
 - ① 预处理
 - ② 正则化误差函数（切线传播）
 - ③ 数据增强
 - ④ 网络结构（CNN）
- **等变性**：输出随输入变换而特定变换，不变性是其特例。

6. 参考文献

- 教材: Bishop, C. M. & Bishop, H. (2023). Deep Learning Foundations and Concepts. Springer Nature Switzerland AG.
- Wolpert, D. H. (1996). The lack of a priori distinctions between learning algorithms.
- Bronstein, M. M. et al. (2021). Geometric deep learning: Grids, groups, graphs, geodesics, and gauges.
- Simard, P. et al. (1992). Tangent prop - A formalism for specifying selected invariances in an adaptive network.
- Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation.
- Winn, J. et al. (2023). Model-based machine learning.