

第 9 章：正则化

第 2 节：权重衰减 (Weight Decay)

《深度学习基础》课程小组

2026 年 10 月 7 日

目录

- 1 权重衰减基础
- 2 一致性正则化
- 3 广义权重衰减
- 4 总结
- 5 参考文献

1. 权重衰减：控制模型复杂度

- 线性回归中引入正则化以控制模型复杂度，作为限制参数数量的替代方案。
- 最简单的正则化项：模型参数的平方和。
- 惩罚大数值的参数。
- 有效模型复杂度由正则化系数 λ 的选择决定。

1.1 概率视角：高斯先验

- 加性正则化项可解释为权重向量 w 上零均值高斯先验的负对数。
- 这提供了将先验知识纳入模型训练的概率视角。
- 但问题在于：
 - 先验表达在模型参数上。
 - 领域知识更可能表达在从输入到输出的网络函数上。
 - 参数与网络函数的关系极其复杂。
 - 因此只有非常有限类型的先验知识能直接表达为参数先验。

1.2 为什么叫“权重衰减”？

- 平方和正则化在机器学习文献中称为**权重衰减**。
- 原因：在顺序学习算法中，它鼓励权重值**向零衰减**，除非数据支持。
- 优点**：导数容易计算，便于梯度下降训练。
- 对于 (9.1) 形式的正则化项，梯度为：


$$\nabla \tilde{E}(\mathbf{w}) = \nabla E(\mathbf{w}) + \lambda \mathbf{w} \quad (9.5)$$

- 注意：1/2 因子在求导时消失（常被约定包含）。

1.3 几何效果：收缩权重

- 考虑二维参数空间 + 二次无正则化误差函数 (图 9.3)。
- 坐标轴旋转以对齐海森矩阵的特征向量。
- 正则化项的效果：收缩权重参数的幅度。
- **关键观察**：对不同参数效果差异很大。
 - w_1 ：输出对其相对不敏感 $\Rightarrow$ 正则化将其推向零。
 - w_2 ：输出对其更敏感 $\Rightarrow$ 正则化影响较小。
- **有效参数数量**：正则化后仍保持“活跃”的参数数量。
- $\lambda \rightarrow \infty$ ：所有参数被驱动为零，有效参数数量为 0。
- $\lambda = 0$ ：有效参数数量等于模型总参数数量。

1.4 误差函数等高线示意图



图：误差函数（红）、正则化项（绿）及其线性组合（蓝）的等高线。

- $\lambda = 0$: 最小误差在 w^* 。
- $\lambda > 0$: 正则化误差的最小值向原点偏移。
- 偏移在 w_1 方向更大（误差对其不敏感）。
- 正则化有效抑制对预测精度影响小的参数。

2. 简单权重衰减的局限性

- 简单权重衰减 (9.1) 破坏了网络映射的某些理想变换性质。
- 考虑两层 MLP, 线性输出单元。

输入线性变换

对输入做线性变换:

$$x_i \rightarrow \tilde{x}_i = ax_i + b \quad (9.8)$$

可通过对应变换隐藏层权重保持网络映射不变:

$$w_{ji} \rightarrow \tilde{w}_{ji} = \frac{1}{a} w_{ji} \quad (9.9)$$

$$w_{j0} \rightarrow \tilde{w}_{j0} = w_{j0} - \frac{b}{a} \sum_i w_{ji} \quad (9.10)$$

2.1 输出变换与一致性要求

输出线性变换

对输出做线性变换：

$$y_k \rightarrow \tilde{y}_k = cy_k + d \quad (9.11)$$

可通过变换第二层权重和偏置实现：

$$w_{kj} \rightarrow \tilde{w}_{kj} = cw_{kj} \quad (9.12)$$

$$w_{k0} \rightarrow \tilde{w}_{k0} = cw_{k0} + d \quad (9.13)$$

- **一致性要求**：用原始数据和变换后数据训练的网络应等价，仅权重差一个线性变换。
- 任何正则化项都应与该性质**一致**，否则会任意偏向某个等价解。
- 简单权重衰减 (9.1) 对所有权重和偏置**一视同仁**，**不满足**该性质。

2.2 一致性正则化项 I

寻找在线性变换 (9.9)(9.10)(9.12)(9.13) 下**不变**的正则化项：

$$\frac{\lambda_1}{2} \sum_{w \in \mathcal{W}_1} w^2 + \frac{\lambda_2}{2} \sum_{w \in \mathcal{W}_2} w^2 \quad (9.14)$$

- $\mathcal{W}_1$ ：第一层权重集合； $\mathcal{W}_2$ ：第二层权重集合。
- **偏置被排除**在求和之外。
- 若重新缩放正则化参数 $\lambda_1 \rightarrow a^{1/2}\lambda_1$ 和 $\lambda_2 \rightarrow c^{-1/2}\lambda_2$ ，该正则化项保持不变。

2.2 一致性正则化项 II

对应的先验分布

$$p(\mathbf{w} \mid \alpha_1, \alpha_2) \propto \exp \left(-\frac{\alpha_1}{2} \sum_{w \in \mathcal{W}_1} w^2 - \frac{\alpha_2}{2} \sum_{w \in \mathcal{W}_2} w^2 \right) \quad (9.15)$$

- 该先验是**非正常**的（无法归一化），因为偏置参数无约束。
- 非正常先验给正则化系数选择和贝叶斯模型比较带来困难。
- 通常为偏置包含**单独的先验**（破坏平移不变性），有自己的超参数。

2.3 四个超参数的效果

- 先验由四个超参数控制：
 - α_1^b : 第一层偏置的精度
 - α_1^w : 第一层权重的精度
 - α_2^b : 第二层偏置的精度
 - α_2^w : 第二层权重的精度
- 效果 (图 9.4):
 - α_2^w : 控制函数的垂直尺度
 - α_1^w : 控制函数值变化的水平尺度
 - α_1^b : 控制变化发生的水平范围
 - α_2^b : 控制函数的垂直偏移范围

2.4 推广：任意分组

更一般地，可将权重分为任意数量的组 $\mathcal{W}_k$ ：

$$\Omega(\mathbf{w}) = \frac{1}{2} \sum_k \alpha_k \|\mathbf{w}\|_k^2 \quad (9.16)$$

其中

$$\|\mathbf{w}\|_k^2 = \sum_{j \in \mathcal{W}_k} w_j^2 \quad (9.17)$$

- 例如：多层网络中可为每一层使用不同的正则化项。

3. 广义权重衰减

简单二次正则化的推广：

$$\Omega(\mathbf{w}) = \frac{\lambda}{2} \sum_{j=1}^M |w_j|^q \quad (9.18)$$

- $q = 2$ ：对应二次正则化 (9.1)。
- 图 9.5 展示了不同 q 值的正则化函数等高线。

Lasso ($q = 1$)

统计文献中称为`lasso` (Tibshirani, 1996)。

- 对二次误差函数，若 λ 足够大，某些系数 w_j 被驱动为零。
- 导致`稀疏模型`：对应基函数不起作用。

3.1 稀疏性的来源

最小化正则化误差函数：

$$E(\mathbf{w}) + \frac{\lambda}{2} \sum_{j=1}^M |w_j|^q \quad (9.19)$$

等价于在约束下最小化无正则化误差函数：

$$\sum_{j=1}^M |w_j|^q \leq \eta \quad (9.20)$$

- 两种方法可通过拉格朗日乘子关联。
- 稀疏性来源见图 9.6：约束下的误差函数最小值。
- λ 增大 $\Rightarrow$ 更多参数被驱动为零。
- 对比：二次正则化保留两个权重参数均为非零值。

3.2 正则化的作用与权衡

- 正则化允许复杂模型在有限规模数据集上训练而不严重过拟合。
- 本质：限制有效模型复杂度。
- 但问题转移了：
 - 从“找到合适的可学习参数数量”
 - 转变为“确定合适的正则化系数 λ 值”
- 模型复杂度问题将在下一节讨论。

4. 本节总结

- **权重衰减**：最简单的正则化项，模型参数平方和。
 - 惩罚大数值参数，控制模型复杂度。
 - 可解释为零均值高斯先验的负对数。
 - 梯度容易计算： $\nabla \tilde{E} = \nabla E + \lambda \mathbf{w}$ 。
- **几何效果**：收缩权重，对输出不敏感的参数被推向零。
- **有效参数数量**：正则化后仍活跃的参数数量。
- **一致性正则化**：
 - 简单权重衰减破坏线性变换性质。
 - 一致性正则化项应对权重缩放和偏置平移不变。
 - 偏置应排除在求和之外，或使用单独先验。
- **广义权重衰减**：
 - $\Omega(\mathbf{w}) = \frac{\lambda}{2} \sum |w_j|^q$
 - $q = 1$ ：lasso，产生**稀疏**模型
 - $q = 2$ ：二次正则化
- 正则化将模型复杂度问题**转移**到正则化系数选择。

5. 参考文献

- 教材: Bishop, C. M. & Bishop, H. (2023). Deep Learning Foundations and Concepts. Springer Nature Switzerland AG.
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso.
- Bishop, C. M. (2006). Pattern Recognition and Machine Learning. Springer.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning.