

第 9 章：正则化

第 3 节：学习曲线 (Learning Curves)

《深度学习基础》课程小组

2026 年 10 月 7 日

目录


- ① 学习曲线基础
- ② 早停法
- ③ 双下降
- ④ 总结
- ⑤ 参考文献

1. 学习曲线：训练过程的可视化

- 泛化性能受多种因素影响：
 - 模型参数数量
 - 数据集大小
 - 权重衰减正则化系数
- 每个因素都在**偏差-方差**之间进行权衡。
- 另一个影响权衡的因素：**学习过程本身**。
- 梯度下降优化中：
 - 训练误差通常随参数更新而**下降**
 - 留出数据误差可能**非单调**
- **学习曲线**：绘制训练集和验证集误差随迭代次数的变化。
- 提供训练进展的洞察，以及控制有效模型复杂度的实用方法。

2. 早停法 (Early Stopping)

- 控制网络有效复杂度的另一种方法。
- 深度学习训练：迭代减少训练集上的误差函数。
- **典型行为：**
 - 训练集误差：随迭代次数大致单调下降
 - 验证集误差：先下降，后上升（网络开始过拟合）
- **策略：**在验证集误差最小点停止训练。




图：训练集误差（左）和验证集误差（右）随迭代步数的变化。

2.1 早停法与有效参数数量

- 学习曲线行为可用有效参数数量定性解释。
- 有效参数数量：
 - 训练开始时较小
 - 随训练增长
 - 对应模型有效复杂度的稳定增加
- 在训练误差达到最小值之前停止训练 = 限制有效模型复杂度。

2.2 早停法与权重衰减的等价性 I

对二次误差函数，早停法与简单权重衰减行为相似 (Bishop, 1995a)。



图：早停法为何能给出与权重衰减相似的结果。

- 权重空间坐标轴旋转以对齐海森矩阵特征向量。

2.2 早停法与权重衰减的等价性 II

- 无权重衰减时，权重从原点出发沿负梯度方向移动：
 - 先平行于 w_2 轴移动，经过 $\bar{w}$ 附近
 - 然后移向误差函数最小值 w_{ML}
- 在 $\bar{w}$ 附近停止 $\approx$ 权重衰减。
- **关键关系**： τ/η 类似于正则化参数 λ 的倒数。
- 有效参数数量在训练过程中**增长**。

3. 双下降 (Double Descent)

- 经典偏差-方差权衡：
 - 参数太少：高偏差，测试误差大
 - 参数增加：测试误差下降
 - 参数过多：高方差，测试误差再次上升
- 经典统计学的传统观念：模型参数数量需根据数据集大小限制。
- 但现代深度神经网络相反：
 - 即使参数数量远超完美拟合训练数据所需，仍能表现优异。
 - 深度学习界的普遍智慧：更大的模型更好。
 - 模型可训练到零误差，仍能在测试数据上表现良好。

3.1 双下降现象

- 看似矛盾的现象可通过**双下降**调和 (Belkin et al., 2019)。
- 图 9.9: ResNet18 在图像分类任务上的训练集和测试集误差 vs 模型复杂度。
- **观察:**
 - 训练误差: 随复杂度增加**单调下降**
 - 测试误差: 先下降, 再上升, **最后再次下降**
 - 即使训练误差达到零后, 测试误差仍继续下降




图: ResNet18 的训练误差与测试误差 vs 模型复杂度。

3.2 双下降的两个区域

- 比经典偏差-方差讨论更复杂，展现两个不同区域：
 - ① 经典区域 (小到中等复杂度)：经典偏差-方差权衡。
 - ② 现代区域 (非常大模型)：测试误差进一步下降。
- 两区域过渡大致发生在：
 - 模型参数足够多，能够精确拟合训练数据。
- Nakkiran et al. (2019) 定义有效模型复杂度：
 - 模型能实现零训练误差的最大训练集大小。
 - 双下降出现在有效模型复杂度超过训练集数据点数时。

3.3 早停法与双下降

- 用**早停法**控制模型复杂度时也观察到类似行为（图 9.10）。
- 增加训练轮数 $\Rightarrow$ 增加有效模型复杂度。
- 对足够大的模型，再次观察到双下降。
- 此类模型有许多可能解，包括**过拟合**的解。
- 似乎是**随机梯度下降**的隐式偏置导致良好泛化性能。




图: ResNet18 的测试误差 vs 训练轮数。

3.4 正则化与双下降


- 用正则化项控制复杂度时也有类似结果。
- 大模型训练至收敛的测试误差 vs $1/\lambda$ (正则化参数倒数):
 - 高 $\lambda \Rightarrow$ 低复杂度
 - 观察到双下降现象 (Yilmaz and Heckel, 2022)

核心洞察

双下降是模型复杂度与泛化性能关系的更完整描述。
经典偏差-方差权衡只是其中一部分。

3.5 双下降的反直觉推论

- **讽刺性推论**：可能存在增加训练数据反而**降低性能**的区域。
- 与传统观点“更多数据总是好事”相反。
- 对处于**临界区域**的模型：
 - 增加训练集大小可能将插值阈值**向右推**。
 - 导致更高的测试集误差。
- 图 9.11：Transformer 模型测试误差 vs 嵌入维度。
 - 训练集从 4,000 增加到 18,000：整体曲线大幅下降。
 - 但对某些中间嵌入维度（临界复杂度区域），增加数据量反而**降低泛化性能**。



图：Transformer 模型的测试误差 vs 嵌入维度。

4. 本节总结

- **学习曲线**：训练集和验证集误差随迭代次数的变化。
- **早停法**：
 - 在验证集误差最小点停止训练。
 - 有效参数数量在训练中增长。
 - 与权重衰减相似： $\tau/\eta \sim 1/\lambda$ 。
- **双下降**：
 - 测试误差 vs 模型复杂度：先降、再升、**最后再降**。
 - 两个区域：经典偏差-方差区域 + 现代大模型区域。
 - 过渡点：模型刚好能**精确拟合训练数据**。
 - 有效模型复杂度超过训练集大小时出现。
- **反直觉推论**：临界区域增加数据可能降低性能。
- **SGD 的隐式偏置**：即使模型可过拟合，SGD 仍导致良好泛化。
- 现代深度学习：**更大模型往往更好**，与经典统计学观念不同。

5. 参考文献

- 教材: Bishop, C. M. & Bishop, H. (2023). Deep Learning Foundations and Concepts. Springer Nature Switzerland AG.
- Bishop, C. M. (1995a). Regularization and complexity control in feed-forward networks.
- Belkin, M. et al. (2019). Reconciling modern machine-learning practice and the classical bias–variance trade-off.
- Nakkiran, P. et al. (2019). Deep double descent: Where bigger models and more data hurt.
- Zhang, C. et al. (2016). Understanding deep learning requires rethinking generalization.
- Yilmaz, F. F. & Heckel, R. (2022). Regularization-wise double descent.