

第 9 章：正则化

第 4 节：参数共享 (Parameter Sharing)

《深度学习基础》课程小组

2026 年 10 月 7 日

目录

- ① 硬权重共享
- ② 软权重共享
- ③ 扩展应用
- ④ 总结
- ⑤ 参考文献

1. 硬权重共享 (Hard Weight Sharing)

- L_2 正则化 $\|\mathbf{w}\|^2$: 鼓励权重接近零来减少过拟合。
- **另一种减少网络复杂度的方法**: 对权重施加**硬约束**。
 - 将权重分组
 - 要求每组内所有权重**共享相同的值**
 - 共享值从数据中学习
- 这被称为**权重共享**、**参数共享**或**参数绑定**。
- 效果: **自由度数量小于网络中连接的数量**。
- 通常作为编码**归纳偏置**的方式, 表达已知的不变性。

1.1 硬权重共享的实现与局限

- 此类网络的误差函数梯度计算：
 - 可通过反向传播的小修改完成。
 - 实际上通过自动微分隐式处理。
- 将在卷积神经网络中广泛使用参数共享。
- **局限**：参数共享仅适用于约束形式可预先指定的特定问题。

2. 软权重共享 (Soft Weight Sharing)

- 不用硬约束强制参数相等，Nowlan and Hinton (1992) 提出软权重共享。
- 正则化项鼓励成组的权重具有相似的值。
- 所有内容都从学习中确定：
 - 权重如何分组
 - 每组的均值
 - 组内值的散布

2.1 高斯混合先验 I

- 简单权重衰减 = 权重上零均值高斯先验的负对数。
- 鼓励所有权重收敛到单一值零。
- **推广**：使用高斯混合分布，鼓励权重形成多个组。
- 混合模型的参数全部作为可调参数：
 - 均值 $\{\mu_j\}$
 - 方差 $\{\sigma_j^2\}$
 - 混合系数 $\{\pi_j\}$

2.1 高斯混合先验 II

概率密度与正则化函数

$$p(\mathbf{w}) = \prod_i \left\{ \sum_{j=1}^K \pi_j \mathcal{N}(w_i \mid \mu_j, \sigma_j^2) \right\} \quad (9.21)$$

$$\Omega(\mathbf{w}) = - \sum_i \ln \left(\sum_{j=1}^K \pi_j \mathcal{N}(w_i \mid \mu_j, \sigma_j^2) \right) \quad (9.22)$$

总误差函数：

$$\tilde{E}(\mathbf{w}) = E(\mathbf{w}) + \lambda \Omega(\mathbf{w}) \quad (9.23)$$

2.2 后验概率与权重梯度

- 对权重 $\{w_i\}$ 和混合模型参数 $\{\pi_j, \mu_j, \sigma_j\}$ **联合最小化**误差。
- 使用梯度下降，需计算 $\Omega(\mathbf{w})$ 对所有可学习参数的导数。
- 将 $\{\pi_j\}$ 视为**先验概率**，引入**后验概率**（贝叶斯定理）：

$$\gamma_j(w_i) = \frac{\pi_j \mathcal{N}(w_i | \mu_j, \sigma_j^2)}{\sum_k \pi_k \mathcal{N}(w_i | \mu_k, \sigma_k^2)} \quad (9.24)$$

- 总误差函数对权重的导数：

$$\frac{\partial \tilde{E}}{\partial w_i} = \frac{\partial E}{\partial w_i} + \lambda \sum_j \gamma_j(w_i) \frac{(w_i - \mu_j)}{\sigma_j^2} \quad (9.25)$$

- 效果：将每个权重**拉向第 j 个高斯的中心**，力的大小正比于该高斯对给定权重的后验概率。

2.3 高斯中心、方差与混合系数的梯度

高斯中心的导数：

$$\frac{\partial \tilde{E}}{\partial \mu_j} = \lambda \sum_i \gamma_j(w_i) \frac{(\mu_j - w_i)}{\sigma_j^2} \quad (9.26)$$

- 直观解释：将 μ_j 推向权重的**加权平均**，权重为后验概率。

方差：引入 $\sigma_j^2 = \exp(\xi_j)$ 确保正值，对 $\{\xi_j\}$ 无约束最小化：

$$\frac{\partial \tilde{E}}{\partial \xi_j} = \frac{\lambda}{2} \sum_i \gamma_j(w_i) \left(1 - \frac{(w_i - \mu_j)^2}{\sigma_j^2} \right) \quad (9.28)$$

- 将 σ_j 推向权重围绕中心 μ_j 的**加权平均平方偏差**。

2.4 混合系数的约束与梯度

混合系数需满足约束：

$$\sum_j \pi_j = 1, \quad 0 \leq \pi_i \leq 1 \quad (9.29)$$

用softmax函数表达：

$$\pi_j = \frac{\exp(\eta_j)}{\sum_{k=1}^K \exp(\eta_k)} \quad (9.30)$$

对 $\{\eta_j\}$ 的导数：

$$\frac{\partial \tilde{E}}{\partial \eta_j} = \lambda \sum_i (\pi_j - \gamma_j(w_i)) \quad (9.31)$$

- π_j 被驱动向混合分量 j 的**平均后验概率**。

3. 软权重共享的扩展：生成与判别模型结合

- Lasserre, Bishop, and Minka (2006) 提出**有原则的方法**：
 - 结合**生成模型**的无监督训练
 - 与对应**判别模型**的监督训练
- **适用场景**：有大量**无标签数据**，但有**有标签数据**稀缺。

两种模型的优势互补

- **生成模型**：所有数据（含无标签）都可用于确定参数。
- **判别模型**：在**模型误设定**时能获得更好泛化。
 - 模型误设定：模型未精确描述生成数据的真实分布（通常是这种情况）。
- 通过引入两模型参数的**软绑定**，获得**混合方法**：
 - 对模型误设定**鲁棒**
 - 同时受益于**无标签数据**的训练

4. 本节总结

- **硬权重共享**:
 - 将权重分组，要求组内共享相同值。
 - 自由度数量小于连接数量。
 - 编码归纳偏置，表达已知不变性。
 - 通过反向传播小修改或自动微分实现。
 - 局限：仅适用于约束形式可预先指定的问题。
- **软权重共享**:
 - 正则化项鼓励成组权重具有相似值。
 - 分组、均值、散布都从学习中确定。
 - 使用**高斯混合先验**:
 - 权重被拉向高斯中心，力正比于后验概率。
 - 中心被推向权重的加权平均。
 - 方差被推向加权平均平方偏差。
 - 混合系数被推向平均后验概率。
- **扩展应用**：生成模型 + 判别模型的软绑定。
 - 适用于无标签数据多、有标签数据少的场景。
 - 对模型误设定鲁棒，同时受益于无标签数据。

5. 参考文献

- 教材: Bishop, C. M. & Bishop, H. (2023). Deep Learning Foundations and Concepts. Springer Nature Switzerland AG.
- Nowlan, S. J. & Hinton, G. E. (1992). Simplifying neural networks by soft weight-sharing.
- Lasserre, J. A., Bishop, C. M., & Minka, T. P. (2006). Principled hybrids of generative and discriminative models.