

第 9 章：正则化

第 5 节：残差连接 (Residual Connections)

《深度学习基础》课程小组

2026 年 10 月 7 日

目录

- 1 深度网络的挑战
- 2 残差连接
- 3 残差连接的效果
- 4 实现细节
- 5 总结
- 6 参考文献

1. 深度网络的训练困难

- 深度神经网络的表示能力很大程度上源于**多层处理**。
- 增加层数可**显著提升泛化性能**。
- 批归一化 + 仔细初始化可帮助解决**梯度消失/爆炸**问题。
- **但即使有批归一化**，训练很多层的网络仍然越来越困难。

1.1 破碎梯度 (Shattered Gradients)

- 对这一现象的一种解释：**破碎梯度**。
- 神经网络的表示能力随深度**指数级增长**。
- ReLU 激活函数：网络可表示的**线性区域数量指数级增长**。
- **后果**：误差函数梯度中的**不连续性激增**。
- 图 9.12：输出对输入的导数（雅可比）作为输入的函数。
- 由链式法则，这些导数决定了误差函数曲面的梯度。
- **观察**：
 - 深层网络中，早期层权重的**极小变化**可导致梯度的**显著变化**。
 - 基于梯度的迭代优化假设梯度在参数空间中**平滑变化**。
 - 破碎梯度效应使极深网络的训练**失效**。

2. 残差连接 (Residual Connections)

- 对网络架构的重要修改，极大帮助训练极深网络 (He et al., 2015)。
- 是跳跃层连接 (skip-layer connections) 的一种特殊形式。
- 考虑三层网络：

$$\mathbf{z}_1 = \mathbf{F}_1(\mathbf{x}) \quad (9.32)$$

$$\mathbf{z}_2 = \mathbf{F}_2(\mathbf{z}_1) \quad (9.33)$$

$$\mathbf{y} = \mathbf{F}_3(\mathbf{z}_2) \quad (9.34)$$

- $\mathbf{F}_i(\cdot)$ 可以是线性变换 + ReLU，或更复杂的多层结构。
- 残差连接：将每个函数的输入加回输出：

$$\mathbf{z}_1 = \mathbf{F}_1(\mathbf{x}) + \mathbf{x} \quad (9.35)$$

$$\mathbf{z}_2 = \mathbf{F}_2(\mathbf{z}_1) + \mathbf{z}_1 \quad (9.36)$$

$$\mathbf{y} = \mathbf{F}_3(\mathbf{z}_2) + \mathbf{z}_2 \quad (9.37)$$

2.1 残差块与残差网络

- **残差块**：函数与残差连接的组合，如 $F_1(x) + x$ 。
- **残差网络** (ResNet)：多个残差块串联。
- 残差块可轻松生成**恒等变换**：
 - 若非线性函数参数足够小，使函数输出接近零。

“残差” 的含义

每个块中，函数学习的是**恒等映射与期望输出之间的残差**：

$$F_i(z_{i-1}) = z_i - z_{i-1} \quad (9.38)$$

- 残差网络中的梯度对输入值的**敏感度远低于**标准深层网络（图 9.12(c)）。

3. 更平滑的误差曲面

- Li et al. (2017) 开发了直接可视化误差曲面的方法。
- 结果显示：残差连接的效果是创建更平滑的误差函数曲面（图 9.14）。
- 通常在残差网络中包含批归一化层。
 - 二者结合显著减少梯度消失和爆炸问题。
- He et al. (2015) 表明：
 - 包含残差连接允许极深网络（可能数百层）被有效训练。

3.1 展开形式：多子网络并行

将 (9.35)(9.36)(9.37) 合并为整个网络的单一方程：

$$\mathbf{y} = \mathbf{F}_3(\mathbf{F}_2(\mathbf{F}_1(\mathbf{x}) + \mathbf{x}) + \mathbf{z}_1) + \mathbf{z}_2 \quad (9.39)$$

代入中间变量 $\mathbf{z}_1, \mathbf{z}_2$ ：

$$\mathbf{y} = \mathbf{F}_3(\mathbf{F}_2(\mathbf{F}_1(\mathbf{x}) + \mathbf{x}) + \mathbf{F}_1(\mathbf{x}) + \mathbf{x}) + \mathbf{F}_2(\mathbf{F}_1(\mathbf{x}) + \mathbf{x}) + \mathbf{F}_1(\mathbf{x}) + \mathbf{x} \quad (9.40)$$

- 整体函数由多个并行网络组成，包含层数较少的网络。
- 网络具有深层网络的表示能力（深层网络是其特例）。
- 误差曲面由浅层和深层子网络的组合调节。


4. 维度匹配

- (9.40) 定义的跳跃层连接要求：
 - 输入和所有中间变量具有**相同的维度**，才能相加。
- 可在网络中某点**改变维度**：
 - 引入**非方阵** $\mathbf{W}$ (可学习参数):

$$\mathbf{z}_i = \mathbf{F}_i(\mathbf{z}_{i-1}) + \mathbf{W}\mathbf{z}_{i-1} \quad (9.41)$$

4.1 残差连接的位置

- 最简单的 $F_i(\cdot)$ 选择：
 - 标准神经网络，交替使用可学习线性变换和固定非线性激活（如 ReLU）。
- 这开启两种放置残差连接的可能性（图 9.16）：
 - **版本 (a)**：相加的量始终**非负**（ReLU 层输出）。
 - 无法允许正负值。
 - **版本 (b)**：**更常用**。
 - 允许正负值，更灵活。



图：残差连接的两种放置方式。

5. 本节总结

- 深度网络训练困难：
 - 即使有批归一化，很多层的网络仍难以训练。
 - 破碎梯度：极小的权重变化可导致梯度显著变化。
- 残差连接：
 - 将每个函数的输入加回输出： $\mathbf{z}_i = \mathbf{F}_i(\mathbf{z}_{i-1}) + \mathbf{z}_{i-1}$ 。
 - 残差块：函数 + 残差连接。
 - ResNet：多个残差块串联。
 - 函数学习恒等映射与期望输出之间的残差。
- 效果：
 - 梯度对输入值更不敏感。
 - 创建更平滑的误差曲面。
 - 允许训练数百层的极深网络。
 - 整体函数由多个并行子网络组成。
- 实现细节：
 - 维度匹配：可引入非方阵 $\mathbf{W}$ 。
 - 残差连接位置：版本 (b) (ReLU 之后) 更常用。

6. 参考文献

- 教材: Bishop, C. M. & Bishop, H. (2023). Deep Learning Foundations and Concepts. Springer Nature Switzerland AG.
- He, K. et al. (2015). Deep residual learning for image recognition.
- Balduzzi, D. et al. (2017). The shattered gradients problem: If resnets are the answer, then what is the question?
- Li, H. et al. (2017). Visualizing the loss landscape of neural nets.