

第 9 章：正则化

第 6 节：模型平均 (Model Averaging)

《深度学习基础》课程小组

2026 年 10 月 7 日

目录

- 1 集成方法
- 2 Dropout
- 3 Dropout 的理论视角
- 4 总结
- 5 参考文献

1. 集成方法 (Ensembles)

- 若有多个不同模型解决同一问题，**平均预测**往往比选择单个最佳模型更好。
- 这种模型组合称为**委员会**或**集成**。
- 对产生概率输出的模型，预测分布为各模型预测的平均：

$$p(y|x) = \frac{1}{L} \sum_{l=1}^L p_l(y|x) \quad (9.42)$$

- 平均过程的动机：**偏差-方差权衡**。
 - 多个多项式在正弦数据上训练后平均，方差项趋于**抵消**，改善预测。

1.1 自助聚合 (Bagging)

- **实际问题**：只有一个数据集，需要引入模型间的**变异性**。
- **自助数据集** (bootstrap)：
 - 从原始数据集 $X = \{x_1, \dots, x_N\}$ 中**有放回**地抽取 N 个点。
 - 某些点可能被重复，某些点可能缺失。
- 重复 L 次生成 L 个数据集，每个训练一个模型，预测取平均。
- 该过程称为**自助聚合**或**bagging** (Breiman, 1996)。
- **替代方法**：用原始数据集训练多个**不同架构**的模型。

1.2 集成预测的理论分析 I

考虑回归问题，集成预测：

$$y_{\text{COM}}(\mathbf{x}) = \frac{1}{M} \sum_{m=1}^M y_m(\mathbf{x}) \quad (9.43)$$

每个模型输出 = 真实值 + 误差：

$$y_m(\mathbf{x}) = h(\mathbf{x}) + \epsilon_m(\mathbf{x}) \quad (9.44)$$

平均误差：

$$E_{\text{AV}} = \frac{1}{M} \sum_{m=1}^M \mathbb{E}_{\mathbf{x}} [\epsilon_m(\mathbf{x})^2] \quad (9.46)$$

集成误差（假设误差零均值且**不相关**）：

$$E_{\text{COM}} = \frac{1}{M} E_{\text{AV}} \quad (9.50)$$

1.2 集成预测的理论分析 II

- **戏剧性结果**：平均可将误差降低 M 倍。
- **但关键假设**：各模型误差**不相关**。
- 实践中误差高度相关，实际降低幅度小得多。
- 但可证明： $E_{\text{COM}} \leq E_{\text{AV}}$ 。

1.3 Boosting: 提升方法

- 另一种模型组合方法: **boosting** (Freund and Schapire, 1996)。
- 组合多个**基分类器**, 性能可显著优于任何单个基分类器。
- 即使基分类器仅比随机猜测稍好, boosting 也能给出好结果。

与 Bagging 的关键区别

- 基分类器**按顺序训练**。
- 每个基分类器使用**加权形式**的数据集。
- 权重取决于**前一个分类器的表现**。
- 被前一个分类器**误分类**的点在训练下一个分类器时获得**更大权重**。
- 最终通过**加权多数投票**组合预测。

1.4 模型组合的主要缺点

- 所有模型组合方法的主要缺点：
 - 需训练多个模型。
 - 需为所有模型评估预测。
 - 增加训练和推理的计算成本。
- 严重程度取决于具体应用场景。

2. Dropout: 隐式模型平均 I

- 广泛使用且非常有效的正则化形式 (Srivastava et al., 2014)。
- 可视为对指数级多个模型进行近似模型平均的隐式方法。
- 无需单独训练多个模型。
- 适用性广，计算成本低。
- 是最有效的正则化形式之一，应用广泛。

核心思想

训练时随机删除网络中的节点（包括其连接）。
每次呈现数据点时，重新随机选择要省略的节点。

2. Dropout: 隐式模型平均 II




图: 原始网络 (左) 和两个剪枝网络示例 (右)。

2.1 Dropout 的实现

- 应用于隐藏节点和输入节点，但不应用于输出节点。
- 等价于将丢弃节点的输出设为零。
- 实现：定义掩码向量 $R_i \in \{0, 1\}$ 。
 - 乘以非输出节点 i 的激活值。
 - 值为 1 的概率为 ρ 。
- 典型值：
 - 隐藏节点： $\rho = 0.5$
 - 输入节点： $\rho = 0.8$

2.2 Dropout 的训练过程

- 每个数据点呈现时，创建**新掩码**。
- 在剪枝网络上应用前向和反向传播，创建误差函数梯度。
- 用梯度更新权重（如 SGD）。
- 小批量：梯度在小批量内平均后再更新权重。
- 有 M 个非输出节点的网络有 2^M 个剪枝网络。
 - 训练中只考虑其中**一小部分**。

与传统集成方法的区别

- 传统集成：每个网络**独立训练至收敛**。
- Dropout：隐含训练的指数级多个网络**不独立**，而是与完整网络**共享参数**。

2.3 Dropout 的注意事项

- 训练时间可能更长：
 - 单个参数更新非常嘈杂。
- 误差函数本质上是嘈杂的：
 - 更难通过观察误差函数下降来确认优化算法正常工作。

2.4 推理阶段：模型平均

训练完成后，原则上可用集成规则 (9.42)：

$$p(\mathbf{y}|\mathbf{x}) = \sum_{\mathbf{R}} p(\mathbf{R}) p(\mathbf{y}|\mathbf{x}, \mathbf{R}) \quad (9.51)$$

- 求和遍历指数级大的掩码空间。
- 该求和难以处理，可通过采样少量掩码近似。
- 实践中10 到 20 个掩码即可获得良好结果。
- 该过程称为蒙特卡洛 Dropout。

更简单的方法：权重缩放

- 使用无掩码的训练网络进行预测。
- 重新缩放权重，使测试时每个节点的期望输入与训练时大致相同。
- 若训练时节点以概率 ρ 存在，测试时该节点的输出权重乘以 ρ 。

3. 贝叶斯视角

- **完全贝叶斯处理：**
 - 通过对所有可能的 2^M 个网络模型平均进行预测。
 - 每个网络按其**后验概率**加权。
- **计算上极其昂贵：**
 - 训练时评估后验概率。
 - 测试时计算加权预测。
- **Dropout 近似：**对每个可能的模型给予**相等权重**。

3.1 减少过拟合的直觉

- **标准网络的问题：**

- 参数可能被调整以适应单个数据点的**噪声**。
- 隐藏节点变得**过度专门化**。
- 每个节点根据其他节点的输出调整权重。
- 导致节点的**共适应**，可能无法泛化到新数据。

- **Dropout 的作用：**

- 每个节点**不能依赖**其他特定节点的存在。
- 必须在**广泛的情境**中做出有用贡献。
- 减少**共适应**和专门化。

- **理论联系：**对简单线性回归模型，dropout 正则化等价于**修改形式的二次正则化**。

4. 本节总结

● 集成方法：

- 平均多个模型的预测可改善泛化。
- 概率输出： $p(y|x) = \frac{1}{L} \sum_l p_l(y|x)$
- **Bagging**：自助数据集训练多个模型。
- **Boosting**：按顺序训练，误分类点获得更大权重。
- 理论： $E_{\text{COM}} = \frac{1}{M} E_{\text{AV}}$ （误差不相关时）。
- 主要缺点：训练和推理计算成本增加。

● Dropout：

- 训练时随机删除节点，隐式模型平均。
- 掩码向量 $R_i \in \{0, 1\}$ ，概率 ρ 。
- 隐藏节点 $\rho = 0.5$ ，输入节点 $\rho = 0.8$ 。
- 推理：蒙特卡洛 Dropout 或权重缩放。
- 贝叶斯视角：对 2^M 个模型等权平均的近似。
- 减少共适应和过度专门化。

5. 参考文献

- 教材: Bishop, C. M. & Bishop, H. (2023). Deep Learning Foundations and Concepts. Springer Nature Switzerland AG.
- Breiman, L. (1996). Bagging predictors.
- Freund, Y. & Schapire, R. E. (1996). Experiments with a new boosting algorithm.
- Srivastava, N. et al. (2014). Dropout: a simple way to prevent neural networks from overfitting.