

第 10 章：卷积网络

第 2 节：卷积滤波器 (Convolutional Filters)

《深度学习基础》课程小组

2026 年 10 月 7 日

目录

- ① 动机与四大概念
- ② 特征检测器
- ③ 平移等变性
- ④ 填充与跨步卷积
- ⑤ 多维卷积
- ⑥ 池化
- ⑦ 多层卷积与经典架构
- ⑧ 总结
- ⑨ 参考文献

1. 全连接网络的参数灾难

- 图像数据**高维**，标准全连接架构需要**海量参数**。
- 例： $10^3 \times 10^3$ 彩色图像（3 通道）+ 1000 隐藏单元
 - 第一层权重： 3×10^9
- 还必须**通过样本学习**不变性和等变性 $\Rightarrow$ 需要巨大数据集。
- **解决思路**：设计架构融入**图像结构的归纳偏置**。
 - 大幅降低数据集需求
 - 改善关于图像空间对称性的泛化

1.1 四大核心概念

利用图像二维结构创建归纳偏置：

- ① **层级性** (hierarchy)：从低级特征到高级概念
- ② **局部性** (locality)：单元只看小区域
- ③ **等变性** (equivariance)：输出随输入变换而变换
- ④ **不变性** (invariance)：输出不随输入变换改变

人脸检测的层级结构

图像 → 人脸 → 眼睛 → 虹膜 → 边缘

- **关键**：层级性的**通用概念**构建到模型中，但**层级细节**（每层特征类型）从数据中学习，而非硬编码。
- 层级模型天然适合深度学习：端到端训练，高层特征自动涌现。

2. 感受野与滤波器 (10.2.1)

- 先考虑灰度图像（单通道）。
- 第一层某单元只接受图像中**小矩形区域**（patch）的像素值。
- 该区域称为该单元的**感受野**，体现**局部性**。
- 单元输出：

$$z = \text{ReLU}(\mathbf{w}^T \mathbf{x} + w_0) \quad (10.1)$$

- 每个输入像素对应一个权重，权重本身形成小二维网格：
 - 称为**滤波器**或**核**，可可视化图像。




图: (a) 感受野 3×3 ; (b) 权重可视化核。

2.1 滤波器作为模板匹配器


- 假设 $\mathbf{w}$ 和 w_0 固定，问什么输入 $\mathbf{x}$ 给出最大响应？
- 约束 $\|\mathbf{x}\|^2$ 固定，最大化 $\mathbf{w}^T \mathbf{x}$ 的解：

$$\mathbf{x} = \alpha \mathbf{w} \quad (1)$$

- **含义**：最大响应出现在图像块**看起来像滤波器图像**时（允许整体缩放）。
- ReLU 仅在 $\mathbf{w}^T \mathbf{x} > -w_0$ 时产生非零输出。
- 单元充当**特征检测器**：找到足够好的匹配时发出信号。

3. 平移等变性 (10.2.2)

- 若某位置的小块表示眼睛，则其他位置的相同像素值也表示眼睛。
- 网络需**泛化到所有位置**，无需每个位置都有训练样本。
- **方法**：在图像多个位置**复制相同的权重值**。



图：一维卷积：6 个连接，仅 2 个独立可学习参数。

- 隐藏层单元构成**特征图**，所有单元**共享权重**。
- 图像某块产生特定响应 $\Rightarrow$ 平移后相同像素值在特征图相应平移位置产生相同响应。
- 这就是**等变性**。

3.1 卷积的两大核心特性

稀疏连接 (Sparse Connections)

大多数连接不存在，减少权重数量。

参数共享 (Parameter Sharing)

所有权重值由所有隐藏单元共享，大幅减少独立参数。

- 这种变换称为**卷积**。

3.2 二维卷积的数学定义

图像 I (像素 $I(j, k)$), 滤波器 K (像素 $K(l, m)$), 特征图 C :

$$C(j, k) = \sum_l \sum_m I(j + l, k + m) K(l, m) \quad (10.2)$$

- 可表示为 $C = I * K$ 。
- 严格来说是**互相关**，但机器学习文献惯例称为卷积。
- 图 10.3: 3×3 图像 + 2×2 滤波器 $\rightarrow 2 \times 2$ 特征图。

批归一化的特殊要求

卷积网络中使用批归一化时，**特征图内每个空间位置**必须使用相同的均值和方差。
确保特征图统计特性**与位置无关**。

3.3 手工设计的边缘检测滤波器

垂直边缘检测 (3×3 滤波器):

$$\begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix} \quad (10.3)$$

水平边缘检测 (转置):

$$\begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix} \quad (10.4)$$

- 直观: 水平扫过图像时强度显著局部变化 $\Rightarrow$ 垂直边缘。
- 正权重对应右/下像素, 负权重对应左/上像素 $\Rightarrow$ 方向性导数。

3.4 边缘检测结果的正负响应




图: (a) 原图; (b) 垂直边缘检测; (c) 水平边缘检测。

- 垂直边缘对应**强度增加** $\Rightarrow$ 特征图对应点**为正** (亮色)。
- 垂直边缘对应**强度减小** $\Rightarrow$ 特征图对应点**为负** (暗色)。
- 水平边缘类似。

3.5 卷积结构相对全连接的三大优势

- ① **稀疏连接**：即使大图像也只需很少权重。
- ② **权重共享**：大幅减少独立参数 $\Rightarrow$ 降低训练集大小需求。
- ③ **输入尺寸灵活**：相同网络可应用于不同尺寸图像，无需重新训练。
 - 改变输入尺寸只改变特征图大小，**不改变权重数量**。

GPU 并行

卷积操作在大量位置上重复，特别适合 GPU 大规模并行，实现高计算吞吐。

4. 填充 (Padding, 10.2.3)

- 卷积映射比原图小: $J \times K$ 图像 + $M \times M$ 核 $\rightarrow (J - M + 1) \times (K - M + 1)$ 。
- 若希望输出与输入**尺寸相同**: 填充 P 个像素。
 - 输出: $(J + 2P - M + 1) \times (K + 2P - M + 1)$
- 有效卷积**: $P = 0$, 输出缩小。
- 相同卷积**: $P = (M - 1)/2$, 输出与输入同尺寸。
- 滤波器通常用**奇数** M : 对称填充 + 明确定义的中心像素。
- 填充值通常设**零** (配合图像零均值化)。
- 填充也可应用于特征图, 供后续卷积层处理。

4.1 跨步卷积 (Strided Convolutions, 10.2.4)

- 大图像 + 小核 $\Rightarrow$ 特征图与原图相近。
- 有时希望特征图**显著更小**，为架构设计提供灵活性。
- 跨步卷积**：滤波器以步长 S 移动（而非 1 像素）。
- 水平和垂直同一步长时，特征图元素数量：

$$\left\lfloor \frac{J + 2P - M}{S} - 1 \right\rfloor \times \left\lfloor \frac{K + 2P - M}{S} - 1 \right\rfloor \quad (10.5)$$

- 大图像 + 小滤波器：特征图约为原图的 $1/S$ 。
- 核心功能：**下采样**，减少空间尺寸。

5. 多通道输入的卷积 (10.2.5)

- 彩色图像：3 通道（红、绿、蓝）。
- 扩展滤波器维度以覆盖多通道。
- 图像： $J \times K \times C$ 的张量。
- 滤波器： $M \times M \times C$ 的张量，每个输入通道一个 $M \times M$ 滤波器。
- 无填充、步长 1：特征图 $(J - M + 1) \times (K - M + 1)$ 。




图: (a) 多维滤波器; (b) $3 \times 3 \times 3$ 张量, 27 个权重。

5.1 多输出通道

- 单滤波器 $\approx$ 全连接网络中的单个隐藏节点，只能检测一种特征。
- **扩展**：包含多个滤波器，每个有独立参数和独立特征图。
- 这些独立特征图也称为通道。
- 滤波器张量： $M \times M \times C \times C_{OUT}$
 - C ：输入通道数
 - C_{OUT} ：输出通道数
- 总参数数量： $(M^2 C + 1) C_{OUT}$
- **关键**：参数数量与输入图像空间尺寸无关。

5.2 1×1 卷积

- 滤波器尺寸为单个像素的卷积层。
- 滤波器有 C 个权重（每个输入通道一个）+ 一个偏置。
- **应用**：改变通道数量（通常减少），不改变特征图空间尺寸。
- 与跨步卷积或池化互补：
 - 1×1 卷积：减少通道数
 - 跨步卷积/池化：减少空间维度
- 本质：跨通道的全连接层（对每个位置独立应用）。

6. 池化 (Pooling, 10.2.6)


- 卷积层编码**平移等变性**：特征平移 $\Rightarrow$ 特征图相应平移。
- 适用于**定位**任务（如找物体位置）。
- 但**分类**任务希望输出对平移**不变**。
- 需要层级结构，但简单特征的**微小相对位置变化**不应影响分类。
- **解决方案**：对卷积层输出应用**池化**。

等变性 vs 不变性

- 等变性：输出随输入平移而**同步平移**
- 不变性：输出对平移**不敏感**

6.1 最大池化

- 池化结构与卷积类似：网格排列，每个单元有感受野。
- 需选择滤波器尺寸和步长。
- 关键区别**：池化输出是输入的**简单固定函数**，**无可学习参数**。
- 最大池化**：每个单元输出输入值的**最大值**。



图：2 × 2 块用 max 运算符合并，生成更小特征图。

6.2 池化的功能与类型

- 双重功能：
 - ① 引入局部**平移不变性**
 - ② 通过**下采样**降低表示维度
- 卷积层步长 > 1 也有下采样效果（但可学习）。
- 特征图激活值 = 特征检测强度。
 - 最大池化：保留“特征是否存在”及强度，**丢弃部分位置信息**。
- 其他池化函数：**平均池化**（计算感受野平均值）。
- 所有池化都引入一定程度的**局部平移不变性**。

6.3 通道独立池化与跨通道池化

通道独立池化

池化通常独立应用于每个通道。

- 例：8 通道 64×64 特征图， 2×2 最大池化步长 2
- 输出： $32 \times 32 \times 8$
- 池化不改变通道数，只改变空间维度。

跨通道池化

对特征图的多个通道进行池化。

- 使网络能学习除平移外的其他不变性。
- 例：多个通道检测同一特征的不同朝向，跨通道最大池化 $\approx$ 旋转不变性。

6.4 池化适应变尺寸图像


- 卷积网络最终输出（及部分中间层）必须有**固定尺寸**。
- **问题**：如何用同一网络处理不同尺寸图像？
- **方法**：根据图像尺寸**调整池化步长**。
 - 使池化输出的数量保持**恒定**。
 - 从而适配可变尺寸输入。
- 注意：步长变化改变感受野覆盖密度，可能影响特征提取的尺度一致性。

7. 多层卷积 (10.2.7)

- 单层卷积 $\approx$ 全连接网络的单层。
- 堆叠多层 $\Rightarrow$ 发现和表达层次化结构。
- 每个卷积层：
 - 滤波器张量 $M \times M \times C_{\text{IN}} \times C_{\text{OUT}}$
 - 参数量 $(M^2 C_{\text{IN}} + 1) C_{\text{OUT}}$
- 每个卷积层后可选跟池化层。
- 某层 C_{OUT} 个输出通道 $\rightarrow$ 下一层的输入通道。
- 术语注意：通道数有时称“深度”，但本书保留“深度”表示层数。

7.1 感受野随深度增长

- 关键属性：**局部性**——每个单元只从上一层小区域取信息。
- 深层网络中，后层单元的有效感受野**远大于**早期层。



图：有效感受野随深度增长。

- 不增加参数，通过**层级组合**自然扩大视野。
- 这是深度卷积网络捕捉全局上下文的基础。

7.2 全连接层作为输出阶段

- 分类等任务需对**整张图像**做预测。
- 通常引入 1-2 个**全连接层**作为网络最后阶段。
- 每层单元与上一层所有单元相连。
- 参数量可管理：因池化使最终卷积层维度远低于输入层。
- **注意**：最终全连接层可能包含网络中**大部分独立参数**。
 - 即使卷积层（共享）连接数更多。

7.3 完整 CNN 架构设计

- 完整 CNN：
 - 多个卷积层 + 池化操作
 - 最后阶段常有传统全连接层
- 设计选择（超参数）：
 - 层数、每层通道数
 - 滤波器尺寸、步长宽度
 - 等多个超参数
- **困难**：训练成本高，难以用留出数据系统比较。
- 已探索各种架构，依赖经验法则和迁移已有成功架构。

7.4 早期成功与 ImageNet (10.2.8)

- CNN 是首批成功部署的**深度神经网络**。
- **LeNet**: 低分辨率手写数字灰度图像分类。
- **ImageNet** 推动发展:
 - 约 1400 万张自然图像
 - 近 22,000 个类别
 - 远超此前数据集规模
- 强调**大规模数据** + **适当归纳偏置**的模型的重要性。

7.5 ImageNet 挑战赛与 AlexNet

- 子集：1000 个不重叠类别。
- 随机猜测错误率：99.9
- 数据：128 万训练 + 5 万验证 + 10 万测试。
- 评价：top-1 和 top-5 错误率。
- 早期结果：top-5 错误率约 25.5

AlexNet (2012) 突破

赢得 2012 年比赛，top-5 错误率降至 15.3%。

- ReLU 激活函数
- GPU 训练
- Dropout 正则化

后续年份错误率降至约 3%，优于人类约 5% 的水平。

7.6 VGG-16 架构详解

- VGG = Visual Geometry Group, 16 = 可学习层数。
- 输入: $224 \times 224 \times 3$ 。
- 设计原则: **统一架构**, 最小化超参数选择。
- 所有卷积层: 3×3 滤波器, 步长 1, same padding, ReLU。
- 所有最大池化: 步长 2, 2×2 滤波器 (下采样 4 倍)。
- 通道数变化: $64 \rightarrow 128 \rightarrow 256 \rightarrow 512$
 - 下采样时**通道数加倍**, 平衡表示容量。
- 最后 3 层**全连接**: 4096, 4096, 1000。
- 总参数: 约 **1.38 亿**。
 - 近 1.03 亿在**第一个全连接层**。
 - 大部分连接在第一个卷积层。

7.7 小卷积核堆叠的优势

- 早期 CNN：较大感受野（如 AlexNet 11×11 ，步长 4）。
- 大感受野也可通过多层小感受野隐式实现。
- 优势：
 - 参数显著更少
 - 对较大滤波器施加归纳偏置（必须由卷积子滤波器组合）
- 尽管架构复杂，只需编码网络函数本身：
 - 导数用自动微分计算
 - 代价函数用随机梯度下降优化

8. 本节总结

- **动机**：全连接网络参数爆炸，需融入图像结构归纳偏置。
- **四大概念**：层级性、局部性、等变性、不变性。
- **感受野与滤波器**：局部输入区域，权重可视化为核心。
- **滤波器 = 模板匹配器**：最大响应于与核形状一致的输入。
- **平移等变性**：权重复制实现位置泛化。
- **卷积两大特性**：稀疏连接、参数共享。
- **填充**：有效卷积 vs 相同卷积。
- **跨步卷积**：下采样，减少空间尺寸。
- **多维卷积**：多输入通道 + 多输出通道。
- **1×1 卷积**：通道维度变换。
- **池化**：平移不变性 + 降维，无可学习参数。
- **多层卷积**：感受野随深度增长，全连接层作为输出阶段。
- **经典架构**：LeNet, AlexNet, VGG-16。

9. 参考文献

- 教材: Bishop, C. M. & Bishop, H. (2023). Deep Learning Foundations and Concepts. Springer Nature Switzerland AG.
- LeCun, Y. et al. (1998). Gradient-based learning applied to document recognition.
- Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks.
- Simonyan, K. & Zisserman, A. (2014). Very deep convolutional networks for large-scale image recognition.
- Dumoulin, V. & Visin, F. (2016). A guide to convolution arithmetic for deep learning.
- Lin, M., Chen, Q., & Yan, S. (2013). Network in network.