

第 10 章：卷积网络

第 3 节：可视化训练好的 CNN (Visualizing Trained CNNs)

《深度学习基础》课程小组

2026 年 10 月 7 日

目录

- 1 视觉皮层
- 2 可视化训练好的滤波器
- 3 显著图
- 4 对抗攻击
- 5 合成图像
- 6 总结
- 7 参考文献

1. 视觉皮层 (10.3.1)

- CNN 的许多动机来自**神经科学**的开创性研究。
- 视网膜电信号通过视觉皮层的一系列处理层变换。
- 视觉皮层位于大脑后部，神经元组织成**二维薄片**，形成对二维视野的映射。
- **Hubel 和 Wiesel (1959)**：测量猫视觉皮层单个神经元的电响应。
 - **简单细胞**：对特定角度、特定位置的简单边缘有强烈响应。
 - **复杂细胞**：对更复杂刺激响应，似乎由简单细胞输出组合而来。
 - 更深层：更特定的响应，更大的不变性（“祖母细胞”）。

1.1 Gabor 滤波器 I

简单细胞的响应可用 Gabor 滤波器建模：

$$G(x, y) = A \exp(-\alpha \bar{x}^2 - \beta \bar{y}^2) \sin(\omega \bar{x} + \phi) \quad (10.6)$$

其中

$$\bar{x} = (x - x_0) \cos(\theta) + (y - y_0) \sin(\theta) \quad (10.7)$$

$$\bar{y} = -(x - x_0) \sin(\theta) + (y - y_0) \cos(\theta) \quad (10.8)$$

- θ ：方向角
- ω ：频率， ϕ ：相位角
- (x_0, y_0) ：位置
- α, β ：衰减速率（控制局部化范围）

1.1 Gabor 滤波器 II




图: Gabor 滤波器示例: θ 从 0 到 $\pi/2$, ω 从 1 到 10。

1.2 复杂细胞与 Neocognitron

- **复杂细胞**：组合简单细胞输出，对位置等小变化有**不变性**。
 - 类似 CNN 中的**池化单元**。
- 更深层：更具体的响应，更大的不变性。
- **Neocognitron** (Fukushima, 1980)：CNN 的前身。
 - 多层处理：局部感受野 + 共享权重
 - 局部平均/最大池化 $\Rightarrow$ 位置不变性
 - **局限**：缺乏端到端训练（早于反向传播）
 - 依赖无监督聚类算法的**贪婪逐层学习**

2. 可视化训练好的滤波器 (10.3.2)

- **第一层滤波器**：可直接可视化为小图像。
 - 对应原始输入图像空间中的小图像块。
 - 第一层计算滤波器与图像块的**内积**。
 - 内积幅度大 $\Rightarrow$ 单元激活强。
- 图 10.12: ImageNet 训练的 AlexNet 第一层滤波器。
 - 与 Gabor 滤波器**显著相似**。
- **但注意**：这不意味着 CNN 是大脑工作方式的良好模型。
 - 类似结果也可由多种统计方法得到。
 - 这些滤波器是**自然图像统计的一般性质**。

2.1 后续层的可视化


- 后续层**难以直接解释**：输入不是图像块，而是滤波器响应的组合。
- **方法**（类似 Hubel 和 Wiesel）：
 - 向网络呈现大量图像块
 - 观察哪些产生最高激活值

图 10.13 的发现：层次结构

- 第 1 层：**边缘**
- 第 2 层：**纹理和简单形状**
- 第 3 层：**物体部件**（如车轮）
- 第 5 层：**完整物体**

2.2 数值优化生成代表性图像

- 扩展技术：对输入变量进行**数值优化**，最大化特定单元的激活。
- 若选择输出单元，可寻找最能代表对应类别的图像。
- **关键技巧**：最大化**预激活值**（softmax 之前）而非类别概率。
 - softmax 分母会耦合其他类别。
 - 例：优化“狗”的 softmax 输出可能使图像“不那么像猫”。
- **需要正则化**：
 - 无约束优化 $\Rightarrow$ 像素值趋向无穷大 + 高频结构
 - Yosinski et al. (2015)：像素平方和 + 模糊 + 裁剪



图：通过最大化类别概率生成的合成图像。

3. 显著图 (10.3.3) I

- **显著图**：识别图像中对确定类别标签**最重要的区域**。
- **选择最后一个卷积层的原因**：
 - 仍保留**空间定位**信息
 - 具有**最高层次的语义**表示
 - 后续全连接层会丢失空间信息
- **Grad-CAM**（梯度类别激活映射）方法：

3. 显著图 (10.3.3) II

Grad-CAM 核心步骤

- ① 计算类别 c 的预激活值 $a^{(c)}$ 对最后卷积层各单元 $a_{ij}^{(k)}$ 的导数
- ② 对每个通道取平均，得到权重：

$$\alpha_k = \frac{1}{M_k} \sum_i \sum_j \frac{\partial a^{(c)}}{\partial a_{ij}^{(k)}} \quad (10.9)$$

- ③ 加权求和：

$$\mathbf{L} = \sum_k \alpha_k \mathbf{A}^{(k)} \quad (10.10)$$

- 显著图与最后卷积层同维度（如 VGG 为 14×14 ），可叠加为热力图。

4. 对抗攻击 (10.3.4) I

- **对抗攻击**：对图像进行微小、人类不可察觉的修改，使网络错误分类。
- **快速梯度符号法** (Goodfellow et al., 2014):

$$\mathbf{x}' = \mathbf{x} + \epsilon \operatorname{sign}(\nabla_{\mathbf{x}} E(\mathbf{x}, t)) \quad (10.11)$$

- t : 真实标签
- $E(\mathbf{x}, t)$: 误差函数 (如负对数似然)
- 梯度用**反向传播**高效计算
- **与训练的区别**:
 - 训练：调整**网络参数**以**最小化**误差
 - 攻击：固定网络参数，调整**图像**以**最大化**误差
- ϵ 小 $\Rightarrow$ 人类不可察觉，但网络可能高置信度误分类。

4. 对抗攻击 (10.3.4) II




图: 对抗攻击示例: 熊猫 $\rightarrow$ 长臂猿 (99.3% 置信度)。

4.1 对抗攻击的普遍性与安全影响 I

- 表面看似过拟合，但事实并非如此：
 - 对抗图像可**迁移**：欺骗多个不同网络。
 - **线性模型**也能产生类似对抗结果。
 - 可构造**物理制品**，使真实拍摄图像被误分类。
- **安全影响**：
 - 为攻击训练好的分类器创造机会。
 - 简单修改训练过程可应对基本攻击。
 - 更复杂方法难以防御，仍是**开放研究领域**。

4.1 对抗攻击的普遍性与安全影响 II



图: 修改后的停车标志被分类为限速标志。

5. DeepDream: 合成图像 (10.3.5)

- 目标: 生成具有**夸张特征**的合成图像。
- 确定特定隐藏层中哪些节点响应强烈, 然后修改图像以**放大这些响应**。

DeepDream 基本步骤

- 1 图像输入网络, 前向传播到某个特定层
- 2 将该层的反向传播 δ 变量设为该层节点的**预激活值**
- 3 反向传播到输入层, 得到像素上的**梯度向量**
- 4 沿梯度方向迈出一小步修改图像
- 5 可重复多次以获得更强增强

- 目标函数:

$$F(\mathbf{I}) = \sum_{i,j,k} a_{ijk}(\mathbf{I})^2 \quad (10.12)$$

- 正则化: **空间平滑** + **像素裁剪**, 避免高频结构。

5.1 DeepDream 的效果与用途

- 可应用于照片，或从随机噪声开始生成完全由网络生成的图像。
- 有趣：尽管 CNN 被训练用于区分物体类别，它们似乎捕捉了生成图像所需的部分信息。
- **主要用途**：生成有趣图像的艺术形式。
- 提供对训练网络操作的一些洞见。

6. 本节总结

- **视觉皮层：**
 - 简单细胞 (Gabor 滤波器)、复杂细胞 (池化)、祖母细胞 (深层不变性)
 - Neocognitron: CNN 前身, 但无端到端训练
- **可视化训练好的滤波器：**
 - 第一层可直接可视化为小图像, 与 Gabor 滤波器相似
 - 后续层: 通过最大激活图像块, 显示层次结构 (边缘 → 纹理 → 部件 → 物体)
 - 数值优化生成代表性图像, 需正则化
- **显著图：**
 - Grad-CAM: 识别对类别最重要的区域
 - 使用最后卷积层 (保留空间定位 + 最高语义)
- **对抗攻击：**
 - 快速梯度符号法: 微小修改使网络误分类
 - 普遍存在: 可迁移、线性模型也可、物理制品
- **DeepDream：**
 - 放大特定层响应, 生成夸张特征图像
 - 判别模型也能捕捉生成所需信息

7. 参考文献

- 教材: Bishop, C. M. & Bishop, H. (2023). Deep Learning Foundations and Concepts. Springer Nature Switzerland AG.
- Hubel, D. H. & Wiesel, T. N. (1959). Receptive fields of single neurones in the cat's striate cortex.
- Fukushima, K. (1980). Neocognitron: A self-organizing neural network model.
- Zeiler, M. D. & Fergus, R. (2013). Visualizing and understanding convolutional networks.
- Selvaraju, R. R. et al. (2016). Grad-CAM: Visual explanations from deep networks via gradient-based localization.
- Goodfellow, I. J., Shlens, J., & Szegedy, C. (2014). Explaining and harnessing adversarial examples.
- Mordvintsev, A., Olah, C., & Tyka, M. (2015). Inceptionism: Going deeper into neural networks.