

第 10 章：卷积网络

第 4 节：目标检测 (Object Detection)

《深度学习基础》课程小组

2026 年 10 月 7 日

目录

- 1 边界框
- 2 交并比
- 3 滑动窗口
- 4 跨尺度检测
- 5 非极大值抑制
- 6 快速区域 CNN
- 7 总结
- 8 参考文献

1. 从分类到目标检测

- 图像分类：整张图像分配到**单一类别**。
 - 适用于 ImageNet 这类每张图由单一物体主导的数据集。
- 许多应用需要检测**多个物体**及其**位置**。
- CNN 卷积层学到**广泛适用**的内部表示。
- 可针对各种具体任务**微调**（迁移学习）。
- 例：ImageNet 训练的 CNN → 皮肤病变分类达到人类水平。

1.1 边界框 (Bounding Box, 10.4.1) I

- 许多图像包含属于一个或多个类别的多个物体。
- 需检测每个物体的存在、类别和位置。
- 例：自动驾驶检测行人、道路标志、其他车辆。

1.1 边界框 (Bounding Box, 10.4.1) II

边界框

紧贴物体边界的矩形，用向量表示：

$$\mathbf{b} = (b_x, b_y, b_W, b_H) \quad (1)$$

- b_x, b_y ：中心坐标
- b_W, b_H ：宽度和高度
- 可用像素表示，也可归一化为连续数值
- 约定：左上角 $(0, 0)$ ，右下角 $(1, 1)$

1.1 边界框 (Bounding Box, 10.4.1) III




图: 多个物体的边界框标注。

1.2 单物体分类与定位

- 假设图像包含一个且仅一个来自 C 个类别的物体。
- CNN 通常有 C 个输出单元 (**softmax** 激活)。
- 额外**四个输出** (**线性**激活) 预测边界框坐标。
- 边界框坐标是**连续量** $\Rightarrow$ 使用**平方和误差**。

YOLO 早期思想 (Redmon et al., 2015)

- 将图像划分为 7×7 网格
- 每个网格单元输出关联物体的类别和边界框坐标
- 基于来自整张图像的特征进行预测

2. 交并比 (IoU, 10.4.2) I

- 目标定位需要衡量边界框相对于**真实标注**的准确度。
- 简单重叠面积的问题：
 - 受物体大小影响
 - 无法惩罚预测框落在真实框之外的部分
- **交并比 (IoU)**: 交集面积与并集面积之比。

$$\text{IoU} = \frac{\text{交集面积}}{\text{并集面积}} \quad (2)$$

- 取值范围: **0 到 1**。
- 通常 IoU 超过阈值 **0.5** 认为预测正确。

2. 交并比 (IoU, 10.4.2) II




图: IoU 示意图: 交集 (左绿) 除以并集 (右绿)。

2.1 IoU 的作用与局限

- 优点:

- 比值形式对物体大小归一化
- 并集包含预测框在真实框之外的部分 $\Rightarrow$ 惩罚越界预测

- 局限:

- 一般不直接用作训练损失函数
- 难以通过梯度下降优化
- 训练通常使用居中物体进行
- IoU 主要用作评估指标

3. 滑动窗口 (10.4.3)

- 基本思想:


- 用紧密裁剪的物体样本 + 背景样本训练分类器
- 输入窗口在图像上扫描
- 每个位置分类, 高概率位置对应边界框

- 缺点:

- 潜在窗口位置数量巨大, 计算成本高
- 需多尺度窗口处理不同大小的物体
- 大步幅节省计算但降低定位精度 (权衡)
- 对百万参数的深度网络, 朴素实现成本不可接受

3.1 卷积网络中的计算冗余 I

- 卷积层本身就是**滑动特征检测器**（共享权重）。
- 滑动窗口生成多次前向传播时，存在**大量冗余计算**。



图：重叠窗口位置的计算共享（绿色感受野）。

3.1 卷积网络中的计算冗余 II

- **关键洞察**：滑动窗口的计算结构**镜像**卷积的计算结构。
- 因此可在卷积网络中**高效实现**滑动窗口。

3.2 简化网络示例 I

- 图 10.22: 卷积层 + 最大池化层 + 全连接层。
- 输入 6×6 , 卷积层 3×3 步幅 1。
- 最大池化 2×2 步幅 1 (不重叠感受野)。
- 全连接层单输出单元。
- **关键:** 全连接层可视为滤波器大小 2×2 的卷积层。
 - 只有一个位置 $\Rightarrow$ 单个输出。

3.2 简化网络示例 II




图: 简单卷积网络示例。

3.3 扩大到更大图像 I

- 网络在居中物体图像上训练。
- 应用于更大图像 (8×8): 增大卷积和池化层大小。
- 卷积层: 6×6 ; 池化层: 3×3 。
- 得到四个输出单元, 权重共享。
- 处理左上角窗口的计算 = 处理原始 6×6 输入的计算。
- 其余窗口位置只需少量额外计算 (蓝色区域)。
- 效率显著优于朴素重复应用。

3.3 扩大到更大图像 II




图: 应用于更大图像, 额外计算对应蓝色区域。

4. 跨尺度检测 (10.4.4)

- 需在不同**尺度**和**宽高比**下寻找物体。
- 例：猫直立 vs 躺下，边界框宽高比不同。
- **方法**：固定输入窗口 + **图像多副本缩放**。
 - 制作输入图像的多个副本
 - 每个副本有不同的水平/垂直缩放因子对
 - 固定窗口在每个副本上扫描
 - 用缩放因子将边界框坐标**变换回原始空间**



图：(a) 原图；(b) 水平缩放副本 + 检测；(c) 投影回原图。

- 与“多尺度窗口”**等价**，但实现更简单。

5. 非极大值抑制 (10.4.5) I

- 滑动窗口扫描会产生**同一物体的多次检测** (相近位置)。
- 通过**非极大值抑制**解决, 对每个类别依次执行:

算法流程

- ① 在整个图像上运行滑动窗口, 评估每个位置的类别概率
- ② 消除概率**低于阈值** (如 0.7) 的边界框
- ③ 将**概率最高**的框视为成功检测并记录
- ④ 丢弃与成功检测框 **IoU 超过阈值** (如 0.5) 的其他框
- ⑤ 在剩余框中重复步骤 3-4
- ⑥ 直到所有框被丢弃或宣布为成功检测

5. 非极大值抑制 (10.4.5) II




图: 非极大值抑制: 红框最高概率, 抑制蓝框, 保留绿框。

5.1 两个关键阈值

阈值	典型值	作用
概率阈值	0.7	过滤低置信度检测
IoU 阈值	0.5	判定重叠过多，应被抑制

- **按类别独立处理**：避免不同类别相互干扰。
- 保留同一类别**不同实例**的检测（如图中绿色框）。
- 位于滑动窗口和多尺度检测之后的**后处理步骤**。

6. 快速区域 CNN (10.4.6)

- **滑动窗口的计算浪费**：对图像所有区域应用完整深度网络。
- **改进思路**：先用低成本技术识别**可能包含物体的区域**。
- **快速 R-CNN** (Girshick, 2015):
 - 用分割算法等低成本技术生成区域提议
 - 仅对这些区域应用完整网络
- **更快的 R-CNN** (Ren et al., 2015):
 - 使用**区域提议卷积网络**识别最有希望的区域
 - 允许区域提议网络与检测定位网络**端到端训练**

6.1 滑动窗口与直接边界框预测结合

- **滑动窗口的缺点**：精确局部化需大量密集窗口位置，计算昂贵。
- **更高效的方法**：结合滑动窗口与**直接边界框预测**。
 - 连续输出预测边界框**相对于窗口位置的偏移**
 - 对预测位置进行**微调**
 - 在保持精度的同时提高效率

总结：目标检测流程

滑动窗口 → 多尺度检测 → 非极大值抑制 → 区域提议（快速/更快的 R-CNN）

7. 本节总结 I

- **边界框:**
 - $\mathbf{b} = (b_x, b_y, b_w, b_h)$
 - 单物体: C 个 softmax 输出 + 4 个线性输出
 - 平方和误差
- **交并比 (IoU):**
 - 交集面积 / 并集面积
 - 范围 0 到 1, 阈值 0.5
 - 主要用作评估指标
- **滑动窗口:**
 - 计算冗余, 但可利用卷积结构高效实现
 - 全连接层可视为卷积层
- **跨尺度检测:**
 - 固定窗口 + 图像多副本缩放
- **非极大值抑制:**

7. 本节总结 II

- 迭代选最大概率框，抑制重叠框
- 概率阈值 0.7, IoU 阈值 0.5
- 快速/更快的 R-CNN:
 - 区域提议 + 端到端训练
 - 滑动窗口 + 直接边界框预测

8. 参考文献

- 教材: Bishop, C. M. & Bishop, H. (2023). Deep Learning Foundations and Concepts. Springer Nature Switzerland AG.
- Redmon, J. et al. (2015). You only look once: Unified, real-time object detection.
- Sermanet, P. et al. (2013). OverFeat: Integrated recognition, localization and detection using convolutional networks.
- Girshick, R. (2015). Fast R-CNN.
- Ren, S. et al. (2015). Faster R-CNN: Towards real-time object detection with region proposal networks.