

第 10 章：卷积网络

第 5 节：图像分割 (Image Segmentation)

《深度学习基础》课程小组

2026 年 10 月 7 日

目录

- 1 语义分割与卷积分割
- 2 上采样
- 3 全卷积网络
- 4 U-net 架构
- 5 总结
- 6 参考文献

1. 语义分割 (10.5)

- 图像分类：整图一个类别标签。
- 目标检测：多个物体 + 边界框。
- **语义分割**：每个像素分配到预定义类别之一。
 - 输出空间与输入图像**同维度**
 - 可方便地表示为相同像素数的图像
- 输入图像：3 通道 (R、G、B)。
- 输出数组：C 通道 (C 个类别)，表示各类别概率。
- 每类关联一种颜色，按最高概率着色。



图：图像及其对应语义分割。

1.1 卷积分割 (10.5.1)


- **简单方法**：以每个像素为中心的矩形区域输入 CNN，单 softmax 输出分类该像素。
 - 逐像素处理即可分割整张图像（需边缘填充）。
- **问题**：重叠图像块导致**大量冗余计算**，极其低效。
- **卷积化改进**：
 - 将不同输入位置的前向传播计算组合到单个网络
 - 最终全连接层也变为**卷积层**
- **保持维度**：每层步幅 1 + 相同填充 + 无池化。
- 每个输出单元共享 softmax 权重。

计算成本问题

虽概念上可行，但达到高精度仍需**多层多通道**，对合理分辨率图像成本过高。

2. 上采样 (10.5.2)

- 大多数卷积网络使用**下采样**：通道数增加时特征图尺寸减小。
 - 保持网络规模 and 成本可控
 - 提取高阶语义特征
- **高效分割架构**：标准深度卷积网络 + **可学习上采样层**。
 - 将低维内部表示变换回原始图像分辨率



图：下采样（跨步卷积/池化）后跟上采样（转置卷积/反池化）。

2.1 反池化：池化的上采样对应 I

平均池化的上采样对应

- 将每个输入值复制**到所有**对应的 2×2 输出单元
- 对输出应用平均池化可**恢复输入**

最大池化的上采样对应（最大反池化）

- 每个输入值复制到对应输出块的**第一个单元**
- 其余值设为零
- 对输出应用最大池化可恢复输入

2.1 反池化：池化的上采样对应 II





图: (a) 平均池化对应; (b) 最大池化对应。

2.2 保留空间信息的改进方法

- 将非零值固定在第一个元素**过于随意**。
- **改进**：记录下采样时每个块中**最大值的位置**。
- 上采样时将非零元素放在**相同位置**。
- 保留更多来自下采样层的**空间信息**。



图：记录最大值位置，上采样时放在对应位置。

3. 转置卷积 (10.5.3) I

- 固定上采样（反池化）之外，也可使用**可学习上采样**。
- **跨步卷积（下采样）**：输出单元通过共享权重连接输入小块，输出维度低于输入。
- **转置卷积（上采样）**：输入一个像素连接到输出一个小块。
 - 沿输入移动一步时，输出移动两步或更多步
 - 输出维度高于输入
- **重叠输出**：对多个滤波器位置的贡献**求和或取平均**。

3. 转置卷积 (10.5.3) II




图: 3×3 滤波器, 输出步幅 2 的转置卷积。

3.1 转置卷积的名称与全卷积网络

名称来源

- **转置卷积**：下采样卷积写成矩阵后，上采样由**转置矩阵**给出。
- **分数步幅卷积**：步幅 = 输出步长 / 输入步长（图 10.30 中为 $1/2$ ）。
- **避免**用“反卷积”：数学中反卷积是泛函分析中卷积的逆，概念不同。

全卷积网络 (FCN)

- 无池化层，下采样和上采样**完全由卷积完成**。
- 可接受**任意大小**的图像。
- 输出**相同大小**的分割图。

4. U-net 架构 (10.5.4)

- 下采样允许增加通道数，但降低空间分辨率，丢弃位置信息。
- 图像分类可容忍，但语义分割需要逐像素分类。
- U-net (Ronneberger et al., 2015): 解决空间信息丢失问题。
 - 名称来自示意图的U 形

核心结构

- 对称排列的下采样层和上采样层
- 每个下采样层都有对应的上采样层
- 下采样层最终的通道激活与对应上采样层的第一组通道拼接
- 通过拼接，上采样层可访问更高分辨率的空间信息

4.1 U-net 的最后一层

- 最后一层可使用 1×1 卷积：
 - 将通道数减少到类别数
 - 接 softmax 激活函数
- U-net 是一种全卷积网络：
 - 继承可接受任意大小输入、输出相同大小分割图的特性
- 拼接 vs 相加：
 - U-net 使用通道拼接 (concatenation), 而非逐元素相加
 - 拼接保留高分辨率信息

5. 本节总结 I

- **语义分割：**
 - 每个像素分配到预定义类别
 - 输出与输入同维度， C 个通道
- **卷积分割：**
 - 逐像素 CNN 冗余计算
 - 卷积化改进：全连接层卷积化
 - 保持维度：步幅 1 + 相同填充 + 无池化
- **上采样：**
 - 反池化：平均池化对应（复制到块） / 最大池化对应（放在块首）
 - 改进：记录最大值位置，上采样时放在相同位置
- **转置卷积：**
 - 下采样卷积的转置矩阵
 - 分数步幅卷积
 - 避免用“反卷积”一词

5. 本节总结 II

- **全卷积网络**：无池化，完全由卷积完成，任意输入大小。
- **U-net**：
 - 对称下采样/上采样 + 跳跃拼接
 - 最后一层 1×1 卷积 + softmax
 - 同时获得语义与空间信息

6. 参考文献

- 教材: Bishop, C. M. & Bishop, H. (2023). Deep Learning Foundations and Concepts. Springer Nature Switzerland AG.
- Long, J., Shelhamer, E., & Darrell, T. (2014). Fully convolutional networks for semantic segmentation.
- Noh, H., Hong, S., & Han, B. (2015). Learning deconvolution network for semantic segmentation.
- Badrinarayanan, V., Kendall, A., & Cipolla, R. (2015). SegNet: A deep convolutional encoder-decoder architecture.
- Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation.
- Dumoulin, V. & Visin, F. (2016). A guide to convolution arithmetic for deep learning.